MINI REVIEW

LLM·RAG 애플리케이션 평가용 골든 데이터셋의 구축과 검증: 미니 리뷰

Building and Validating Golden Evaluation Datasets for LLM and RAG Applications: A Mini Review

sooyoung-wind

Pseudo-Lab no-more-slops, Auto-Paper 트랙

초록

대형 언어모델(LLM)과 검색 증강 생성(RAG) 애플리케이션을 개발하는 팀은 회귀 검사, 모델 선택, 자동 판정 모델의 보정에 소규모 평가셋을 쓰고 이를 흔히 골든 데이터셋이라 부른다. 그러나 무엇이 데이터셋을 "골든"으로 만드는지에 대한 합의된 정의는 없고, 널리 쓰이는 공개 벤치마크에서도 전체 수 퍼센트, 일부 하위 영역에서는 분석 문항의 절반이 넘는 라벨 오류가 보고되었다. 이 미니 리뷰는 주로 2015–2026년의 데이터셋 구축, 품질 검증, 문서화 문헌을 종합하여 세 질문에 답한다. 첫째, 구축 방식은 전문가 작성, 실사용 로그 선별, LLM 합성, 적대적 수집의 네 가지로 나뉘며, 어느 방식도 정확성, 현실성, 비용을 함께 만족하지 못한다. RAG 평가셋에는 검색 관련성 판정의 완전성 점검과 근거 귀속 라벨이라는 요건이 더해진다. 둘째, 검증은 구성 타당도, 라벨 신뢰도, 오류 감사, 통계적 충분성, 오염 통제의 다섯 층위로 정리되며, 문헌에는 한 층위를 통과한 평가셋에서 다른 층위의 문제가 발견된 사례가 반복 보고되었다. 셋째, 이 리뷰는 "골든"을 데이터셋의 고정된 속성이 아니라 명시된 평가 목적과 버전에 대해 일곱 가지 조건의 충족이 증거로 문서화된 상태로 정의할 것을 제안하고, 감사된 골든 핵심셋과 그 핵심셋으로 보정한 대규모 보조셋의 2단 구성을 적용 방안으로 제시한다. 끝으로 규모와 품질, 단일 정답과 관점주의, 사람 라벨과 LLM 라벨 사이의 쟁점과 연구 과제를 정리한다.

주제어: 골든 데이터셋, 평가 데이터셋, 대형 언어모델, 검색 증강 생성, 라벨 품질, 벤치마크 타당도

Abstract

Teams building large language model (LLM) and retrieval-augmented generation (RAG) applications rely on small evaluation sets, often called golden datasets, for regression testing, model selection, and calibration of automatic judges. Yet there is no agreed definition of what makes a dataset "golden," and widely used public benchmarks have been found to contain label errors at rates of a few percent overall and, in some subsets, in more than half of the analyzed items. This mini review synthesizes literature, mainly from 2015 to 2026, on dataset construction, quality validation, and documentation. Construction methods fall into expert authoring, curation of real user logs, LLM-based synthesis, and adversarial collection, and none of them secures correctness, realism, and low cost at once; RAG sets additionally require checks on the completeness of relevance judgments and attribution labels. Validation can be organized into five levels (construct validity, label reliability, error auditing, statistical adequacy, and contamination control), and the literature repeatedly reports sets that passed one level yet failed another. We propose that "golden" be defined not as an intrinsic property but as a state in which evidence that seven conditions are met is documented for a stated purpose and version, and we present a two-tier design in which an audited golden core calibrates a larger auxiliary set. We close by discussing three controversies (scale versus quality, a single answer versus perspectivism, and human versus LLM labels) and open research problems.

Keywords: golden dataset, evaluation dataset, large language models, retrieval-augmented generation, label quality, benchmark validity

1. 서론

LLM 애플리케이션 개발에서 평가셋은 프롬프트·모델·검색기를 바꿀 때마다 결과를 비교하는 기준이 된다. OpenAI 문서는 평가 항목마다 사람이 제공한 정답 라벨을 두고 이를 기준으로 변경을 검사하는 평가 주도 개발 절차를 제시하고[1], Anthropic 문서는 실제 과제 분포를 반영한 과제 특화 평가를 권고한다[2]. 실무에서는 이런 기준 집합을 골든 데이터셋(golden dataset)이라 부르지만, 그 이름이 어떤 품질을 보장하는지는 합의되어 있지 않다.

정답 라벨 자체가 틀릴 수 있다는 점은 공개 벤치마크에서 거듭 확인되었다. Northcutt 등은 널리 쓰이는 시험셋 10종의 라벨 오류율을 평균 3.3% 이상으로 추정하였고, 수정된 라벨로 평가할 때 ImageNet에서 오류 문항의 비중이 6%만 늘어도 ResNet-18이 ResNet-50을 앞서는 순위 역전이 일어남을 보였다[3]. MMLU는 문항의 6.49%에 오류가 있는 것으로 추정되었고 Virology 하위 영역에서는 분석 문항의 57%가 오류를 포함하였다[4]. GSM8K를 재검수한 결과에서는 원래 시험셋에서 똑같이 45개를 틀린 두 모델이 수정된 시험셋에서 각각 2개와 17개를 틀려, 라벨 잡음이 모델 간 차이를 가렸음이 드러났다[5]. 소규모 사내 평가셋은 이런 공개 검수를 거치지 않으므로 같은 종류의 오류가 발견되지 않은 채 남을 수 있다.

그러나 기존 서베이와 벤치마크 품질 연구는 애플리케이션 평가셋의 구축과 검증을 직접 다루지 않는다. LLM 평가 서베이는 무엇을, 어디서, 어떻게 평가할지를 정리하였고[6], RAG 평가 서베이는 지표와 벤치마크를 분류하였으며[7,8], 오염 서베이는 학습 데이터 유출을 다루었다[9,10]. 벤치마크 품질 연구는 벤치마크가 갖출 기준을 제시하거나[11] 공개 벤치마크의 모범 사례 준수와 구성 타당도를 평가하였다[12,13]. 특정 애플리케이션을 위한 평가셋을 어떻게 만들고 검증하며, 언제 골든이라 부를 수 있는지를 한데 묶은 리뷰는 이 리뷰의 검색 범위에서 확인되지 않았다.

이 리뷰는 세 질문을 다룬다. (Q1) LLM·RAG 평가셋은 어떤 방식으로 구축되며 각 방식의 위험은 무엇인가. (Q2) 구축된 평가셋은 어떤 층위에서 검증되는가. (Q3) 어떤 조건을 갖추면 평가셋을 골든이라 부를 수 있는가. 2장은 Q1, 3장은 Q2, 4장은 Q3에 답하고, 5장은 남은 쟁점과 연구 과제를 논의한다.

문헌은 2026년 10월에 arXiv, ACL Anthology, 주요 학회 논문집, 개발사 공식 문서에서 평가셋 구축, 라벨 품질, 오염, 통계적 검정력, 데이터셋 문서화를 주제어로 검색하고, 핵심 문헌의 인용을 앞뒤로 추적하여 모았다. 대상 기간은 주로 2015–2026년으로 하되, 골드 표준과 주석 일치도 개념의 기원을 설명하는 2000–2010년 문헌을 인용 추적으로 포함하였다. 데이터셋 구축 또는 검증 절차를 구체적으로 기술하거나 그 결과를 정량 보고한 문헌을 우선 포함하였고, 개발사 문서와 블로그는 회색 문헌으로 구분하여 실무 관행의 근거로만 사용하였다. 이 리뷰는 체계적 문헌고찰이 아닌 서술형 미니 리뷰이다.

2. 구축: 네 가지 출처와 RAG의 추가 요건

평가셋의 문항과 정답은 전문가 작성, 실사용 로그, LLM 합성, 적대적 수집 중 하나 또는 그 조합에서 나온다. 표 1은 문헌에서 확인한 각 방식의 장점, 위험, 보완책을 비교하며, 이 장은 그 근거를 차례로 검토한다.

2.1 전문가 작성

전문가가 문항과 정답을 직접 작성하는 방식은 정확성을 우선하지만 비용이 크고 전문가 라벨에도 잡음이 남는다. GPQA는 박사급 전문가가 문항을 쓰고 다른 전문가 두 명이 차례로 풀어 검토하며, 비전문가 세 명이 웹 검색을 허용받고도 풀지 못하는지를 확인하였다[14]. 전문가 두 명이 모두 정답에 동의하고 비전문가 정답률이 1/3 이하인 198문항이 최고 품질 부분집합으로 분리되었는데, 이는 전문가 합의와 비전문가 정답률을 함께 품질 등급의 기준으로 삼은 설계이다. 작성자에게는 시간당 평균 약 95달러가 지급되었다[14]. HealthBench에서는 262명의 의사가 48,562개의 채점 기준을 작성하였지만, 합의 기준 채점에서 의사 간 일치도와 모델–의사 일치도(macro F1)가 모두 55–75% 범위에 머물렀다[15].

2.2 실사용 로그

실제 사용자 질의는 해당 서비스의 배포 분포를 직접 반영하지만, 원시 로그를 그대로 쓰면 분포는 맞아도 평가 가치가 낮은 문항이 많아진다. MS MARCO는 Bing 검색 로그에서, Natural Questions는 Google 검색 질의에서 질문을 표집하였다[16,17]. Arena-Hard의 BenchBuilder는 Chatbot Arena 질의 20만 개를 중복 제거하고 4,000개 주제로 군집화한 뒤, LLM으로 구체성·복잡성 등 일곱 가지 품질 기준을 채점하여 500개를 선별하였다[18]. 이런 선별은 변별력을 높이지만 선별된 집합은 더 이상 원래 트래픽의 분포가 아니므로, 로그 기반 평가셋은 무엇을 기준으로 걸렀는지를 함께 기록해야 해석할 수 있다. 로그 사용은 수집 동의와 비식별화를 전제로 하며, WildChat은 명시적 동의를 받은 대화만 공개하였다[19].

2.3 LLM 합성

LLM으로 질의와 정답을 생성하면 적은 비용으로 규모와 범위를 확보할 수 있으나, 생성된 정답의 정확성과 생성 모델의 편향을 따로 검증해야 한다. 학습용 지시문 데이터를 합성한 Self-Instruct에서 사람이 생성 결과 200개를 검토한 결과 지시문의 92%는 타당하였지만 입력·출력까지 모두 올바른 항목은 54%에 그쳤다[20]. RAG 평가 도구는 문서에서 지식 그래프를 만든 뒤 단일·다중 홉 질의를 생성하거나[21], 생성된 질의가 자신의 원문 단락을 1위로 검색하는 경우만 남기는 왕복 일관성 필터를 적용하고 사람 라벨 150–300개로 판정 모델을 보정한다[22]. HealthBench는 의사가 다룰 상황 유형을 지정하고 LLM이 대화를 생성하는 혼합 설계를 썼다[15]. 편향 측면에서는 GPT-4와 Llama 2가 자신이 생성한 출력을 다른 출력과 구별하였고 자기 인식과 자기 선호의 강도가 상관을 보였으며[23], LLM으로 만든 검색 시험 모음이 LLM 기반 검색기에 유리할 위험이 분석되었다[24].

2.4 적대적 수집

모델을 틀리게 하는 문항을 사람이 작성하는 적대적 수집은 난이도를 높이지만, 겉보기에 어려운 문항 중 상당수는 정답이 모호하거나 틀린 문항이다. 이 방식은 군중 작성 데이터가 가설 문장만으로 SNLI의 약 67%를 맞히게 하는 주석 흔적을 남긴다는 보고[25] 이후 쉬운 단서를 피하는 방법으로 주목받았다. 그러나 ANLI에서 모델을 속인 것으로 보인 사례의 비율은 사람 검증 전 18.54%에서 검증 후 9.52%로 줄어, 모델을 속인 것으로 보인 문항의 약 절반이 독립 검증자의 동의를 얻지 못하였다[26]. Dynabench는 사람과 모델이 문항 작성과 검증을 반복하는 플랫폼으로 이 절차를 일반화하였다[27]. 적대적 수집에는 따라서 작성자와 독립된 검증 단계가 필수적이다.

2.5 RAG 평가셋의 추가 요건

RAG 평가셋은 질의–근거 문서–정답의 삼중 구조를 가지며, 검색 관련성 라벨의 불완전성이 평가 결과를 바꿀 수 있다. 풀링(pooling)으로 만든 관련성 판정은 판정되지 않은 문서를 비관련으로 가정하는데, 컬렉션이 커지면 이 가정이 깨지고 판정이 주제 제목의 어휘를 포함한 문서 쪽으로 치우쳤다[28]. BEIR의 TREC-COVID에서 밀집 검색기 상위 10개 결과의 최대 31.8%가 판정되지 않은 문서였고, 980건을 추가 판정하자 DPR의 nDCG@10이 0.332에서 0.445로 오르고 ANCE가 BM25를 앞서는 것으로 순위가 바뀌었다[29]. LLM 관련성 판정은 추가 판정의 비용을 낮추지만 프롬프트 표현에 따라 정확도가 달라졌다[30,31]. 근거 귀속 라벨을 NLI 모델로 자동 판정한 ALCE에서 사람 판정과의 일치도는 Cohen's κ 0.525–0.698이었다[32].

판정 라벨과 별도로, RAG 평가셋의 질의 범위는 층화와 답할 수 없는 질의로 설계할 수 있다. CRAG는 4,409개 질의를 영역, 질의 유형, 개체 인기도, 시간 변동성으로 층화하였고 인기도가 낮고 변동이 큰 층에서 정확도가 낮아짐을 보였다[33]. MultiHop-RAG는 답할 수 없는 질의 301개를 포함하여 근거 부재 시 응답 거부를 평가하였고[34], RGB는 부정 거부(negative rejection)를 별도 능력으로 시험하였다[35]. 능력×검사 유형 행렬로 문항을 계획하는 CheckList는 이런 층화 설계를 행동 검사로 체계화하였다[36].

표 1. 평가셋 구축 방식별 장점, 위험, 문헌에서 확인한 보완책

구축 방식	장점	주요 위험	보완책(대표 사례)
전문가 작성	정답 정확성, 고난도 문항	높은 비용, 전문가 간 불일치	다단계 전문가 검토와 합의 기준 등급화(GPQA), 합의 기준별 일치도 보고(HealthBench)
실사용 로그	배포 분포 반영	저가치 문항 다수, 선별에 따른 분포 변화, 개인정보	군집화 후 품질 채점과 선별 기준 기록(BenchBuilder), 동의·비식별화(WildChat)
LLM 합성	저비용, 범위 확대	정답 오류, 생성·판정 모델의 자기 선호	왕복 일관성 필터와 사람 라벨 보정(ARES), 전문가 상황 지정(HealthBench)
적대적 수집	높은 변별력, 쉬운 단서 회피	정답 모호성·오류 증가	작성자와 독립된 검증자 다수결(ANLI), 반복 수집·검증(Dynabench)
RAG 추가 요건	검색·생성 오류의 분리 진단	판정 누락 문서, 근거 귀속 자동 판정의 중간 수준 일치도	판정 구멍 측정과 추가 판정(BEIR), 층화와 답 없는 질의 포함(CRAG, MultiHop-RAG)

네 방식의 위험은 서로 겹치지 않는다. 전문가 작성과 적대적 수집은 정확성이나 변별력을 얻는 대신 비용과 모호성을 지고, 로그와 합성은 현실성이나 규모를 얻는 대신 정답 검증을 뒤로 미룬다. 따라서 구축 출처만으로는 평가셋의 품질을 판단할 수 없으며, 어떤 출처에서 나온 평가셋이든 3장의 검증을 거쳐야 한다.

3. 검증: 서로를 보장하지 않는 다섯 층위

이 리뷰는 평가셋 검증을 구성 타당도, 라벨 신뢰도, 오류 감사, 통계적 충분성, 오염 통제의 다섯 층위로 정리하며, 각 층위는 4장 표 2의 조건 C1–C5에 대응한다. 층위를 나누는 이유는 한 층위의 통과가 다른 층위의 문제를 배제하지 못한 사례가 반복 보고되었기 때문이다. 여러 모델이 동의한 정답에서도 오류가 발견되었고[37], 사람과의 일치율이 높은 판정 모델도 점수 수준에서는 사람과 달랐으며[38], 전문가 검수를 거친 집합도 다른 실행 환경에서는 일부 문항이 재현되지 않았다[39].

3.1 구성 타당도

라벨이 정확하고 표본이 충분해도 평가셋이 의도한 능력을 측정하지 않으면 골든이라 할 수 없으므로, 측정 대상의 정의가 다른 모든 검증에 앞선다. LLM 벤치마크 445개를 검토한 연구에서 측정 대상을 정의한 벤치마크는 78.2%였으나 그 정의의 47.8%는 합의되지 않은 개념이었다[13]. BetterBench는 설계부터 폐기까지 46개 모범 사례를 제시하였고[12], 소수 벤치마크를 일반 능력의 대리 지표로 쓰는 관행은 구성 타당도의 문제로 비판받았다[40]. 애플리케이션 평가셋에서 측정 대상은 배포될 과제 자체이므로, 과제 정의와 층별 문항 구성이 이 층위의 증거가 된다.

3.2 라벨 신뢰도

주석자 간 일치도는 라벨이 개인의 판단을 넘어 재현되는지를 측정하며, 기준값 통과 여부와 함께 불일치 문항의 성격을 보고해야 해석할 수 있다. Krippendorff는 α 0.800 이상을 요구하고 잠정적 결론만 허용되는 경우 0.667 이상을 하한으로 제시하였다[41,42]. 다만 Artstein과 Poesio는 단일 기준값이 모든 목적에 맞는지 의문을 제기하였고, 범주 분포가 치우쳐 기대 일치율이 높으면 관측 일치율이 0.96이어도 κ가 0.65에 그치는 예를 보였다[43]. 평가 분할에 다수 주석을 두는 설계는 이 변이를 측정할 수 있게 하며, Natural Questions는 평가 분할 문항마다 다섯 명의 주석을 수집하였다[17]. 일치도가 낮은 원인이 잡음만은 아니다. 자연어 추론의 불일치는 주석자를 늘리거나 맥락을 바꾸어도 남았고[44], 이런 사람 라벨 변이를 제거할 잡음이 아니라 평가가 반영해야 할 신호로 보아야 한다는 주장이 제기되었다[45–47].

3.3 오류 감사

일치도가 높아도 모두가 같은 오류를 범할 수 있으므로, 정답 자체를 다시 감사하고 그 결과를 오류율의 하한으로 해석해야 한다. 플래티넘 벤치마크 연구는 여러 최신 LLM 중 하나라도 틀린 문항을 사람이 다시 검토하는 방식으로 15개 벤치마크를 수정하였고, GSM8K 전체에서는 219문항을 검토하여 110문항을 제거하고 10문항의 정답을 고쳤다[5,37]. 저자들은 모든 모델이 틀린 정답에 동의하는 문항은 이 절차로 찾을 수 없으므로 찾아낸 오류 수가 하한이라고 밝혔다[37]. 문항 반응 통계와 LLM 1차 선별로 이상 문항을 골라 전문가 검토를 유도한 연구는 벤치마크 9종에서 최대 84%의 정밀도로 문제 문항을 찾았다[48]. SWE-bench Verified는 전문 개발자 93명이 무작위 표본 1,699개를 검토하여 문제 설명이 불충분하거나 시험 코드가 올바른 해법을 거부하는 항목(68.3%)을 걸러낸 뒤, 남은 항목에서 500개를 선정하였다[49]. 코드 평가에서는 정답 판정 기준인 시험 코드도 감사 대상이다. HumanEval의 시험을 80배로 늘리자 pass@k가 최대 19.3–28.9% 떨어져, 기존 시험이 잘못된 코드를 통과시켰음이 드러났다[50]. 모델 불일치에 기반한 감사는 모든 모델이 공유하는 오류를 놓치므로 무작위 표본 감사와 함께 써야 한다.

3.4 통계적 충분성

평가셋의 크기는 구분하려는 성능 차이에 맞추어 정해야 한다. Card 등은 NLP 비교 실험의 상당수가 검정력이 부족하며, 문장 2,000개 규모의 기계번역 시험셋은 BLEU 1점 차이를 약 75%의 검정력으로만 탐지함을 보였다[51]. Miller는 평균의 표준오차와 쌍체 비교를 보고하고, 같은 문서에서 나온 문항처럼 묶인 문항에는 군집 표준오차를 쓰도록 권고하였다. DROP에서 군집 표준오차는 단순 표준오차의 약 3.05배였다. 또한 Miller는 분산을 가정한 예시 계산에서 유의수준 0.05와 검정력 80%로 3%p 차이를 탐지하려면 약 969개의 독립 문항이 필요하다고 보이고, 새 평가셋에 최소 1,000문항을 권고하였다[52]. 한편 문항 반응 이론으로 고른 과제별 100문항은 전체 점수를 평균 약 2% 오차로 추정하였으나 특이한 모델에서는 추정이 덜 정확하였다[53]. 소규모 부분집합은 상시 모니터링에는 쓸 수 있지만 작은 차이를 판정하는 근거로는 부족하다. 벤치마크 445개 중 불확실성 추정이나 통계 검정을 사용한 것이 16.0%에 그쳤다는 결과[13]는 이 층위가 실무에서 가장 자주 생략됨을 보여 준다.

3.5 오염 통제와 재현성

평가 문항이 학습 데이터에 들어가면 점수가 부풀고 잘못된 결론이 출판될 수 있다[9,54]. Oren 등은 문항 순서가 교환 가능한 벤치마크에서, 문항 순서를 섞었을 때보다 원래 순서의 우도가 유의하게 높은지를 보는 검정으로 학습 데이터나 모델 가중치에 접근하지 않고 오염을 탐지할 수 있음을 보였다[55]. BIG-bench는 웹 수집 데이터에서 걸러낼 수 있도록 모든 과제 파일에 카나리아 문자열을 넣었다[56]. GSM8K와 같은 분포로 새로 만든 GSM1k에서는 정확도가 최대 8% 떨어진 모델이 있었고, GSM8K 문항의 생성 확률이 높은 모델일수록 하락 폭이 컸다[57]. 이에 대응하여 LiveBench는 문항을 매월 갱신하고 LiveCodeBench는 공개 시점을 기록하여 모델 학습 시점 이후 문항만 평가할 수 있게 하였다[58,59]. 오염이 없어도 고정된 평가셋의 점수는 새 표본이나 새 실행 환경에서 재현되지 않을 수 있다. 같은 생성 절차로 만든 새 시험셋에서 ImageNet 분류기의 정확도는 11–14% 떨어졌고[60], SWE-bench Verified 500문항 중 16문항은 다른 기관의 실행 환경에서 안정적으로 실행되지 않아 제외되었다[39]. 따라서 비공개 보존 분할, 공개 시점 기록, 실행 환경 고정, 정기 재구축이 검증 절차에 포함되어야 한다[13,58,59].

3.6 골든셋을 이용한 판정 모델 메타평가

골든셋은 그 자체의 검증 대상일 뿐 아니라 LLM 판정 모델을 검증하는 기준으로도 쓰이며, 이때는 일치율 하나로 판정 모델을 승인할 수 없다. MT-Bench와 Chatbot Arena에서 GPT-4 판정의 사람 일치율은 80%를 넘었으나[61], 다른 연구에서는 가장 큰 판정 모델조차 사람이 매긴 점수와 정확도 척도에서 최대 5점까지 달랐고, 일치율이 높은 판정 모델도 10–20점 차이를 보였다[38]. 20개 과제에서 판정 모델의 사람 일치도는 평가 속성과 주석자 전문성에 따라 크게 달랐다[62]. 판정 모델은 골든셋에서 일치도와 점수 수준 차이를 함께 측정한 뒤에 쓰고, 불균형한 라벨에서는 정밀도와 재현율을 따로 보아야 한다[63].

4. 무엇을 골든이라 부를 수 있는가

정보검색의 시험 모음 전통에서 "골드 표준"은 절대적 정답을 뜻하지 않았다. TREC 계열 시험 모음에서 평가자마다 관련성 판정이 크게 달랐지만 시스템 순위는 판정 집합을 바꾸어도 높은 상관을 유지하였고, 이 순위 안정성이 시험 모음을 실험 도구로 쓰는 근거가 되었다[64]. 이후 CALBC는 여러 자동 태거의 합의로 만든 라벨을 은 표준(silver standard)으로 구분하였고[65], 최근 Vendrow

등은 라벨 오류와 모호성을 최소화하도록 재검수한 벤치마크를 플래티넘 벤치마크로 부를 것을 제안하였다[37]. Aroyo와 Welty는 단일 정답, 불일치는 나쁘다, 한 번 만들면 영원히 유효하다 등 사람 주석의 일곱 가지 신화를 비판하였다[46]. 이 리뷰는 이 흐름을 근거로, 골든을 데이터셋의 고정된 속성이 아니라 목적과 시점에 따라 달라지는 상태로 본다.

이 리뷰는 골든 데이터셋을 **명시된 평가 목적과 버전에 대해 표 2의 일곱 조건을 충족한다는 증거가 문서로 남은 평가셋**으로 정의할 것을 제안한다. 이 정의는 벤치마크 품질 기준[11–13], 주석 문헌[45,46], 문서화 문헌[66,67]을 저자가 종합한 것이며, 일곱 조건으로 나눈 구성은 어느 한 문헌이 제시한 것이 아니다. 예를 들어 Bowman과 Dahl은 타당성, 정확한 라벨, 충분한 검정력, 유해 시스템 억제의 네 가지 기준을 제시하였다[11]. 조건 C1–C5는 3장의 다섯 검증 층위(3.1–3.5)에 차례로 대응하고, C6과 C7은 그 증거를 남기고 갱신하는 절차이다. 2장의 구축 방식은 정의의 조건이 아니라 C1과 C3에서 점검할 위험의 출처이다. 문서화 항목은 Datasheets, Data Statements, Data Cards가 제시하였고[66–68], Croissant와 그 책임 있는 AI 확장은 기계 판독 형식을 제공하며[69,70], NeurIPS 2026 데이터셋 투고는 한계·편향·의도된 용도를 이 형식에 포함하도록 요구한다[71]. 유지 절차로는 데이터셋 폐기 틀[72]과 지속 갱신형 벤치마크[27,73]를 참고할 수 있다. 채점 기준도 유지 대상이다. Shankar 등의 사용자 연구에서 참여자는 출력을 채점하면서 채점 기준을 바꾸는 기준 표류(criteria drift)를 보였으므로[74], 채점 기준은 평가셋과 함께 버전 관리해야 한다.

표 2. 골든 데이터셋의 일곱 조건과 운영 점검 항목

조건	운영 점검	문헌의 근거·기준값	남길 증거
C1 구성 타당도	측정 대상 정의, 배포 과제·위험 영역 대비 층화 범위	정의한 벤치마크의 47.8%가 논쟁적 정의[13]; 층별 성능 차이[33]	과제 정의서, 층별 문항 수
C2 라벨 신뢰도	다중 주석, 우연 보정 일치도, 불일치 처리 규칙	α≥0.800, 잠정 결론은 α≥0.667[42]; 단일 기준값의 한계[43]	일치도, 판정·중재 기록, 비집계 라벨
C3 오류 감사	모델 불일치 문항 재검토와 무작위 표본 감사	시험셋 10종 평균 오류율 ≥3.3%[3]; 감사 결과는 하한[37]	수정·제거 목록, 오류율 추정
C4 통계적 충분성	최소 탐지 차이 기준 표본 크기, 군집·쌍체 신뢰구간	가정한 예시에서 3%p 탐지(유의수준 0.05, 검정력 80%)에 약 1,000문항[52]	검정력 계산, 신뢰구간
C5 오염 통제	비공개 분할, 공개 시점 기록, 카나리아, 오염 검정, 실행 환경 고정	GSM1k에서 GSM8K 대비 최대 8% 하락[57]; 순서 검정[55]	분할 정책, 오염 검사 결과
C6 문서화	구축 출처·선별 기준·절차·주석자·라이선스·한계 기록	데이터시트·데이터 카드[66,67]; Croissant-RAI[70]	데이터 카드, 기계 판독 메타데이터
C7 유지·버전	정오표, 재감사 주기, 채점 기준 동시 버전 관리, 폐기 기준	한 번 만들면 영원히 유효하다는 신화[46]; 기준 표류[74]	버전 이력, 변경 기록

이 정의를 실무에 적용하는 방안으로, 이 리뷰는 감사를 거친 골든 핵심셋과 합성·로그 기반의 은 표준 보조셋을 함께 두는 2단 구성을 제안한다. 핵심셋은 표 2의 조건을 모두 갖추고 보조셋의 자동 채점기와 LLM 판정 모델을 보정하는 기준으로 쓰며, 보조셋은 규모를 살려 회귀 탐지와 범위 확대를 맡는다. 이 구성은 사람 라벨 150–300개로 판정 모델을 보정한 ARES의 설계[22]와 LLM 판정을 사람 라벨과 대조하라는 실무 지침[63]을 평가셋 구성으로 넓힌 것이다. 다만 판정 모델 보정에 충분한 핵심셋의 크기와 모델 간 작은 차이를 판정하는 데 필요한 크기는 다르다. 핵심셋을 모델 선택에도 쓰려면 C4에 따라 탐지할 차이에 맞는 문항 수를 확보해야 하며, 3%p 수준의 차이라면 약 1,000문항이 필요하다[52].

5. 논의

5.1 쟁점

첫째 쟁점은 규모와 품질의 관계이다. Anthropic 문서는 사람이 정밀 채점한 소수 문항보다 신호가 다소 약한 자동 채점 문항을 많이 두는 편이 낫다고 권고하였으나[2], 벤치마크 연구는 철저히 검증된 정확하고 모호하지 않은 문항을 요구하였다[11,37]. 이 리뷰는 두 입장이 서로 다른 용도를 겨냥한다고 본다. 대규모 자동 채점셋은 회귀 탐지에, 감사된 핵심셋은 판정 모델 보정과 정답 기준 확인에 적합하며, 4장의 2단 구성은 두 입장을 용도에 따라 결합한 것이다.

둘째 쟁점은 단일 정답과 관점주의의 대립이다. 주관적 판단이 들어가는 응답 품질 평가에서는 다수결 라벨 하나보다 라벨 분포를 보존하는 편이 타당하다는 주장이 있으나[45,47], 회귀 검사에는 실행마다 같은 판정을 내는 고정된 기준이 필요하다. 이 리뷰는 문항 유형별로 정답형과 분포형을 구분하여 기록하고, 분포형 문항은 비집계 라벨을 함께 보존하는 방식을 절충안으로 제안한다.

셋째 쟁점은 사람 라벨을 LLM 라벨로 대체하는 문제이다. Bing 검색 관련성 판정에서는 LLM 판정이 실제 검색자 기준으로 제3자 작업자보다 정확하였다는 보고가 있다[30]. 그러나 LLM 판정 모델의 자기 선호가 보고되었고[23] LLM으로 만든 시험 모음이 LLM 기반 검색기에 유리할 위험도 제기되었다[24]. 따라서 이 리뷰는 LLM 라벨을 사람 라벨로 보정된 은 표준 라벨로 취급하고, 골든 핵심셋의 정답은 사람이 확정할 것을 제안한다.

5.2 연구 공백과 향후 과제

이 리뷰가 확인한 문헌에는 세 가지 공백이 남아 있다. 첫째, 평가셋의 라벨 오류가 실제 애플리케이션의 배포 결정을 얼마나 바꾸는지 정량화한 연구는 이 리뷰가 찾은 범위에서 공개 벤치마크의 순위 역전과 성능 차이 은폐 사례[3,5]를 넘어서지 못하였다. 사내 평가셋에 오류를 의도적으로 주입하고 모델 선택 결과가 바뀌는 오류율을 측정하는 연구가 필요하다. 둘째, RAG 지식 베이스의 문서가 갱신될 때 정답과 근거 라벨을 함께 갱신하는 절차는 확인하지 못하였다. CRAG의 시간 변동성 층화[33]와 LiveBench의 월간 갱신[58]은 질의 수준의 변화를 다루지만, 문서 버전과 정답 버전을 연결하는 관리 방법은 별도로 설계되어야 한다. 셋째, 이 리뷰가 인용한 근거는 대부분 영어 벤치마크에서 나왔으므로, 한국어 등 다른 언어의 애플리케이션 평가셋에서 일치도 기준값과 필요한 문항 수가 같은지 재검증해야 한다. 아울러 이 리뷰의 일곱 조건과 2단 구성은 문헌의 종합에서 도출한 제안이므로, 조건별 충족 여부가 실제 평가 결론의 안정성과 어떤 관계인지 실증해야 한다.

5.3 이 리뷰의 한계

이 리뷰는 서술형 종합이므로 누락된 문헌이 있을 수 있다. 문헌 검색과 요약에는 LLM 에이전트를 활용하였으며, 원문 접근이 막힌

일부 출처는 웹 아카이브 사본으로 확인하였다. 회색 문헌은 실무 관행을 보여 주는 근거로만 사용하였으나, 해당 문서는 개정되거나 폐기될 수 있다.

6. 결론

이 리뷰는 LLM·RAG 애플리케이션 평가셋의 구축과 검증 문헌을 종합하여 세 질문에 답하였다. 첫째, 전문가 작성, 실사용 로그, LLM 합성, 적대적 수집은 각기 다른 위험을 지며 어느 방식도 정확성, 현실성, 비용을 함께 만족하지 못하였고, RAG 평가셋은 관련성 판정의 불완전성이라는 위험을 더 진다. 둘째, 검증의 다섯 층위는 서로를 보장하지 않았으며, 특히 통계적 충분성은 공개 벤치마크에서도 드물게 점검되었다. 셋째, 골든이라는 이름은 데이터셋을 만든 방식이 아니라 명시된 목적과 버전에 대한 검증 증거에 붙어야 한다. 이 리뷰가 제안한 일곱 조건은 실무 평가셋을 감사하는 점검표로, 2단 구성은 평가셋을 짜는 설계 지침으로 쓸 수 있다. 다만 핵심셋으로 모델 간 작은 차이를 판정하려면 검정력에 맞는 규모가 필요하고, LLM 라벨은 사람 라벨로 보정해야 하며, 제안의 유효성은 영어 이외의 평가셋과 실제 배포 결정에서 검증되어야 한다.

생성형 AI 사용 고지

저자는 문헌 검색, 출처 확인, 초안 작성과 퇴고에 Anthropic Claude(Claude Code, claude-opus-5-5)를 사용하였다. 본문의 수치는 Claude 에이전트가 인용 문헌의 원문, 초록 또는 웹 아카이브 사본과 대조하였고 저자가 그 기록을 검토하였다. 최종 내용의 책임은 저자에게 있다.

참고문헌

1. OpenAI. Evals (API documentation). 2026. https://developers.openai.com/api/docs/guides/evals (accessed 2026-10-25).
2. Anthropic. Create strong empirical evaluations (Claude documentation). 2026. https://platform.claude.com/docs/en/docs/test-and-evaluate/develop-tests (accessed 2026-10-25).
3. Northcutt CG, Athalye A, Mueller J. Pervasive label errors in test sets destabilize machine learning benchmarks. In: NeurIPS Datasets and Benchmarks Track; 2021. arXiv:2103.14749.
4. Gema AP, Leang JOJ, Hong G, et al. Are we done with MMLU? In: Proc NAACL; 2025. p. 5069–96. doi:10.18653/v1/2025.naacl-long.262. arXiv:2406.04127.
5. Vendrow E, Vendrow J, Madry A, Beery S. GSM8K-Platinum: revealing performance gaps in frontier LLMs [blog]. 2025 Mar 6. https://gradientscience.org/gsm8k-platinum/ (accessed 2026-10-25).
6. Chang Y, Wang X, Wang J, et al. A survey on evaluation of large language models. ACM Trans Intell Syst Technol. 2024;15(3):1–45. doi:10.1145/3641289. arXiv:2307.03109.
7. Yu H, Gan A, Zhang K, Tong S, Liu Q, Liu Z. Evaluation of retrieval-augmented generation: a survey. arXiv:2405.07437. 2024.
8. Gan A, Yu H, Zhang K, et al. Retrieval augmented generation evaluation in the era of large language models: a comprehensive survey. arXiv:2504.14891. 2025.
9. Xu C, Guan S, Greene D, Kechadi MT. Benchmark data contamination of large language models: a survey. arXiv:2406.04244. 2024.
10. Chen S, Chen Y, Li Z, et al. Benchmarking large language models under data contamination: a survey from static to dynamic evaluation. In: Proc EMNLP; 2025. p. 10091–109. doi:10.18653/v1/2025.emnlp-main.511. arXiv:2502.17521.
11. Bowman SR, Dahl GE. What will it take to fix benchmarking in natural language understanding? In: Proc NAACL; 2021. p. 4843–55. doi:10.18653/v1/2021.naacl-main.385.
12. Reuel A, Hardy A, Smith C, Lamparth M, Hardy M, Kochenderfer MJ. BetterBench: assessing AI benchmarks, uncovering issues, and establishing best practices. In: NeurIPS Datasets and Benchmarks Track; 2024. arXiv:2411.12990.
13. Bean AM, Kearns RO, Romanou A, et al. Measuring what matters: construct validity in large language model benchmarks. In: NeurIPS Datasets and Benchmarks Track; 2025. arXiv:2511.04703.
14. Rein D, Hou BL, Stickland AC, et al. GPQA: a graduate-level Google-proof Q&A benchmark. In: Proc COLM; 2024. arXiv:2311.12022.
15. Arora RK, Wei J, Soskin Hicks R, et al. HealthBench: evaluating large language models towards improved human health. arXiv:2505.08775. 2025.
16. Bajaj P, Campos D, Craswell N, et al. MS MARCO: a human generated machine reading comprehension dataset. arXiv:1611.09268. 2016.
17. Kwiatkowski T, Palomaki J, Redfield O, et al. Natural Questions: a benchmark for question answering research. Trans Assoc Comput Linguist. 2019;7:453–66. doi:10.1162/tacl_a_00276.
18. Li T, Chiang WL, Frick E, et al. From crowdsourced data to high-quality benchmarks: Arena-Hard and BenchBuilder pipeline. In: Proc ICML; 2025. arXiv:2406.11939.
19. Zhao W, Ren X, Hessel J, Cardie C, Choi Y, Deng Y. WildChat: 1M ChatGPT interaction logs in the wild. In: Proc ICLR; 2024. arXiv:2405.01470.
20. Wang Y, Kordi Y, Mishra S, et al. Self-Instruct: aligning language models with self-generated instructions. In: Proc ACL; 2023. p. 13484–508. doi:10.18653/v1/2023.acl-long.754. arXiv:2212.10560.
21. Ragas. Testset generation for RAG (documentation). 2026. https://docs.ragas.io/en/stable/concepts/test_data_generation/rag/ (accessed 2026-10-25).
22. Saad-Falcon J, Khattab O, Potts C, Zaharia M. ARES: an automated evaluation framework for retrieval-augmented generation systems. In: Proc NAACL; 2024. p. 338–54. doi:10.18653/v1/2024.naacl-long.20. arXiv:2311.09476.
23. Panickssery A, Bowman SR, Feng S. LLM evaluators recognize and favor their own generations. In: Proc NeurIPS; 2024. arXiv:2404.13076.
24. Rahmani HA, Craswell N, Yilmaz E, Mitra B, Campos D. Synthetic test collections for retrieval evaluation. In: Proc SIGIR; 2024. p. 2647–51. doi:10.1145/3626772.3657942. arXiv:2405.07767.
25. Gururangan S, Swayamdipta S, Levy O, Schwartz R, Bowman SR, Smith NA. Annotation artifacts in natural language inference data. In: Proc NAACL; 2018. p. 107–12. doi:10.18653/v1/N18-2017. arXiv:1803.02324.
26. Nie Y, Williams A, Dinan E, Bansal M, Weston J, Kiela D. Adversarial NLI: a new benchmark for natural language understanding. In: Proc ACL; 2020. p. 4885–901. doi:10.18653/v1/2020.acl-main.441. arXiv:1910.14599.
27. Kiela D, Bartolo M, Nie Y, et al. Dynabench: rethinking benchmarking in NLP. In: Proc NAACL; 2021. p. 4110–24. doi:10.18653/v1/2021.naacl-main.324.
28. Buckley C, Dimmick D, Soboroff I, Voorhees E. Bias and the limits of pooling for large collections. Inf Retr. 2007;10(6):491–508. doi:10.1007/s10791-007-9032-x.
29. Thakur N, Reimers N, Rücklé A, Srivastava A, Gurevych I. BEIR: a heterogenous benchmark for zero-shot evaluation of information retrieval models. In: NeurIPS Datasets and Benchmarks Track; 2021. arXiv:2104.08663.
30. Thomas P, Spielman S, Craswell N, Mitra B. Large language models can accurately predict searcher preferences. In: Proc SIGIR; 2024. p. 1930–40. doi:10.1145/3626772.3657707. arXiv:2309.10621.
31. Upadhyay S, Pradeep R, Thakur N, Craswell N, Lin J. UMBRELA: UMbrela is the (open-source reproduction of the) Bing RELevance Assessor. arXiv:2406.06519. 2024.
32. Gao T, Yen H, Yu J, Chen D. Enabling large language models to generate text with citations. In: Proc EMNLP; 2023. p. 6465–88. doi:10.18653/v1/2023.emnlp-main.398. arXiv:2305.14627.
33. Yang X, Sun K, Xin H, et al. CRAG – comprehensive RAG benchmark. In: NeurIPS Datasets and Benchmarks Track; 2024. arXiv:2406.04744.
34. Tang Y, Yang Y. MultiHop-RAG: benchmarking retrieval-augmented generation for multi-hop queries. In: Proc COLM; 2024. arXiv:2401.15391.
35. Chen J, Lin H, Han X, Sun L. Benchmarking large language models in retrieval-augmented generation. In: Proc AAAI; 2024;38(16):17754–62. doi:10.1609/aaai.v38i16.29728. arXiv:2309.01431.
36. Ribeiro MT, Wu T, Guestrin C, Singh S. Beyond accuracy: behavioral testing of NLP models with CheckList. In: Proc ACL; 2020. p. 4902–12. doi:10.18653/v1/2020.acl-main.442. arXiv:2005.04118.
37. Vendrow J, Vendrow E, Beery S, Madry A. Do large language model benchmarks test reliability? arXiv:2502.03461. 2025.
38. Thakur AS, Choudhary K, Ramayapally VS, Vaidyanathan S, Hupkes D. Judging the judges: evaluating alignment and vulnerabilities in LLMs-as-judges. In: Proc GEM² Workshop at ACL; 2025. p. 404–30. arXiv:2406.12624.
39. Epoch AI. SWE-bench Verified [benchmark page]. https://epoch.ai/benchmarks/swe-bench-verified (accessed 2026-10-25).
40. Raji ID, Bender EM, Paullada A, Denton E, Hanna A. AI and the everything in the whole wide world benchmark. In: NeurIPS Datasets and Benchmarks Track; 2021. arXiv:2111.15366.
41. Krippendorff K. Content analysis: an introduction to its methodology. 2nd ed. Thousand Oaks (CA): Sage; 2004.

42. Krippendorff K. Reliability in content analysis: some common misconceptions and recommendations. Hum Commun Res. 2004;30(3):411–33. doi:10.1111/j.1468-2958.2004.tb00738.x.
43. Artstein R, Poesio M. Inter-coder agreement for computational linguistics. Comput Linguist. 2008;34(4):555–96. doi:10.1162/coli.07-034-R2.
44. Pavlick E, Kwiatkowski T. Inherent disagreements in human textual inferences. Trans Assoc Comput Linguist. 2019;7:677–94. doi:10.1162/tacl_a_00293.
45. Plank B. The "problem" of human label variation: on ground truth in data, modeling and evaluation. In: Proc EMNLP; 2022. p. 10671–82. doi:10.18653/v1/2022.emnlp-main.731.
46. Aroyo L, Welty C. Truth is a lie: crowd truth and the seven myths of human annotation. AI Mag. 2015;36(1):15–24. doi:10.1609/aimag.v36i1.2564.
47. Cabitza F, Campagner A, Basile V. Toward a perspectivist turn in ground truthing for predictive computing. In: Proc AAAI; 2023;37(6):6860–8. doi:10.1609/aaai.v37i6.25840.
48. Truong S, Tu Y, Hardy M, et al. Fantastic bugs and where to find them in AI benchmarks. In: NeurIPS Datasets and Benchmarks Track; 2025. arXiv:2511.16842.
49. OpenAI. Introducing SWE-bench Verified [blog]. 2024 Aug 13. https://openai.com/index/introducing-swe-bench-verified/ (archived: https://web.archive.org/web/20240909063313/https://openai.com/index/introducing-swe-bench-verified/; accessed 2026-10-25).
50. Liu J, Xia CS, Wang Y, Zhang L. Is your code generated by ChatGPT really correct? Rigorous evaluation of large language models for code generation. In: Proc NeurIPS; 2023. arXiv:2305.01210.
51. Card D, Henderson P, Khandelwal U, Jia R, Mahowald K, Jurafsky D. With little power comes great responsibility. In: Proc EMNLP; 2020. p. 9263–74. doi:10.18653/v1/2020.emnlp-main.745. arXiv:2010.06595.
52. Miller E. Adding error bars to evals: a statistical approach to language model evaluations. arXiv:2411.00640. 2024.
53. Maia Polo F, Weber L, Choshen L, Sun Y, Xu G, Yurochkin M. tinyBenchmarks: evaluating LLMs with fewer examples. In: Proc ICML; 2024. arXiv:2402.14992.
54. Sainz O, Campos JA, García-Ferrero I, Etxaniz J, Lopez de Lacalle O, Agirre E. NLP evaluation in trouble: on the need to measure LLM data contamination for each benchmark. In: Findings of EMNLP; 2023. p. 10776–87. doi:10.18653/v1/2023.findings-emnlp.722.
55. Oren Y, Meister N, Chatterji N, Ladhak F, Hashimoto TB. Proving test set contamination in black-box language models. In: Proc ICLR; 2024. arXiv:2310.17623.
56. Srivastava A, Rastogi A, Rao A, et al. Beyond the imitation game: quantifying and extrapolating the capabilities of language models. Trans Mach Learn Res. 2023. arXiv:2206.04615.
57. Zhang H, Da J, Lee D, et al. A careful examination of large language model performance on grade school arithmetic. In: NeurIPS Datasets and Benchmarks Track; 2024. arXiv:2405.00332.
58. White C, Dooley S, Roberts M, et al. LiveBench: a challenging, contamination-limited LLM benchmark. In: Proc ICLR; 2025. arXiv:2406.19314.
59. Jain N, Han K, Gu A, et al. LiveCodeBench: holistic and contamination free evaluation of large language models for code. In: Proc ICLR; 2025. arXiv:2403.07974.
60. Recht B, Roelofs R, Schmidt L, Shankar V. Do ImageNet classifiers generalize to ImageNet? In: Proc ICML (PMLR 97); 2019. arXiv:1902.10811.
61. Zheng L, Chiang WL, Sheng Y, et al. Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. In: NeurIPS Datasets and Benchmarks Track; 2023. arXiv:2306.05685.
62. Bavaresco A, Bernardi R, Bertolazzi L, et al. LLMs instead of human judges? A large scale empirical study across 20 NLP evaluation tasks. In: Proc ACL (Short Papers); 2025. p. 238–55. doi:10.18653/v1/2025.acl-short.20. arXiv:2406.18403.
63. Husain H. Your AI product needs evals [blog]. 2024 Mar 29. https://hamel.dev/blog/posts/evals/ (accessed 2026-10-25).
64. Voorhees EM. Variations in relevance judgments and the measurement of retrieval effectiveness. Inf Process Manag. 2000;36(5):697–716. doi:10.1016/S0306-4573(00)00010-8.
65. Rebholz-Schuhmann D, Jimeno Yepes AJ, van Mulligen EM, et al. CALBC silver standard corpus. J Bioinform Comput Biol. 2010;8(1):163–79. doi:10.1142/S0219720010004562.
66. Gebru T, Morgenstern J, Vecchione B, et al. Datasheets for datasets. Commun ACM. 2021;64(12):86–92. doi:10.1145/3458723. arXiv:1803.09010.
67. Pushkarna M, Zaldivar A, Kjartansson O. Data cards: purposeful and transparent dataset documentation for responsible AI. In: Proc ACM FAccT; 2022. p. 1776–826. doi:10.1145/3531146.3533231. arXiv:2204.01075.
68. Bender EM, Friedman B. Data statements for natural language processing: toward mitigating system bias and enabling better science. Trans Assoc Comput Linguist. 2018;6:587–604. doi:10.1162/tacl_a_00041.
69. Akhtar M, Benjelloun O, Conforti C, et al. Croissant: a metadata format for ML-ready datasets. In: NeurIPS Datasets and Benchmarks Track; 2024. arXiv:2403.19546.
70. Jain N, Akhtar M, Giner-Miguelez J, et al. A standardized machine-readable dataset documentation format for responsible AI. arXiv:2407.16883. 2024.
71. NeurIPS. Responsible AI metadata requirements for the Evaluations and Datasets Track, NeurIPS 2026 [blog]. 2026 May 4. https://blog.neurips.cc/2026/05/04/responsible-ai-metadata-requirements-for-the-evaluations-and-datasets-track-neurips-2026/ (accessed 2026-10-25).
72. Luccioni AS, Corry F, Sridharan H, Ananny M, Schultz J, Crawford K. A framework for deprecating datasets: standardizing documentation, identification, and communication. In: Proc ACM FAccT; 2022. p. 199–212. doi:10.1145/3531146.3533086. arXiv:2111.04424.
73. Liang P, Bommasani R, Lee T, et al. Holistic evaluation of language models. Trans Mach Learn Res. 2023. arXiv:2211.09110.
74. Shankar S, Zamfirescu-Pereira JD, Hartmann B, Parameswaran AG, Arawjo I. Who validates the validators? Aligning LLM-assisted evaluation of LLM outputs with human preferences. In: Proc ACM UIST; 2024. p. 1–14. doi:10.1145/3654777.3676450. arXiv:2404.12272.