골든셋의 라벨 오류는 모델 선택 결정을 얼마나 바꾸는가: MMLU-Redux 자연 실험과 통제된 오류 주입

Anonymous ACL submission

초록

모델 교체나 배포 결정은 흔히 골든셋에서 측정한 두 모델의 점수 차이에 근거한다. 골든셋에 라벨 오류가 흔하다는 보고는 많지만, 이 오류가 모델 쌍의 비교 결정을 얼마나, 어느 방향으로 바꾸는지는 정량화되지 않았다. 본 연구는 공개 모델 42종의 MMLU 문항별 예측과 MMLU-Redux 2.0의 전문가 수정 정답을 이용하여 두 실험을 수행하였다. 자연 실험에서는 원래 정답을 수정 정답으로 바꿀 때 모델 쌍의 결정이 바뀌는 비율을 측정하였고, 주입 실험에서는 오류를 넣을 문항과 잘못된 라벨의 종류를 통제하였다. 전체 셋에서는 라벨 수정으로 바뀐 결정이 드물었으나, 과목 단위의 작은 셋에서는 수정 문항이 많은 과목일수록 반전이 많았고 바이러스학 과목에서는 결정의 36%가 바뀌었다. 우세 방향이 뒤집힌 경우는 없었으며, 라벨 오류는 모델 간 격차를 줄여 결정을 보류로 바꾸었다. 무작위 라벨 오류의 영향은 같은 수의 문항을 교체할 때와 비슷하였다. 반면 어려운 문항을 모델들이 가장 많이 고르는 오답으로 잘못 표시하는 체계적 오류는 무작위 오류보다 결정을 1.4–1.6배 많이 바꾸었고, 실제 오류도 이 방향으로 치우쳐 있었다. 골든셋의 허용 오류율은 체계적 오류를 가정하여 정하고, 작은 셋과 오류가 몰린 하위 집합은 따로 감사할 필요가 있다.

Abstract

Model replacement and deployment decisions often rest on the score difference between two models on a golden evaluation set. Label errors in such sets are common, yet how much they change pairwise model-selection decisions, and in which direction, has not been quantified. Using per-item MMLU predictions from 42 open models and the expert corrections of MMLU-Redux 2.0, we run a natural experiment that replaces the original labels with the corrected ones and an injection experiment that controls which items are corrupted and which wrong label they receive. On the full set, correcting labels rarely changed a decision. On small subject-level sets, flips grew with the share of corrected items and reached 36% of decisions in virology. No decision reversed the winner. Instead, label errors compressed the gaps between models and turned decisions into inconclusive ones. Random label errors changed about as many decisions as replacing the same number of items. Systematic errors, which label hard items with the distractor most models choose, changed 1.4–1.6 times as many decisions as random errors, and real errors leaned in this direction. Error tolerances for golden sets should therefore assume systematic errors, and small sets and error-dense subsets need their own audits.

1 서론

LLM 애플리케이션을 운영하는 팀은 새 모델이나 프롬프트의 도입 여부를 정할 때 고정된 평가 데이터셋, 즉 골든셋에서 후보와 현재 모델의 점수를 비교한다. 이때의 결정은 대개 "후보 B가 현재 모델 A보다 δ 이상 낫다"는 쌍 비교의 형태를 띤다. 골든셋의 정답 라벨이 틀리면 이 비교의 근거도 함께 흔들린다.

공개 평가셋의 라벨 오류는 드물지 않다. 널리 쓰이는 시험셋 10종에서는 평균 3.3% 이상의 라벨 오류가 발견되었고, 수정한 라벨로 평가하면 모델 순위가 바뀔 수 있었다(Northcutt et al., 2021). MMLU(Hendrycks et al., 2021)는 문항의 약 6.5%에 오류가 있는 것으로 추정되었으며(Gema et al., 2025), 라벨 오류와 모호한 문항을 걷어 낸 벤치마크에서도 최신 모델이 단순한 문항에서 여전히 실패하였다(Vendrow et al., 2025).

평가 결론의 불확실성에 관한 연구는 주로 표본 변동과 검정력을 다루었다(Card et al., 2020; Madaan et al., 2024). 라벨 오류의 양과 종류가 쌍 비교 결정을 얼마나, 어느 방향으로 바꾸는지를 표본 변동과 분리하여 측정한 연구는 찾기 어렵다. 골든셋의 구축과 검증을 다룬 선행 리뷰(Anonymous, 2026)도 이를 연구 공백으로 꼽았다. 이 리뷰는 맹검 감사의 통과 기준으로 "오류율의 95% Wilson 상한이 $\delta/4$ 이하"를 제안하였으나, 이 기준을 뒷받침하는 실증 결과는 없었다.

본 연구는 두 실험으로 이 공백을 다룬다. 첫째는 MMLU-Redux 2.0의 전문가 재주석을 이용한 자연

실험이다. 공개 모델 42종의 문항별 예측에 원래 정답과 수정 정답을 각각 적용하여 두 조건의 쌍 비교 결정을 비교한다. 둘째는 오류 주입 실험이다. 오류를 넣을 문항과 잘못된 라벨의 종류를 따로 바꾸어 오류 메커니즘의 효과를 분리하고, 라벨은 그대로 두고 문항만 바꾸는 기준선과 비교한다. 연구 질문은 다음 네 가지이다.

RQ1. 실제 라벨 오류를 수정하면 쌍 비교 결정은 얼마나 바뀌는가?

RQ2. 실제 라벨 오류는 무작위로 생기는가, 아니면 모델들이 고르는 오답 쪽으로 치우치는가?

RQ3. 결정 반전은 오류율, 오류 메커니즘, 셋 크기에 따라 어떻게 달라지며, 라벨 오류 없이 문항만 바꾼 경우와 비교하면 어떠한가?

RQ4. $\delta/4$ 감사 기준은 어느 정도의 오류율을 걸러내며, 그 경계의 오류율에서 결정은 얼마나 안정적인가?

주요 결과는 세 가지이다. 첫째, 라벨 오류는 어느 조건에서도 우세 방향을 뒤집지 않았고, 모델 간 격차를 줄여 결정을 보류로 바꾸었다. 둘째, 무작위 라벨 오류의 영향은 같은 수의 문항을 교체할 때와 비슷하였다. 어려운 문항에 모델들이 가장 많이 고른 오답(이하 대표 오답)을 표시하는 체계적 오류는 무작위 오류보다 결정을 1.4–1.6배 많이 바꾸었고, 실제 오류도 대표 오답 쪽으로 치우쳐 있었다. 셋째, 선행 리뷰의 감사 기준이 허용하는 경계 오류율(0.75%)에서도 870문항 셋의 결정 반전율은 1% 안팎이었다.

2 관련 연구

평가셋의 라벨 오류. Northcutt et al. (2021)의 연구는 confident learning으로 오류 후보를 찾고 크라우드소싱으로 확인하여 시험셋 10종의 라벨 오류를 추정하였다. MMLU-Redux(Gema et al., 2025)는 MMLU 문항을 전문가가 다시 주석하고, 오류를 정답 오류, 질문 불명확, 복수 정답 등의 유형으로 나누었다. Vendrow et al. (2025)의 연구는 여러 벤치마크에서 라벨 오류와 모호한 문항을 제거한 판을 만들어 모델의 신뢰성을 다시 평가하였다. 이 연구들은 오류의 빈도와 순위 변화를 보고하였으나, 실무에서 쓰는 쌍 비교 결정이 얼마나 바뀌는지는 측정하지 않았다.

평가 결론의 통계적 불확실성. Card et al. (2020)의 연구는 NLP 실험의 상당수가 작은 차이를 검출하기에 검정력이 부족함을 보였고, Madaan et al. (2024)의 연구는 학습 시드에 따른 벤치마크 점수의 분산을 측정하였다. 이 연구들이 다룬 불확실성은 표본과 학습 과정의 변동에서 온다. 본 연구는 같은 표본 안에서 라벨만 바꾸어, 라벨 오류의 효과를 표본 변동과 분리하여 측정한다.

3 데이터와 방법

3.1 데이터

MMLU-Redux 2.0(Gema et al., 2025)은 MMLU의 57과목에서 과목마다 100문항을 다시 주석한 자료이며, 문항마다 오류 유형과 정답 오류인 경우의 수정 정답을 제공한다. 모델 예측은 Open LLM Leaderboard v1(Beeching et al., 2023)이 공개한 MMLU 5-shot 문항별 결과에서 가져왔다. 리더보드는 lm-evaluation-harness(Gao et al., 2023)로 네 선택지의 로그확률을 계산하며, 본 연구는 로그확률이 가장 큰 선택지를 모델의 예측으로 삼았다. 두 자료는 과목명과 프롬프트 문자열을 키로 결합하였다(부록 B). 5,700문항 중 5,690문항이 결합되었고, 리더보드에 정답이 기록된 문항에서 리더보드의 정답과 Redux의 원래 정답은 모두 일치하였다.

모델은 MMLU 문항별 결과가 공개된 2023–2024년의 공개 모델 42종이다(부록 A). 후보 48종 가운데 6종은 문항별 결과를 얻지 못해 제외하였다. 3종은 추정한 이름의 리더보드 저장소가 없었으며, 이 중 OLMo는 실제 저장소 이름을 확인하여 두 모델(OLMo-7B-hf, OLMo-1.7-7B-hf)로 대체하였다. 나머지 3종인 Llama-2 chat 모델은 리더보드가 MMLU 문항별 결과를 공개하지 않았다.

3.2 라벨 조건

Redux 주석에 따라 문항을 세 범주로 나누었다. 오류가 없는 문항(5,321문항), 정답 오류로 표시되고 원래 정답과 다른 수정 정답이 명시된 수정 가능 문항(100문항), 그리고 그 밖의 오류가 있는 미해결 문항(269문항)이다. 미해결 문항에는 질문이 불명확하거나 정답이 여럿이어서 정답 하나로 고칠 수 없는 문항이 포함된다.

오류가 없는 문항과 수정 가능 문항을 합친 5,421문항을 분석 집합 S라 하고, S의 수정 정답을 기준 라벨로 삼았다. 관측 라벨은 두 가지이다. 첫째는 S의 원래 정답으로, 기준 라벨과의 차이는 라벨 오류의 효과만 반영한다. 둘째는 결합된 5,690문항 전체의 원래 정답으로, 리더보드의 공개 점수와 같은 조건이다. 이 조건에는 라벨 오류의 효과와 미해결 문항이 포함된 효과가 함께 들어 있다. 과목별 수정 문항 비율은 그 과목의 S 문항 중 수정 가능 문항이 차지하는 비율로 정의하였으며, Redux가 보고한 과목별 오류율과는 다르다.

3.3 결정 규칙과 결정 반전

모델 쌍 (A, B)마다 같은 문항에서의 정확도 차이 $d = \mathrm{acc}_B - \mathrm{acc}_A$와 그 95% 신뢰구간 $[L, U]$를 계산하였다. 신뢰구간은 문항별 정답 여부의 쌍체 분

조건	문항 선택	변경 내용
무작위 오류	균일	무작위 오답 라벨
대표 오답 오류	균일	대표 오답 라벨
어려운 문항 오류	오답률 비례	무작위 오답 라벨
체계적 오류	오답률 비례	대표 오답 라벨
문항 교체 기준선	균일	표본 밖 문항으로 교체
문항 제거 기준선	균일	문항 제거

표 1: 오류 주입 조건. 모든 조건은 k개 문항을 바꾼다. 오답률과 대표 오답은 평가 대상이 아닌 다른 모델 집단에서 계산한다.

조건	기준 우세	반전	상실	허위	역전
전체 셋, *861*쌍					
S의 원래 정답	735	8	2	6	0
공개 점수	735	10	5	5	0
McNemar–Holm	735	8	2	6	0
과목 단위 셋, *57*과목, *49,077*쌍					
S의 원래 정답	26,851	1,086	764	322	0
McNemar–Holm	–	447	–	–	0

표 2: 라벨 수정 전후의 결정 반전(δ = 3%p). 기준 우세는 수정 라벨에서 우세로 판정된 쌍의 수이다. McNemar–Holm 행은 정규근사 대신 정확 McNemar 검정과 Holm 보정을 쓴 결과이며, 과목 단위에서는 반전과 역전만 집계하였다(–).

산을 이용한 정규근사로 구하였다. 결정 여유 δ에 대해, $d \geq \delta$이고 $L > 0$인 쌍은 B 우세, $d \leq -\delta$이고 $U < 0$인 쌍은 A 우세로 판정하고, 나머지 쌍은 보류로 판정하였다. δ로는 0, 1, 2, 3, 5%p를 사용하였고, 본문에는 선행 리뷰의 예시와 같은 3%p의 결과를 주로 보고한다. 민감도 분석으로, 신뢰구간 대신 정확 McNemar 검정(McNemar, 1947)의 p값에 861쌍 전체에 대한 Holm 보정(Holm, 1979)을 적용한 규칙도 계산하였다.

기준 라벨과 관측 라벨에서 판정이 다르면 결정이 반전되었다고 한다. 반전은 세 가지로 나눈다. 기준에서 우세였던 쌍이 보류가 되는 결정 상실, 보류였던 쌍이 우세가 되는 허위 결정, 우세 방향이 뒤바뀌는 역전이다. 반전율은 반전된 쌍의 수를 전체 쌍의 수로 나눈 값이다.

3.4 오류 주입

S에서 n문항(n = 100, 300, 870, 5,421)을 비복원 추출해 골든셋을 만들고, 기준 라벨로 내린 판정과 오류를 넣은 라벨로 내린 판정을 비교하였다. 오류 문항 수는 $k \sim \mathrm{Binomial}(n, e)$로 뽑았다. 작은 셋에서는 ne가 1보다 작을 수 있으므로, k를 이항분포에서 뽑아 반복 평균의 오류율이 e가 되게 하였다. 오류율은 0.25%부터 12%까지 아홉 수준을 사용하였다.

오류 메커니즘은 두 요인을 교차한 네 조건이다(표 1). 첫째 요인은 오류를 넣을 문항의 선택으로, 균일 추출과 문항별 오답률에 비례한 추출이 있다. 오답률에 비례한 추출은 모델이 자주 틀리는 어려운 문항을 더 많이 고른다. 둘째 요인은 새 라벨로, 세 오답 중 하나를 균등하게 고르는 무작위 오답과 대표 오답이 있다. 대표 오답이 여럿이면 선택지 순서가 앞선 것을 택하였다. 어려운 문항을 골라 대표 오답을 표시하는 조건을 체계적 오류라 부른다.

평가 대상 모델의 예측으로 대표 오답을 정하면, 그 모델이 고른 오답이 정답으로 표시되어 그 모델이 유리해진다. 이를 피하기 위해 교차 적합을 사용하였다. 모델 42종을 무작위로 21종씩 두 집단으로 나누고, 한 집단 안의 쌍(210쌍)을 평가할 때는 대표 오답과 문항별 오답률을 다른 집단의 모델에서 계산하였다.

라벨 오류가 없는 교란과 비교하기 위해 기준선 두 가지를 두었다. 문항 교체 기준선은 같은 수 k의 문항을 표본 밖의 S 문항으로 바꾸고, 문항 제거 기준선은 k개 문항을 뺀다. 전체 셋에서는 바꿀 문항이 남지 않으므로 교체 기준선을 계산하지 않았다.

모든 조건은 같은 표본에서 기준 라벨로 내린 판정과 비교하므로, 반전율은 표본 추출 변동을 포함하지 않는다. 반복은 셋 크기마다 300회(전체 셋은 60회)이다. 반전율에는 반복 간 95% 신뢰구간을, 조건 간 배율에는 반복 단위 부트스트랩(1,000회) 95% 신뢰구간을 붙였다. 세부 사항은 부록 B에 정리하였다.

3.5 그 밖의 분석

RQ2에서는 수정 가능 100문항의 원래 정답이 모델 42종 전체의 대표 오답과 일치하는 비율을 우연 기댓값 1/3과 단측 이항검정으로 비교하였다. 순위의 변화는 Kendall τ(Kendall, 1938)로 측정하였다. RQ4에서는 m문항 감사에서 오류가 0건일 때의 95% Wilson 상한 $z^2/(m+z^2)$(Wilson, 1927)과 감사 통과 확률 $(1-e)^m$을 계산하였다(z = 1.96).

4 결과

4.1 실제 오류를 고쳐도 순위는 유지되었고, 반전은 작은 셋에 몰렸다

라벨 수정으로 모델 정확도는 평균 0.63%p 올랐고(범위 −0.11%p에서 0.96%p), 순위는 거의 그대로였다. 수정 라벨에서의 순위와 비교한 Kendall τ는 S의 원래 정답에서 0.992, 공개 점수에서 0.991이었다.

표 2은 δ = 3%p에서의 반전을 요약한다. 전체 셋에서 반전은 861쌍 중 8건이었고, 공개 점수 조건에서는 10건이었다. 늘어난 2건은 미해결 문항이 포함된 효과로 볼 수 있다. McNemar–Holm 규칙에서도 반전은 8건이었다.

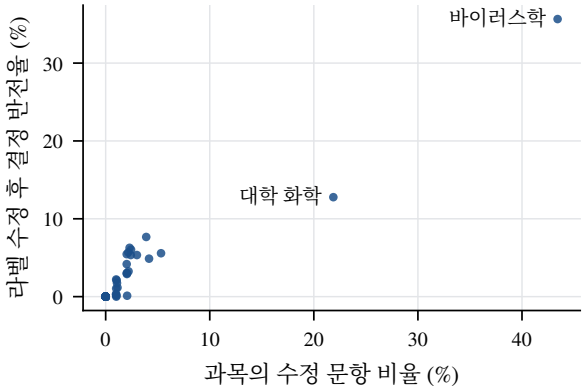


그림 1: 과목별 수정 문항 비율과 라벨 수정 후 결정 반전율(δ = 3%p, 과목마다 861쌍). 점 하나가 한 과목이다.

과목 단위 셋(76–100문항, 평균 95문항)에서는 49,077쌍 중 1,086건(2.2%)이 반전되었고, 결정 상실이 허위 결정의 두 배를 넘었다. 이 크기의 셋에서는 신뢰구간 조건이 판정을 좌우하여, δ를 0에서 5%p까지 바꾸어도 반전 수가 같았다. 즉 이 크기에서는 δ보다 신뢰구간 조건이 판정을 결정하였다. McNemar–Holm 규칙에서는 우세 판정 자체가 줄어 반전이 447건이었다.

반전은 수정 문항이 많은 과목에 몰렸다(그림 1). 과목별 반전율과 수정 문항 비율의 상관은 Pearson $r = 0.95$, Spearman $\rho = 0.97$이었다. 57과목 중 32과목에서는 반전이 없었다. 바이러스학(virology, 76문항, 수정 문항 비율 43%)에서는 결정의 36%가, 대학 화학(college chemistry, 수정 문항 비율 22%)에서는 13%가 바뀌었다. 상관은 바이러스학을 빼면 $r = 0.81$, 대학 화학까지 빼면 $r = 0.88$로 여전히 높았다.

4.2 실제 오류는 대표 오답 쪽으로 치우쳤다

수정 가능 100문항 가운데 43문항에서 원래의 틀린 라벨이 대표 오답과 같았다. 오답 셋 중 하나를 무작위로 골랐을 때의 기대 일치율 33%보다 높다(단측 이항검정 $p = 0.028$, Wilson 95% 신뢰구간 34–53%). 같은 문항에서 모델 예측이 원래 라벨과 일치한 비율은 19%, 수정 라벨과 일치한 비율은 53%였고, 오류가 없는 문항에서 모델의 평균 정확도는 60%였다. 실제 오류가 대표 오답 쪽으로 치우친다는 증거는 있으나, 표본이 100건이어서 치우침의 크기는 불확실하다.

4.3 체계적 오류는 무작위 오류보다 결정을 더 많이 바꾸었다

반전율은 오류율이 높을수록, 셋이 작을수록 커졌다(그림 2). 오류율 3%에서 100문항 셋의 반전율은 전체 셋의 약 7–9배였다(표 3). 모든 조건에서 역전은 한 건도 없었다.

체계적 오류의 반전율은 무작위 오류의 1.4–1.6배였다(870문항 이하, 오류율 1–5%, 부트스트랩 신뢰구간 하한 1.28 이상). 전체 셋에서는 배율이 1.9–2.5배로 더 컸지만 반전 수가 적어 신뢰구간이 넓었다. 두 요인을 나누어 보면 각 요인이 따로 반전을 늘렸다. 대표 오답 오류는 무작위 오류의 1.2–1.3배, 어려운 문항 오류는 1.1–1.3배였고, 두 요인을 함께 쓴 체계적 오류에서 가장 컸다(그림 3).

무작위 라벨 오류의 효과는 라벨 오류가 없는 교란과 크게 다르지 않았다. 870문항 이하에서 무작위 오류의 반전율은 문항 교체 기준선의 1.0–1.2배, 문항 제거 기준선의 1.4–1.7배였다. 무작위 오류로 생기는 반전의 대부분은 판정 경계 근처의 쌍이 작은 교란에 흔들리는 데서 오는 것으로 보인다. 체계적 오류의 반전율은 교체 기준선의 약 1.6배였다.

라벨 오류에 고유한 특징은 반전의 방향에서 나타났다. 870문항, 오류율 3%에서 네 가지 라벨 오류 조건은 모두 결정 상실이 허위 결정의 약 두 배였으나, 교체 기준선에서는 두 방향이 비슷하였다(표 3의 둘째 묶음). 이 비대칭은 격차 압축과 관련된다. 기준 라벨에서 정확도 차이가 큰 쌍일수록 라벨 오류로 차이가 더 많이 줄었다(음의 상관). 오류율 3%에서 이 상관은 무작위 오류에서 −0.46(100문항)부터 −0.98(전체 셋)까지, 체계적 오류에서 −0.21부터 −0.67까지였다. 교체 기준선의 상관은 0에 가까웠다(−0.03에서 −0.01).

4.4 $\delta/4$ 감사 기준 경계의 오류율에서도 결정은 대부분 유지되었다

오류 0건 감사의 95% Wilson 상한이 $\delta/4$ 이하가 되는 최소 감사 크기는 δ = 3%p에서 509문항이었다. δ가 1, 2, 5%p이면 각각 1,533, 765, 304문항이다. 따라서 선행 리뷰의 “509문항 오류 0건” 규칙은 Wilson 상한 기준과 같은 규칙이다.

표 4는 이 감사의 통과 확률과 같은 오류율에서의 반전율을 함께 보인다. 오류율이 $\delta/4 = 0.75\%$인 셋은 2.2%의 확률로만 감사를 통과한다. 이 오류율에서 870문항 셋의 반전율은 무작위 오류 0.81%, 체계적 오류 1.12%였고, 문항 교체 기준선은 0.70%였다. 100문항 셋에서는 무작위 오류 1.22%, 체계적 오류 1.86%였다. 통과 확률은 감사의 작동 특성일 뿐이며, 감사를 통과한 셋의 오류율 분포는 사전 분포 없이 말할 수 없다.

5 논의

라벨 오류는 주로 결정을 보류로 바꾼다. 4지선다 문항을 정확도로 채점할 때 라벨 오류는 해당 문항을 맞힌 모델의 점수를 깎고, 오류 라벨과 같은 오답을 고른 모델에 점수를 준다. 정확도가 높은 모델일수록 깎이는 문항이 많으므로 격차가 줄고, 반전은 결정 상실 쪽으로 치우친다. 실험 범위에서 우세 방향이 뒤집힌 경우는 없었고, 대신 작은 차이

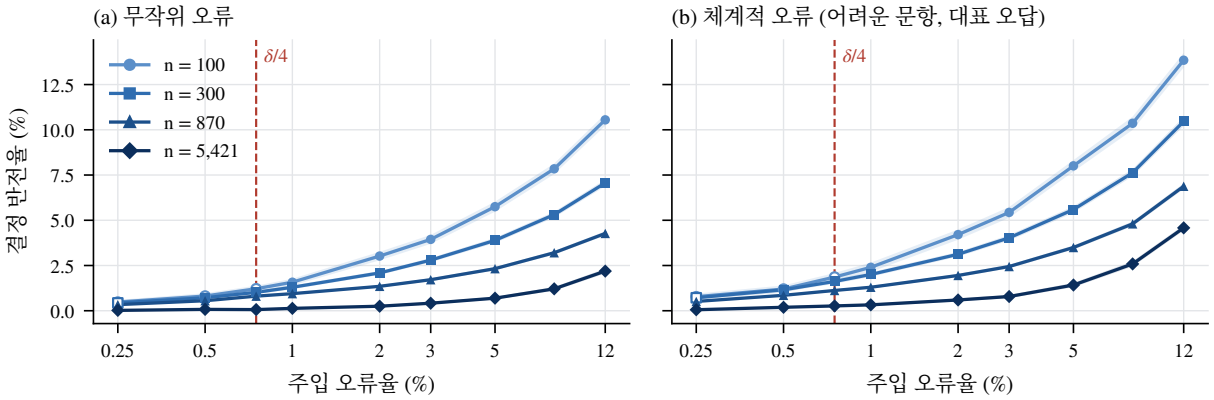


그림 2: 주입 오류율에 따른 결정 반전율(δ = 3%p, 교차 적합). 띠는 반복 간 95% 신뢰구간이다. 속이 빈 표식은 기대 오류 문항 수가 1 미만인 조건이며, 점선은 선행 리뷰의 감사 기준 오류율 $\delta/4$ = 0.75%이다. 가로축은 로그 척도이다.

	라벨 오류				기준선(라벨 오류 없음)	
	무작위	대표 오답	어려운 문항	체계적	문항 교체	문항 제거
결정 반전율(%)						
n = 100	3.94	4.65	4.46	5.43	3.39	2.32
n = 300	2.80	3.51	3.24	4.03	2.47	1.84
n = 870	1.72	2.08	2.00	2.44	1.48	1.09
n = 5,421	0.42	0.59	0.55	0.79	–	0.32
n = 870에서 반전의 방향(%)						
결정 상실	1.14	1.39	1.31	1.59	0.72	0.62
허위 결정	0.57	0.69	0.69	0.86	0.76	0.47
격차 압축 상관	−0.86	−0.80	−0.68	−0.46	−0.01	0.01

표 3: 오류율 3%에서 조건별 결정 반전(δ = 3%p, 교차 적합, 반복 300회, 전체 셋은 60회). 반전율의 반복 간 95% 신뢰구간 반폭은 모두 0.3%p 이하이다. 격차 압축 상관은 오류로 생긴 쌍 차이의 변화와 원래 쌍 차이 사이의 Pearson 상관이다(n = 870). 전체 셋에는 교체할 문항이 남지 않아 문항 교체 기준선을 계산하지 않았다(–).

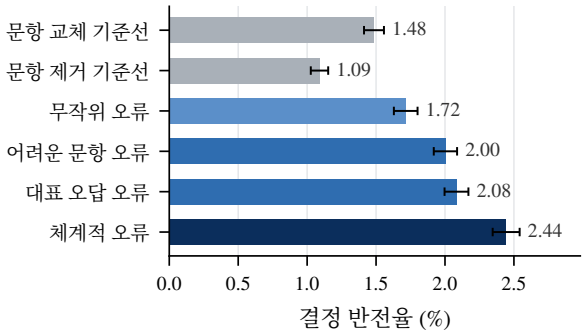


그림 3: 870문항 셋에서 문항의 3%를 바꿀 때의 조건별 결정 반전율(δ = 3%p). 오차 막대는 반복 간 95% 신뢰구간이다. 조건의 정의는 표 1에 있다.

		n = 100		n = 870	
오류율	통과 확률	무작위	체계적	무작위	체계적
0.25	28.0	0.48	0.78	0.34	0.51
0.50	7.8	0.81	1.20	0.55	0.85
0.75	2.2	1.22	1.86	0.81	1.12
1.00	0.6	1.58	2.40	0.94	1.30

표 4: 509문항 오류 0건 감사의 통과 확률과 같은 오류율에서의 결정 반전율(모두 %, δ = 3%p). 통과 확률은 $(1-e)^{509}$이고, 오류율 0.75%가 $\delta/4$에 해당한다.

를 가려낼 검정력이 줄었다. 따라서 라벨 오류의 주된 비용은 잘못된 모델 선택보다 판정 보류와 그에 따른 추가 평가에 있을 가능성이 크다.

허용 오류율은 체계적 오류를 가정해 정해야 한다. 무작위 라벨 오류만 가정하면, 라벨 오류의 영향이 문항 일부를 교체하는 정도로만 보여 라벨 검수의 이득이 작게 평가된다. 그러나 실제 오류는 대표 오답 쪽으로 치우쳤고, 이런 체계적 오류의 반전율은 문항 교체 기준선의 약 1.6배였다. 무작위 오류 시뮬레이션으로 허용 오류율을 정하면 위험을 과소평가하게 된다.

작은 셋과 오류가 몰린 하위 집합은 따로 감사해야 한다. 오류율 3%에서 100문항 셋의 반전율은 전체 셋의 7–9배였다. 100문항 안팎의 셋에서는 신뢰구간이 넓어 δ가 판정에 관여하지 못하므로, 오류는 대부분 판정 보류로 이어진다. 바이러스학처럼

오류가 몰린 과목은 셋 전체의 오류율이 낮아도 그 과목 안의 결정을 크게 흔든다. 셋 전체의 오류율만 보고하는 감사로는 이런 하위 집합을 찾아내기 어렵다.

$\delta/4$ 기준은 셋 크기와 함께 적용해야 한다. 509문항 오류 0건 규칙은 오류율 0.75%인 셋을 2.2%의 확률로만 통과시키며, 그 오류율에서 870문항 셋의 반전은 1% 안팎이고 역전은 없었다. 이 반전의 상당 부분은 문항 교체만으로도 생기는 수준이므로, 870문항 이상의 셋에서 이 기준은 보수적이다. 그러나 100문항 셋에서는 같은 오류율에서도 체계적 오류의 반전율이 1.9%였다.

6 결론

공개 모델 42종과 전문가 수정 라벨을 이용한 실험에서, 골든셋 라벨 오류는 모델 순위를 거의 바꾸지 않았고 우세 방향을 뒤집지도 않았다. 라벨 오류는 모델 간 격차를 줄여 결정을 보류로 바꾸었다. 무작위 라벨 오류의 효과는 같은 수의 문항을 교체할 때와 비슷하였으나, 어려운 문항에 대표 오답이 표시되는 체계적 오류는 약 1.5배 큰 효과를 냈고 실제 오류도 이 방향으로 치우쳤다. 효과는 작은 셋과 오류가 몰린 과목에서 컸다. 골든셋을 관리할 때는 허용 오류율을 체계적 오류 기준으로 정하고, 과목이나 기능 같은 하위 집합마다 오류율을 감사할 것을 권한다. 선행 리뷰의 509문항 감사 기준은 870문항 이상의 셋에서는 보수적인 기준으로 쓸 수 있으나, 100문항 안팎의 셋에서는 같은 기준에서도 반전이 더 많으므로 셋 크기를 함께 고려해야 한다.

한계

과제와 채점. MMLU는 4지선다 정확도 과제이다. 생성형 응답이나 RAG 출력을 판정 모델로 채점하는 평가에서는 라벨 오류가 격차를 압축하지 않을 수 있다.

모델. MMLU 문항별 결과가 공개된 2023–2024년 모델로 한정되며, Llama-2 chat 같은 공식 대화형 모델이 빠졌다. 최신 모델에서의 결과는 확인하지 않았다.

라벨. 미해결 오류 269문항은 기준 라벨에서 제외하였고, Redux 재주석 자체의 오류는 고려하지 않았다. 실제 오류의 체계성 추정(RQ2)은 100건에 기반한다.

결정 규칙과 측정 범위. 결과는 결정 규칙에 의존하며, McNemar–Holm 규칙에서 과목 단위 반전은 절반 이하로 줄었다. 반전율은 같은 표본 안의 교란 효과만 측정하며, 표본 추출 변동에 따른 결정의 불안정은 다루지 않았다.

참고문헌

Anonymous. 2026. Building and validating golden evaluation datasets for LLM and RAG applications: A mini review. Manuscript.

Edward Beeching, Clémentine Fourrier, Nathan Habib, et al. 2023. Open LLM leaderboard (2023–2024). Hugging Face. Per-item results: https://huggingface.co/open-llm-leaderboard-old.

Dallas Card, Peter Henderson, Urvashi Khandelwal, Robin Jia, Kyle Mahowald, and Dan Jurafsky. 2020. With little power comes great responsibility. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*.

Leo Gao, Jonathan Tow, et al. 2023. A framework for few-shot language model evaluation. Zenodo.

Aryo Pradipta Gema, Joshua Ong Jun Leang, Giwon Hong, et al. 2025. Are we done with MMLU? In *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies*.

Dan Hendrycks, Collin Burns, Steven Basart, Andy Zou, Mantas Mazeika, Dawn Song, and Jacob Steinhardt. 2021. Measuring massive multitask language understanding. In *International Conference on Learning Representations*.

Sture Holm. 1979. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2):65–70.

M. G. Kendall. 1938. A new measure of rank correlation. *Biometrika*, 30(1/2):81–93.

Lovish Madaan, Aaditya K. Singh, Rylan Schaeffer, et al. 2024. Quantifying variance in evaluation benchmarks. *arXiv preprint arXiv:2406.10229*.

Quinn McNemar. 1947. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2):153–157.

Curtis G. Northcutt, Anish Athalye, and Jonas Mueller. 2021. Pervasive label errors in test sets destabilize machine learning benchmarks. In *Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks*.

Joshua Vendrow, Edward Vendrow, Sara Beery, and Aleksander Madry. 2025. Do large language model benchmarks test reliability? *arXiv preprint arXiv:2502.03461*.

Edwin B. Wilson. 1927. Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158):209–212.

A 모델 목록

표 5는 분석에 포함한 모델 42종과 세 라벨 조건에서의 정확도를 보인다. 모델 이름은 Hugging Face 저장소 이름이다. 제외한 6종 가운데 `allenai/OLMo-7B`, `deepseek-ai/deepseek-llm-7b-base`, `internlm/internlm2-7b`는 추정한 이름의 리더보드 저장소가 없었다. Llama-2 chat 3종(7B, 13B, 70B)은 리더보드 저장소에 MMLU 문항별 결과가 없었다. OLMo 2종을 추가하기 전의 40종으로 분석한 결과도 본문의 결론과 같았다.

B 실험 세부 사항

문항 결합. Redux 문항의 질문과 네 선택지를 lm-evaluation-harness의 MMLU 프롬프트 형식(질문, A–D 선택지, "Answer:")으로 이어 붙이고 연속된 공백을 하나로 정규화하였다. 리더보드 상세 파일의 문항 필드도 같은 방식으로 정규화한 뒤, 과목명과 함께 결합 키로 사용하였다. 모든 모델의 예측이 있는 문항만 남겼다.

오류 주입. 오답률 비례 추출의 가중치는 다른 집단 모델의 문항별 오답률에 0.001을 더한 값이다. 모든 모델이 맞힌 문항의 대표 오답은 세 오답 중 하나를 무작위로 정하였다. 한 반복은 두 집단에서 210쌍씩 모두 420쌍을 평가한다. 반복 간 신뢰구간은 반복별 반전율의 평균에 표준오차의 1.96배를 더하고 뺀 구간이다. 조건 간 배율의 신뢰구간은 반복을 복원 추출하여 두 조건의 평균 반전율의 비를 1,000회 계산한 뒤 2.5와 97.5 백분위수로 구하였다.

난수 시드. 모델 분할에 7, 표본 추출과 오류 주입에 42, 부트스트랩에 1, 대표 오답의 무작위 보조 추첨에 0을 사용하였다.

재현. 코드와 결과 파일은 공개 저장소의 `app/`과 `results/`에 있다. `fetch.py`가 데이터를 내려받고, `analyze.py`가 결과 파일을, `figures.py`와 `tables.py`가 그림과 표를 만든다. MMLU-Redux 2.0은 CC BY 4.0으로 배포되며, 원자료는 저장소에 복사하지 않았다.

모델	공개 점수	S 원래 정답	S 수정 정답	변화(%p)
Qwen/Qwen1.5-72B	77.3	78.0	78.9	0.87
01-ai/Yi-34B	76.1	76.8	77.6	0.79
NousResearch/Nous-Hermes-2-Mixtral-8x7B-DPO	72.0	72.8	73.6	0.79
mistralai/Mixtral-8x7B-v0.1	71.9	72.6	73.5	0.81
deepseek-ai/deepseek-llm-67b-base	71.9	72.6	73.4	0.85
mistralai/Mixtral-8x7B-Instruct-v0.1	71.3	71.9	72.8	0.96
tiiuae/falcon-180B	70.6	71.2	72.0	0.87
meta-llama/Llama-2-70b-hf	70.0	70.6	71.4	0.77
Qwen/Qwen1.5-14B	69.4	70.4	71.2	0.79
Qwen/Qwen-14B	67.7	68.5	69.4	0.90
meta-llama/Meta-Llama-3-8B-Instruct	67.2	68.0	68.8	0.85
meta-llama/Meta-Llama-3-8B	67.2	67.7	68.5	0.81
google/gemma-7b	66.0	66.6	67.3	0.74
upstage/SOLAR-10.7B-v1.0	65.2	65.9	66.7	0.87
openchat/openchat_3.5	65.2	65.9	66.5	0.61
WizardLM/WizardLM-70B-V1.0	64.8	65.3	65.9	0.65
huggyllama/llama-65b	64.3	64.7	65.4	0.68
mistralai/Mistral-7B-v0.1	63.7	64.3	65.2	0.89
teknium/OpenHermes-2.5-Mistral-7B	63.7	64.4	65.1	0.66
01-ai/Yi-6B	63.6	64.4	65.1	0.70
Qwen/Qwen1.5-7B	62.3	62.8	63.5	0.72
HuggingFaceH4/zephyr-7b-beta	61.2	61.7	62.6	0.87
mistralai/Mistral-7B-Instruct-v0.2	61.1	61.8	62.5	0.70
Intel/neural-chat-7b-v3-1	60.5	61.3	62.1	0.81
Qwen/Qwen-7B	59.7	60.3	61.0	0.72
huggyllama/llama-30b	58.3	58.9	59.7	0.81
microsoft/phi-2	58.2	58.6	59.2	0.65
tiiuae/falcon-40b	57.0	57.8	58.3	0.57
lmsys/vicuna-13b-v1.5	57.0	57.7	58.2	0.52
meta-llama/Llama-2-13b-hf	54.5	55.0	55.6	0.63
allenai/OLMo-1.7-7B-hf	53.6	54.2	54.7	0.50
lmsys/vicuna-7b-v1.5	51.2	51.7	52.4	0.68
huggyllama/llama-13b	47.9	48.5	49.0	0.52
mosaicml/mpt-30b	47.7	48.1	48.6	0.57
meta-llama/Llama-2-7b-hf	46.8	47.2	47.7	0.50
stabilityai/stablelm-3b-4e1t	45.1	45.5	46.2	0.70
google/gemma-2b	42.9	43.5	43.7	0.28
huggyllama/llama-7b	36.4	36.7	36.9	0.18
mosaicml/mpt-7b	31.1	31.0	31.0	−0.04
allenai/OLMo-7B-hf	27.9	28.0	28.0	0.00
tiiuae/falcon-7b	27.3	27.6	27.4	−0.11
EleutherAI/pythia-12b	27.5	27.4	27.4	0.00

표 5: 모델별 정확도(%). 공개 점수는 결합된 5,690문항의 원래 정답, S 원래 정답과 S 수정 정답은 분석 집합 5,421문항에서의 정확도이며, 변화는 수정 정답과 원래 정답의 차이이다. 수정 정답 기준 정확도 순으로 정렬하였다.