LLM-as-a-Judge는 언제 믿을 수 있는가: 2023–2026 문헌 2,185편의 분류·비교·종합

초안 · 2026-10-19

초록

대형 언어모델(LLM)이 다른 모델의 출력을 채점하거나 비교하는 LLM-as-a-Judge는 벤치마크 순위, 보상 신호, 품질 감시에 널리 쓰이지만, 어떤 조건에서 그 판정을 믿을 수 있는지는 충분히 정리되지 않았다. 이 서베이는 2023년 1월부터 2026년 10월까지의 후보 10,273편에서 선별한 2,185편을 판정 구성, 신뢰성과 편향, 개선 기법, 응용 분야, 보안의 다섯 축으로 분류했다. 결론이 갈리는 비교 질문 12개를 정해 주장 928개를 지지·반박·조건부·효과 없음으로 집계하면서 자기 방법을 제안한 논문의 주장과 기존 방식들을 독립적으로 비교한 주장을 나눴고, 결과가 갈린 7개 질문은 독립 평가 주장 중 99개를 골라 본문으로 확인했다. 선별·추출·주장 기록과 본문 확인은 LLM이 했으며, 사람 검수는 선별 판정 표본 200편에 한정했다.

분석 결과, 판정 신뢰도가 과제 난이도와 함께 떨어진다는 것과 판정 모델이 적은 비용의 조작에 흔들린다는 것은 초록 기준으로 근거가 한 방향으로 모였다. 판정 형식, 모델 크기, CoT, 다중 판정 집계의 효과는 결과가 갈렸고, 정답 참조는 대체로 도움이 되었으나 조건에 따라 효과가 달랐다. 본문 확인에서는 과제의 검증 가능성, 판정 모델이 스스로 풀 수 있는지, 평가 지표, 데이터의 적대성이 여러 질문에 걸쳐, 판정 모델 간 오류 상관이 집계 질문에서 결과를 바꾸는 조건으로 반복해서 기록되었다. 전문 분야에서 LLM 판정이 전문가를 대신한다는 명제는 독립 평가 132개 중 22개만 지지해 대체로 부정되었고, 방어가 공격을 의미 있게 줄인다는 명제는 독립 평가 11개 중 1개만 지지했다. 앙상블·토론, 전문 분야 판정, 방어는 제안 방법 쪽에서 대부분 지지된 것과 달리 독립 평가에서는 지지가 소수였고, 파인튜닝 판정 모델과 편향 완화는 근거 대부분이 제안 논문의 자기 보고여서 독립 검증이 부족했다. 본문으로 확인한 주장 중 초록의 지지와 반박이 서로 뒤집힌 경우는 없었지만, 11개는 방향이 달라졌고 그중 9개는 조건부로 옮겨 가 초록이 조건을 지우는 경향을 보였다.

이를 바탕으로 독립 재현과 보고 기준, 조건별 판정 모델 선택과 층화 메타평가, 측정의 표준화, 이종 집계와 오류 상관, 정상 성능을 지키는 방어, 전문 분야의 분담 판정, 검증 범위의 확대라는 일곱 가지 연구 의제를 제시한다.

주제어: LLM-as-a-Judge, 자동 평가, 판정 편향, 메타평가, 체계적 문헌 고찰

1. 서론

1.1 배경

대형 언어모델(LLM)이 만든 긴 응답을 사람이 하나하나 평가하기는 어렵다. 정답이 하나로 정해지지 않는 개방형 질문, 요약, 대화, 코드 설명, 에이전트의 행동 기록은 참조 답과의 어휘 겹침으로 잴 수 없고, 사람 평가는 비싸고 느리다. 강한 LLM에게 응답을 채점하거나 비교하게 하는 방법, 곧 LLM-as-a-Judge는 이 문제를 풀기 위해 빠르게 퍼졌다. MT-Bench와 Chatbot Arena 연구는 GPT-4 판정이 사람 선호와 사람끼리의 일치 수준으로 맞는다고 보고하면서 위치·길이·자기선호 편향도 함께 지적했고 [1], G-Eval은 CoT와 양식 채우기로 요약·대화 평가에서 사람과의 상관을 높였다 [2]. 이후 판정 전용 모델 학습 [3], 보상모델 평가 벤치마크 [4]로 연구가 넓어졌다.

판정 모델은 이제 벤치마크 순위, 강화학습의 보상 신호, 데이터 선별, 배포된 시스템의 품질 감시에 쓰인다. 판정이 틀리면 그 위에 쌓인 평가와 학습도 틀어질 수 있다. 그래서 "LLM 판정을 언제, 어떤 조건에서 믿을 수 있는가"는 평가 방법론에 그치지 않고 벤치마크 순위·보상·데이터 선별의 타당성과 직결된다.

1.2 기존 서베이와 이 서베이의 차이

LLM 판정을 다룬 일반 서베이는 2024년 말에 집중되어 있다 [5, 6, 7]. 이들은 판정 방식, 신뢰성, 응용 분야를 폭넓게 정리했지만, 이 분야 문헌의 대부분은 그 뒤에 나왔다. 이 서베이의 포함 논문 2,185편 중 2025년 이후 출판이 1,822편(83%)이다. 2025–2026년에도 일반 서베이가 나왔고 [8, 9, 10], 분야별로는 보안 [11], 의료 [12], 소프트웨어공학 [13] 리뷰가 나왔다. 그러나 이 서베이가 확인한 범위에서는 늘어난 문헌 전체를 질문 단위로 집계한 정리가 드물다.

이 서베이는 두 가지 점에서 기존 서베이와 다르다. 첫째, 2023년 1월부터 2026년 10월까지의 문헌을 분야를 가리지 않고 대상으로 삼는다. 둘째, 논문을 분류해 나열하는 데서 그치지 않고 분류 → 비교 → 종합 → 연구 의제의 순서로 정리한다. 비교는 결론이 갈리는 질문별로 주장의 방향을 집계하되, 자기 방법을 제안한 논문의 주장과 독립 평가를 나눠 센다(2.4–2.5절).

1.3 연구 질문

이 서베이는 다섯 개의 연구 질문을 다룬다. 연구 질문마다 결론이 갈리는 비교 질문을 한 개에서 네 개씩 두었다(표 2-1).

- **RQ1. 판정 구성**: LLM 판정 모델은 어떤 형식과 구성으로 만들어지며, 어떤 구성이 사람 판정과 더 잘 맞는가? (4장)
- **RQ2. 신뢰성과 편향**: 판정의 신뢰성은 어떻게 측정되며, 어떤 편향과 실패가 보고되었는가? (5장)
- **RQ3. 개선 기법**: 판정을 개선하는 기법은 무엇이며, 실제로 효과가 있는가? (6장)
- **RQ4. 응용 분야**: 어떤 분야에 쓰이며, 전문 분야에서 사람을 대신할 수 있는가? (7장)
- **RQ5. 보안**: 판정 모델은 어떤 공격에 취약하며, 방어는 효과가 있는가? (8장)

1.4 기여

이 서베이의 기여는 다음과 같다.

1. **대규모 문헌 지도**: 10,273편의 후보에서 선별한 2,185편을 판정 형식·구성, 편향, 개선 기법, 분야, 보안의 다섯 축으로 분류했다 (3–8장).
2. **질문 단위의 증거 집계**: 12개 비교 질문에 대한 주장 928개를 지지·반박·조건부·효과 없음으로 집계하고, 제안 방법과 독립 평가를 나눠 보였다 (4–8장).
3. **상충 결과의 조건 분석**: 결과가 갈린 7개 질문의 독립 평가 주장 99개를 본문으로 확인했다. 과제의 검증 가능성, 판정 모델이 스스로 풀 수 있는지, 평가 지표, 데이터의 적대성은 여러 질문에 걸쳐 결과가 갈리는 조건으로 반복되었고, 판정 모델 간 오류 상관은 집계 질문(Q-MULTI)에서만 나타났다 (9장).
4. **연구 의제**: 독립 재현과 보고 기준, 조건별 판정 모델 선택과 층화 메타평가, 측정의 표준화, 이종 집계와 오류 상관, 정상 성능을 지키는 방어, 전문 분야의 분담 판정, 검증 범위의 확대라는 7개 의제를 근거와 함께 제시했다 (10장).

1.5 구성

2장은 검색·선별·추출·주장 기록·본문 확인의 방법과 한계를 설명한다. 3장은 문헌 전체를 개관한다. 4–8장은 RQ1–5를 차례로 다루며, 각 장은 분류, 비교, 종합, 공백의 순서로 쓴다. 9장은 연구 질문별 답, 여러 질문에 걸쳐 결과를 가르는 조건, 제안 방법과 독립 평가의 격차, 이 종합의 한계를 논의하고, 10장은 연구 의제를 정리한다. 11장에서 결론을 맺는다.

2. 방법

이 서베이는 체계적 문헌 고찰의 절차(검색 → 선별 → 추출 → 종합)를 따르되, 규모 때문에 선별·추출·주장 기록의 1차 작업을 LLM 서브에이전트에 맡기고, 선별 단계에서만 사람이 표본으로 검수했다. 판정 연구를 정리하면서 판정 작업을 LLM에 맡긴 셈이므로, 각 단계에서 사람 검수와 자동 점검을 어떻게 붙였는지를 함께 밝힌다. 모든 스크립트와 중간 기록은 프로젝트 저장소에 있다.

2.1 검색

검색 기간은 2023년 1월 1일부터 2026년 10월 19일까지다. 시작점은 MT-Bench와 Chatbot Arena로 LLM 판정 모델과 사람 판정의 일치를 체계적으로 측정한 연구가 나온 시기로 잡았다. 검색어는 "LLM-as-a-judge", "LLM-as-judge", "LLMs as judges", "LLM judge", "LLM evaluator", "LLM-based evaluation", "LLM-as-a-jury", "language model as a judge", "judge model"의 9개 구절이다.

데이터베이스 검색에는 OpenAlex, Semantic Scholar, arXiv를 썼다. 여기에 인용 기반 확장을 더했다. 일반 서베이와 분야별 리뷰 6편을 시드로 삼아 이들의 참고문헌과 이들을 인용한 논문을 Semantic Scholar에서 모았다. 참고문헌이 색인되지 않은 서베이는 arXiv HTML판의 참고문헌 목록에서 arXiv ID를 직접 뽑았다. LLM 판정 연구를 정리한 공개 목록(Awesome 목록) 2개도 출처로 넣었다.

출처별 수집 건수(중복 포함)는 OpenAlex 7,204, Semantic Scholar 5,321, arXiv 4,077, 서베이를 인용한 논문 2,882, Awesome 목록 606, 서베이 참고문헌 1,049(두 경로 합계), 시드 서베이 6건이다. arXiv ID, DOI, 정규화한 제목 순서로 중복을 합치고 2023년 이전 출판물 94편을 뺀 결과 선별 대상은 10,273편이 되었다. 이 값은 아래 병합 오류를 고친 뒤 다시 병합한 결과다.

병합 과정에서 데이터 오류를 하나 고쳤다. OpenAlex의 DOI 랜딩 URL 일부를 arXiv ID로 잘못 읽어 서로 다른 논문이 하나로 합쳐진 사례가 489편 있었다. arXiv ID를 유효한 형식으로만 인정하고 OpenAlex에서는 DOI로만 얻도록 고친 뒤 다시 병합했다.

2.2 선별

이 서베이의 범위는 LLM이 생성물을 평가하거나 판정하는 연구다. 선별 기준은 이 범위의 포함·제외 원칙을 판정 가능한 규칙으로 옮긴 것이다. LLM이 평가자·판정자 역할을 하는 연구를 포함하고(I1–I8: 판정 방식 제안, 신뢰성·편향 분석, 판정 모델 학습, 판정 벤치마크·메타평가, 분야별 판정 연구, 판정 모델 보안, LLM 판정과 직접 비교한 보상모델 연구, 서베이·포지션 페이퍼), LLM 판정을 평가 지표로만 쓴 연구, LLM이 평가 대상일 뿐인 벤치마크, LLM 판정과 비교하지 않은 보상모델 단독 연구 등을 제외했다(E1–E7). 분야 응용 논문은 판정 모델을 사람 판정과 대조해 검증했을 때만 포함했다. 초록이 없고 제목만으로 판정 연구임이 분명하지 않으면 제외하지 않고 '애매'로 두었다. 사람이 쓴 텍스트에 라벨을 다는 LLM 주석(annotation) 연구는 생성물 판정이 아니므로 제외하고 관련 연구로만 언급한다.

1차 선별은 Claude Code 서브에이전트(Sonnet)가 제목과 초록을 읽고 했다. 제목에 judge·evaluator 등이 들어간 후보(r1, 1,407편)부터 시작해, 큐레이션 출처(r2, 729편), 무작위 표본(r2s, 140편), 나머지 전수(r3, 7,997편) 순서로 네 라운드를 돌렸다. 애매로 남은 논문의 재판정(r4)과 추출 중 표시된 논문의 재판정(r5)은

뒤에 따로 했다. 무작위 표본의 포함률(10.7%, 95% CI 6.6–16.9%)로 미선별 영역의 관련 논문 수를 먼저 추정했고, 전수 선별의 실제 포함률(13.0%)은 이 구간 안에 들었다.

사람 검수는 저자가 r1과 r3 라운드의 LLM 판정에서 포함 50편과 제외 50편씩을 무작위로 뽑아 제목과 초록만 보고 판정했다. 200편 중 197편이 일치했다(98.5%, Wilson 95% CI 95.7–99.5%). 불일치 3건은 모두 초록이 없거나 한 문장뿐인 경우와 LLM 판정의 대안 연구를 어떻게 볼지의 문제였고, 기준을 명확히 한 뒤 사람 판정으로 덮어썼다.

LLM 선별의 실패도 기록해 두었다. 일부 배치는 초록을 끝까지 읽지 않고 같은 근거 문장을 되풀이했고, 병렬 서브에이전트가 같은 임시 파일을 써서 한 배치의 판정이 다른 배치의 논문에 붙은 사례도 있었다. 이후 배치 안 근거 문장 반복률, 배치 간 근거 문장 공유, 제목과 근거의 대응을 자동으로 검사해 문제가 된 배치를 다시 선별했다.

추출 단계에서 LLM 판정 연구가 아닐 수 있다고 표시된 논문(170편)과 초록 없이 제목만으로 추출된 논문(59편)은 다시 선별해 43편을 제외하고 62편을 '애매'로 돌렸다. 초록 유사도와 같은 첫 저자의 유사 제목으로 찾은 같은 연구의 다른 판본 35편(arXiv·medRxiv 프리프린트와 학회·저널판, 저장소 사본, 제목이 바뀐 판본)은 동료 심사를 거친 판본이나 논문판만 남겼다. 최종 포함은 2,185편이다. 애매 1,868편은 이 서베이에서 검토하지 않았다.

2.3 정보 추출

포함 논문마다 두 종류의 정보를 기록했다. 첫째는 PMDRL 요약으로, 저자·연도·게재처(Who), 풀려는 문제(Problem), 방법(Method), 데이터·판정 모델(Data), 결과(Result), 스스로 밝힌 한계(Limitation), 지적한 기존 연구의 공백(Gap)이다. 둘째는 분류 코드로, 기여 유형, 판정 형식, 판정 구성, 분야, 언어, 사람 판정과의 비교 여부와 지표, 다룬 편향, 제안한 개선책이다. 추출은 제목과 초록만 근거로 했고, 초록에 없는 항목은 비워 두었다.

1차 추출 뒤 편향과 개선책에서 '기타'가 많이 나와(편향 592편, 개선책 328편) 표본을 읽고 하위 범주를 새로 만들었다. 편향에는 문체, 앵커링, 사회 편향, 관대·엄격 채점, 맹점, 기준 불일치를 더했고, 개선책에는 과제 분해, 프롬프트 최적화, 비평·재검토, 내부 표현 조작, 도구·실행 검증, 사람 개입, 판정 보류를 더했다. 재분류 후 '기타'는 편향 226편, 개선책 169편으로 줄었다. 두 값은 최종 포함 논문 2,185편 기준이다.

2.4 비교 질문과 주장 추출

논문을 분류하는 데서 그치지 않고 결과를 맞대기 위해, 결론이 갈리는 질문 12개를 정하고 각 질문을 검증할 명제로 적었다(표 2-1). 포함 논문의 초록을 다시 읽어, 같은 연구 안에서 대안과 직접 비교한 결과만 이 명제에 답하는 주장으로 뽑았다. 주장마다 방향을 넷 중 하나로 기록했다. 지지는 명제대로의 결과, 반박은 반대 결과, 조건부는 과제·판정 모델·지표 등 조건에 따라 방향이 달라진다는 결과, 효과 없음은 차이가 없다는 결과다. 결과가 성립한 조건과 초록의 수치도 함께 적었다.

표 2-1 비교 질문

ID	장	검증할 명제
Q-FORMAT	4	쌍비교 판정이 점수형 판정보다 사람 판정과 더 일치한다.
Q-MULTI	4	여러 판정 모델의 집계·토론이 단일 판정보다 낫다.
Q-SCALE	5	더 크거나 강한 판정 모델일수록 편향이 적고 사람과 더 일치한다.
Q-SELF	5	판정 모델은 품질을 통제해도 자기·같은 계열 출력을 더 높게 평가한다.
Q-HARD	5	과제가 어렵거나 응답 품질이 비슷하게 높을수록 사람과의 일치가 떨어진다.
Q-COT	6	판정 전에 추론·설명을 생성하면 판정이 좋아진다.
Q-REF	6	정답·참조 답을 주면 판정이 좋아진다.
Q-FT	6	판정 전용으로 학습한 작은 모델이 GPT-4급 판정에 이르고 일반화된다.
Q-DEBIAS	6	편향 완화 기법이 해당 편향을 의미 있게 줄인다.
Q-EXPERT	7	전문 분야에서 LLM 판정이 전문가끼리의 일치 수준으로 맞는다.
Q-ATTACK	8	적은 비용의 조작으로 판정 결과를 크게 바꿀 수 있다.
Q-DEFENSE	8	제안된 방어가 공격 성공률을 의미 있게 낮춘다.

주장 기록의 품질은 시범 배치와 형식 검사로 점검했다. 당시 종합 대상 2,200편(이후 중복 판본 15편을 빼 2,185편)을 110편씩 20개 배치로 나눠 기록하되, 첫 배치(110편)를 먼저 검토한 뒤 나머지 19개 배치를 같은 규칙으로 기록했다. 처음 11개 질문으로 시범 추출을 했을 때, 자연 발생 편향의 완화(순서 교환, 길이 통제)가 보안 방어로 기록되는 문제가 보여 Q-DEBIAS를 더하고 적용 원칙을 좁혔다. 모든 배치의 기록 형식을 자동으로 검사했고, 형식 오류는 없었다. 형식 검사는 기록 형식만 보므로, 주장이 초록과 맞는지는 이 검사로 확인되지 않는다.

주장마다 근거의 성격도 표시했다. 논문이 제안한 방법의 효과를 보고한 주장은 '제안 방법', 기존 방식들을 독립적으로 비교한 주장은 '독립 평가'로 나눴다. 제안 방법의 성과 보고는 긍정 쪽으로 치우치기 쉬우므로, 두 집단을 따로 집계해야 상충 결과를 제대로 읽을 수 있다. 이렇게 뽑은 주장은 중복 판본을 뺀 2,185편 기준으로 928개다.

2.5 본문 확인

초록은 짧고 결과를 일반화해 쓰는 경향이 있으므로, 결과가 갈린 7개 질문(Q-SCALE, Q-MULTI, Q-EXPERT, Q-COT, Q-REF, Q-FORMAT, Q-DEFENSE)은 본문으로 확인했다. 7개 질문은 주장 추출 집계를 본 뒤 정했다. 근거 대부분이 제안 방법이어서 '독립 근거 부족'이 주된 결과인 Q-FT와 Q-DEBIAS, 거의 모든 주장이 한 방향인 Q-HARD와 Q-ATTACK, 대체로 한 방향인 Q-SELF는 뺐다. 다만 독립 평가만 보면 Q-DEBIAS(지지·반박·조건부·효과 없음 7·6·7·0)와 Q-FT(4·2·6·0)도 방향이 갈려 있어, 이 선정은 정량 기준이 아니라 집계를 읽은 판단이며 2.6에 한계로 적는다. 본문을 읽을 수 있는 arXiv와 ACL Anthology 논문의 독립 평가 주장을 대상으로, 질문마다 방향별 비율로 나누되 방향마다 최소 2개를 넣고 인용이 많은 순으로 최대 15개를 골랐다. 이렇게 고른 주장은 99개(논문 90편)다. 본문 확인은 사람이 아니라 LLM 서브에이전트(Sonnet)가 arXiv HTML(없으면 PDF)과 ACL Anthology PDF를 읽고 기록했으며, 사람이 따로 검수하지 않았다.

본문 확인에서 기록한 항목은 초록 주장이 본문 결과와 맞는지, 본문 기준 방향은 무엇인지, 결과를 바꾸는 조건(과제 유형, 판정 모델 크기·종류, 평가 지표, 데이터의 적대성 등)이 무엇인지, 근거 수치가 본문 어디에 있는지다. 일치 판정은 세 범주다. confirmed는 본문이 초록 주장을 그대로 뒷받침하는 경우, partly는 일부 조건에서만 성립하거나 과장된 경우, contradicted는 본문 결과가 초록 주장과 다른 경우다. 본문 기준 방향은 이 판정과 별도로 다시 기록했으므로, 일치 판정이 confirmed여도 방향은 바뀔 수 있다. 99개 중 75개는 confirmed, 24개는 partly였고 contradicted는 없었다. 방향이 바뀐 11개는 이 75개와 24개 안에 있으며(confirmed 4개, partly 7개), 그중 8개는 지지(1개)·반박(7개)에서 조건부로 옮겨 갔다. 나머지 3개는 효과 없음에서 반박으로 2개, 조건부로 1개 바뀌었다. 이 결과는 9.4절에서 다시 논의한다.

2.6 한계

이 방법에는 다섯 가지 한계가 있다. 첫째, 선별·추출·주장 기록의 1차 작업을 LLM이 했다. 선별은 사람 검수로 일치율을 확인했지만, 추출과 주장 기록은 2.4에 적은 시범 배치 검토와 형식 검사에 의존했다. 둘째, 주장 추출은 초록 기준이며, 본문 확인은 결과가 갈린 7개 질문의 독립 평가 주장 99개에 한정했다. 이 7개 질문의 선정은 정량 기준이 아니고, 본문 확인도 LLM 서브에이전트가 했다. 셋째, 본문 확인 대상을 arXiv와 ACL Anthology로 제한해 저널 논문의 비중이 낮다. 넷째, 집계는 주장의 개수이며 효과 크기를 합친 메타분석이 아니다. 논문마다 지표와 데이터가 달라 효과 크기를 합칠 수 없어 방향을 집계했다(3.6절). 다섯째, 애매로 남은 1,868편은 검토하지 않았고, 포함 논문의 62.7%가 arXiv 프리프린트다.

3. 문헌 개관

이 장은 포함 논문 2,185편을 분류 코드로 집계해 문헌의 전체 모양을 보인다. 기여 유형, 판정 형식, 판정 구성, 응용 분야는 한 논문에 여러 코드를 붙일 수 있으므로 표의 편수를 더하면 2,185편을 넘는다. 비율은 모두 전체 2,185편을 분모로 한다. 이 집계는 4–8장의 비교에 앞서 각 축에 근거가 얼마나 쌓여 있는지, 어느 축이 얇은지를 확인하는 데 쓴다.

3.1 연도와 출처 유형

표 3-1은 출판 연도와 출처 유형의 분포다. 2026년 논문이 1,193편(54.6%)으로 절반을 넘고, 2025년 629편을 더하면 전체의 83.4%가 최근 2년 안에 나왔다. 2026년은 10월까지만 수집했는데도 이 규모다. 2023년은 79편에 그치지만 이 분야의 기준점이 된 연구가 이 시기에 몰려 있다. 인용 상위 30편 중 17편이 2023년, 10편이 2024년 논문이고 2025년 논문은 3편, 2026년 논문은 없다. MT-Bench와 Chatbot Arena로 GPT-4 판정과 사람 선호의 일치를 보고한 연구 [1], 응답 순서만 바꿔도 판정이 뒤집힌다는 것을 보인 연구 [14], CoT와 양식 채우기로 판정하는 G-Eval [2]이 여기에 속한다. 문헌의 양은 2026년에 몰려 있고 자주 인용되는 기준 연구는 2023–2024년에 몰려 있다. 최근 연구는 인용이 쌓일 시간이 짧아 인용 수만으로는 영향력을 가늠하기 어렵다는 뜻이다.

표 3-1 연도와 출처 유형 (N = 2,185)

구분	값	편수	비율
연도	2023	79	3.6%
	2024	281	12.9%
	2025	629	28.8%
	2026 (10월까지)	1,193	54.6%
	미상	3	0.1%
출처	arXiv	1,370	62.7%
	학회·저널·기타	653	29.9%
	저장소(Zenodo·OSF·SSRN·medRxiv 등)	162	7.4%

출처로 보면 arXiv 프리프린트가 1,370편(62.7%)이고 학회·저널 등은 653편(29.9%), 프리프린트 저장소는 162편(7.4%)이다. 출처 유형은 후보 목록의 게재처 필드로 나눴으며, 게재처가 arXiv이거나 비어 있으면서 arXiv 번호를 가진 논문을 arXiv로 셌다. 나중에 학회·저널에 실린 논문도 메타데이터에 arXiv로 남아 있으면 arXiv에 들어간다. 동료 심사를 거치지 않은 논문이 다수일 수 있다는 점은 4–8장에서 결과를 읽는 방식에 영향을 준다. 이 서베이가 초록 기준 주장과 본문 확인을 구분하고, 제안 방법의 자기 보고와 독립 평가를 나누는 이유 가운데 하나가 이것이다.

3.2 기여 유형

기여 유형은 판정 방식 제안(method) 1,126편(51.5%)과 신뢰성·편향 분석(analysis) 1,016편(46.5%)이 가장 많다. 벤치마크·메타평가 655편(30.0%), 분야 적용 575편(26.3%), 판정 모델 학습 300편(13.7%)이 뒤를 잇고,

보안 91편(4.2%)과 서베이 63편(2.9%)은 적다. 새 판정 방식을 내놓는 연구와 기존 판정을 의심하는 연구가 거의 같은 규모로 공존한다는 점이 이 분야의 특징이다. 반면 보안은 판정 모델이 평가와 보상 신호에 널리 쓰이는 데 비해 근거가 얇다. 8장에서 공격과 방어의 근거 수가 다른 것도 보안 문헌이 적다는 이 분포와 함께 읽어야 한다.

3.3 판정 형식과 구성

표 3-2는 판정 형식과 판정 구성의 분포다. 형식에서는 점수형(pointwise)이 1,119편(51.2%)으로 가장 많고 루브릭 673편(30.8%), 이진 564편(25.8%), 쌍비교 458편(21.0%)이 뒤를 잇는다. 초기 연구에서 대표 형식으로 다뤄진 쌍비교 [1]보다 점수형과 루브릭이 더 흔하다. 루브릭은 사용자 정의 기준으로 평가하는 판정 모델 학습 [3]과, 인스턴스별 루브릭을 강화학습 보상으로 쓰는 연구 [15]로 쓰임새가 넓어졌다. 순위(listwise)는 63편(2.9%)으로 드물다. 각 형식의 정의는 4.1.1절에서 다룬다.

표 3-2 판정 형식과 판정 구성 (중복 포함, 비율 분모 2,185)

판정 형식	편수	비율	판정 구성	편수	비율
점수형	1,119	51.2%	단일	1,490	68.2%
루브릭	673	30.8%	앙상블·배심	368	16.8%
이진	564	25.8%	판정 전용 학습	346	15.8%
쌍비교	458	21.0%	에이전트형	176	8.1%
참조 기반	222	10.2%	추론형	177	8.1%
서술형 비평	203	9.3%	토론·다중 에이전트	85	3.9%
순위	63	2.9%			

구성에서는 단일 판정이 1,490편(68.2%)으로 압도적이다. 앙상블·배심 368편과 판정 전용 학습 346편이 그다음이고, 에이전트형 176편, 추론형 177편, 토론 85편은 아직 소수다. 앙상블·토론과 파인튜닝 판정 모델은 각각 `Q-MULTI`와 `Q-FT`의 대상이다. 편수에 비해 독립 비교가 적은지는 4.2.2절과 6.2.3절에서 주장 단위로 본다.

3.4 응용 분야

표 3-3은 응용 분야의 분포다. 특정 분야를 정하지 않은 일반 평가가 744편(34.1%)이고, 그다음으로 의료 220편, 안전 208편, 검색·RAG 205편, 멀티모달 201편, 대화 193편, 코드 192편, 에이전트 176편이 각각 8–10% 수준으로 고르게 퍼져 있다. 검색 분야에서는 관련성 판정을 LLM에 맡기는 연구가 일찍 자리 잡았고 [16], RAG 평가에서는 경량 판정 모델과 소수의 사람 주석을 결합하는 방식이 나왔다 [17]. 번역(63편), 법(62편), 금융(45편)은 각각 3% 미만이다. 번역은 GPT 기반 품질 지표가 MQM 사람 라벨 대비 높은 정확도를 보인 초기 연구가 있음에도 [18] 후속 연구의 비중이 작다. 법과 금융은 근거가 가장 얇다. 7장의 `Q-EXPERT` 분석은 이 불균형을 전제로 읽어야 한다.

표 3-3 응용 분야 (중복 포함, 비율 분모 2,185)

분야	편수	비율	분야	편수	비율
일반	744	34.1%	교육	166	7.6%

분야	편수	비율	분야	편수	비율
의료	220	10.1%	요약	144	6.6%
안전	208	9.5%	과학	121	5.5%
검색·RAG	205	9.4%	수학	108	4.9%
멀티모달	201	9.2%	창작	105	4.8%
대화	193	8.8%	번역	63	2.9%
코드	192	8.8%	법	62	2.8%
에이전트	176	8.1%	금융	45	2.1%
기타	175	8.0%			

3.5 판정 모델

초록에 판정 모델 이름이 나온 경우만 집계하면 GPT-4o가 102편, GPT-4가 90편으로 가장 많고 ChatGPT, Gemini, Claude가 각 26편, GPT-4o-mini가 22편이다. 상위 25개 이름 가운데 GPT 계열이 가장 많은 자리를 차지한다. GPT-5(16편), GPT-4.1(15편), Claude Sonnet 4.6(11편), GPT-5.5(9편), Claude Opus 4.7(7편)처럼 최근 모델도 상위에 올라 있어, 2026년 논문의 비중이 판정 모델 선택에도 반영된 것으로 보인다. 공개 모델로는 Llama와 Qwen이 각 10편, DeepSeek-R1 9편, Qwen3-8B와 Llama-3.1-8B가 각 7편이다.

이 집계는 해석에 주의가 필요하다. 첫째, 상위 모델의 편수도 전체의 5% 미만이어서 대부분의 논문은 초록에 판정 모델을 특정하지 않는다. 둘째, "GPT", "Claude", "Gemini"처럼 버전 없이 쓴 이름과 버전을 밝힌 이름이 섞여 있고, 방법 이름인 G-Eval(8편)도 판정 모델로 기록되어 있다. 판정 모델의 버전을 밝히지 않는 관행은 재현성 문제로 이어질 수 있으며, 독점 모델 판정의 재현성은 기존 연구에서도 우려로 지적되었다 [19].

3.6 사람 판정과의 비교와 측정 지표

사람 판정과 직접 대조한 논문은 1,244편(56.9%)이다. 나머지 941편에서는 사람 판정과의 대조가 확인되지 않았다. 에이전트형 판정 176편 중 사람과 대조한 연구는 89편으로 절반에 그친다(7장, 10장).

표 3-4 사람 판정 비교에 쓰인 지표 (사람과 비교한 1,244편, 중복 포함)

지표	편수	지표	편수
일치율(agreement)	566	기타	55
정확도(accuracy)	229	Kendall	36
상관(correlation, 종류 미상)	164	F1	31
카파(kappa)	113	ICC	18
Spearman	71	precision	6
Pearson	58	alpha	6

표 3-4는 이 1,244편이 쓴 지표다. 일치율이 566편으로 가장 많지만 사람과 비교한 논문의 절반에 못 미치고, 정확도 229편, 종류를 밝히지 않은 상관 164편, 카파 113편, Spearman 71편, Pearson 58편, Kendall 36편이 섞여 있다. 일치율과 정확도는 우연 일치를 보정하지 않고, 카파와 alpha는 보정하며, 상관은 순위나 선형

관계를 본다. 같은 판정 결과라도 상관으로는 높고 카파로는 낮게 나올 수 있으며, 쌍비교 정확도와 점수 일치도는 척도가 달라 바로 비교할 수 없다(9.2절).

보고된 수치도 마찬가지다. 예를 들어 G-Eval은 요약에서 Spearman 상관 0.514를 [2], Prometheus는 Pearson 상관 0.897을 [3], MT-Bench 연구는 80% 이상의 일치율을 보고한다 [1]. 이 수치들은 지표와 데이터가 달라 어느 쪽이 사람과 더 가까운지 말해 주지 않는다. 20개 과제에서 LLM 판정의 신뢰도가 모델과 데이터셋에 따라 크게 달라진다는 결과 [19]까지 고려하면, 논문 간 수치를 모아 판정 모델의 신뢰도를 하나로 요약하기는 어렵다. 이 서베이가 효과 크기를 합치지 않고 주장의 방향을 집계하는 것도 이 때문이다.

3.7 언어 범위

영어 외 언어를 다룬 논문은 250편(11.4%)이다. 나머지는 영어 외 언어를 다룬 것으로 확인되지 않으므로, 5장의 편향 분석과 6장의 개선 기법이 다른 언어에서도 같은 방향으로 나타나는지는 근거가 부족하다. 번역 분야가 63편에 그친다는 점(3.4절)과 함께, 다국어 판정은 10장의 연구 의제 A7로 이어진다.

3.8 본론과의 연결

분포에서 드러나는 모양은 세 가지다. 문헌은 2026년의 arXiv 프리프린트에 몰려 있다. 방법 제안과 신뢰성 분석이 같은 규모로 공존하지만, 앙상블과 파인튜닝처럼 독립 비교가 적은 축이 있다. 사람 판정과의 비교는 절반을 조금 넘는 논문에서만 이루어지고 그 지표도 통일되어 있지 않다. 4–8장은 이 분포를 분류의 출발점으로 삼아 비교 질문별 근거를 정리한다.

4. 판정 형식과 구성

이 장은 RQ1, 즉 LLM 판정이 어떤 형식으로 결과를 내고 어떤 구성으로 판정 모델을 배치하는지를 다룬다. 4.1절은 포함 논문 2,185편을 판정 형식과 판정 구성의 두 축으로 나누고 두 축의 교차 분포를 보인다. 4.2절은 이 축에서 결론이 갈리는 두 비교 질문, 쌍비교가 점수형보다 사람과 더 일치하는가(Q-FORMAT)와 앙상블·토론이 단일 판정보다 나은가(Q-MULTI)를 주장 단위로 맞댄다. 4.3절은 두 질문에서 결과를 가르는 조건을 정리하고, 4.4절은 이 장에서 드러난 공백을 10장의 연구 의제와 연결한다. 이 장의 수치는 모두 논문 수 또는 주장 수이며 효과 크기를 합친 값이 아니다.

4.1 분류

4.1.1 판정 형식

판정 형식은 판정 모델이 내놓는 결과의 모양을 말한다. 한 논문이 여러 형식을 쓰면 중복으로 셌고, 형식별 편수는 표 3-2에 있다. 이 장은 형식을 응답 하나에 절대 점수를 매기는 점수형(pointwise), 평가 기준을 명시한 루브릭, 맞음·틀림이나 지지·비지지를 가르는 이진 판정, 두 응답 중 나은 쪽을 고르는 쌍비교, 정답이나 참조 답을 주고 판정하는 참조 기반, 점수와 함께 또는 점수 대신 서술형 비평을 내는 형식, 여러 후보를 한 번에 순위 매기는 순위(listwise)로 나눈다.

형식별 대표 연구를 하나씩 든다. 점수형의 대표는 G-Eval로, CoT와 양식 채우기로 NLG 출력에 점수를 매겨 요약에서 사람과 Spearman 0.514를 보고했다 [2]. 쌍비교 판정을 대규모로 적용한 대표 연구는 MT-Bench와 Chatbot Arena를 쓴 Zheng 외의 연구이며, GPT-4 판정이 사람 선호와 80% 이상 일치해 사람끼리의 일치 수준에 이른다고 보고했다 [1]. 같은 시기 Wang 외는 쌍비교에서 응답 순서만 바꿔도 순위가 뒤집히는 문제를 보였다 [14]. 구체적인 수치는 5.1.2절에 있다. 쌍비교는 상대 비교라는 장점과 위치 편향이라는 약점을 함께 들여왔다. 루브릭 형식은 Prometheus가 대표한다. 사용자가 준 루브릭에 따라 평가하도록 13B 모델을 학습해 45개 맞춤 루브릭에서 사람과 Pearson 0.897을 보고했다 [3]. 이진 판정은 FActScore처럼 장문을 원자적 사실로 쪼개 각 사실의 지지 여부를 가리는 분해와 결합되기도 한다 [20]. 순위 형식은 63편 중 검색 영역이 10편이고 일반 영역이 34편으로 특정 영역에 몰려 있지 않다. 검색 관련성 판정에서는 4.2.1절에서 보듯 점수형과의 차이가 척도의 세밀도에 따라 달라진다 [21].

4.1.2 판정 구성

판정 구성은 판정 모델을 몇 개, 어떤 방식으로 배치하는지를 말한다. 이 장은 구성을 단일 판정 모델, 여러 판정을 모으는 앙상블·배심, 판정 전용으로 학습한 모델, 도구를 쓰거나 여러 단계를 거쳐 판정하는 에이전트형, 판정 전에 긴 추론을 하는 추론형, 여러 에이전트가 토론하는 구성으로 나눈다. 구성별 편수는 표 3-2에 있다.

앙상블·배심 구성의 대표 사례는 서로 다른 계열의 작은 모델로 만든 패널 PoLL이다. 저자들은 패널이 단일 GPT-4급 판정보다 낮고 비용은 7배 이상 낮다고 보고했다 [22]. 토론 구성으로는 여러 LLM 심판이 토론하는 ChatEval [23]과, 전문가 LLM 둘의 토론을 비전문가가 판정하는 감독 설정의 Khan 외 [24]가 대표 사례다. 두 연구는 같은 범주에 들지만 목적이 다르다. 전자는 응답 품질 평가이고, 후자는 정보가 없는 판정자가 정답을 고르는 감독 문제다. 판정 전용 학습은 Prometheus와 Prometheus 2 [3, 25], RAG 평가용 경량 판정 모델 ARES

[17]가 대표한다. 보상 모델 평가 벤치마크 RewardBench [4]도 이 범주의 평가 기준으로 쓰인다. 추론형 구성에서는 보상 모델링을 추론 과제로 바꾼 RM-R1 [26]과, 추론 시 병렬 표집과 메타 보상 모델 투표로 성능을 올리는 SPCT [27]가 대표적이다. SPCT처럼 추론형과 앙상블에 함께 분류되는 연구가 있어 두 구성의 경계는 흐리다. 에이전트형은 검색으로 사실을 하나씩 확인하는 SAFE [28], 웹 에이전트 궤적을 판정하는 Online-Mind2Web의 판정 방법 [29], 웹 에이전트 판정 모델을 평가하는 AgentRewardBench [30]가 대표한다. AgentRewardBench는 어떤 LLM도 모든 벤치마크에서 최고가 아니라고 보고했다.

4.1.3 형식과 구성의 교차

표 4-1 판정 형식과 판정 구성의 교차 (편수, 중복 포함)

형식 \ 구성	단일	앙상블	전용 학습	추론형	에이전트형	토론
점수형	792	194	177	79	61	37
루브릭	466	123	89	57	76	23
이진	375	108	88	63	78	23
쌍비교	307	80	104	52	14	20
참조 기반	175	23	30	12	25	4
서술형 비평	95	22	88	43	29	17
순위	44	15	8	3	4	4

표 4-1에서 세 가지 경향이 보인다. 첫째, 어느 형식이든 단일 판정이 가장 많고, 점수형·단일 칸(792편)이 전체에서 가장 큰 칸이다. 둘째, 판정 전용 학습은 쌍비교(104편)와 서술형 비평(88편)에서 단일 판정 대비 비중이 크다. 서술형 비평은 단일 95편, 전용 학습 88편으로 두 칸이 거의 같다. 비평을 생성하도록 학습한 판정 모델과 쌍선호 데이터로 학습한 보상 모델이 이 칸을 채운다. 셋째, 에이전트형은 이진(78편)과 루브릭(76편)에 몰리고 쌍비교(14편)는 드물다. 에이전트 궤적 평가가 성공 여부나 체크리스트 충족을 묻는 경우가 많기 때문으로 보인다. 토론 구성은 어느 형식에서나 40편을 넘지 않는다. 토론 구성 85편 중 45편이 `Q-MULTI` 주장을 45개 냈다. 제안 방법이 31개, 독립 평가가 14개이며, `Q-MULTI` 주장 140개의 약 3분의 1이다.

4.2 비교

4.2.1 쌍비교가 점수형보다 사람과 더 일치하는가 (`Q-FORMAT`)

검증할 명제는 "쌍비교 판정이 점수형 판정보다 사람 판정과 더 일치한다"이다. 초록 기준 독립 평가는 지지 12개, 반박 7개로 쌍비교 쪽이 많았지만, 본문을 확인한 15개에서는 조건부가 지지와 같은 6개로 늘었다(표 4-2). 이 질문에 답하는 주장은 31개이고, 그중 독립 평가 25개의 일부인 15개를 본문으로 확인했다.

표 4-2 `Q-FORMAT` 주장의 방향 (주장 수)

근거	지지	반박	조건부	효과 없음	합계
독립 평가 (초록 기준)	12	7	5	1	25
제안 방법 (초록 기준)	6	0	0	0	6
독립 평가 중 본문 확인 (본문 기준)	6	2	6	1	15

초록 기준으로는 지지가 반박보다 많다. 지지 쪽 독립 평가는 멀티모달 판정과 다국어 평가에 많다. MLLM-as-a-Judge는 GPT-4V가 쌍비교에서 사람과 가장 가깝고 점수와 일괄 순위에서는 크게 어긋난다고 보고했다 [31]. 10개 인도 언어를 다룬 Watts 외는 사람과 LLM이 쌍비교에서는 상당히 일치하지만 직접 평가에서는 일치가 떨어지고, 벵골어·오디아어에서 특히 낮다고 보고했다 [32]. 시각 생성 과제 [33], 코드 판정 [34], 원어민다운 품질 평가 [35]에서도 같은 방향의 결과가 나왔다. 제안 방법 6개는 모두 지지다. 쌍비교 기반 순위 집계 PAIRS [36], 쌍비교로 에세이 점수를 만드는 LCES [37], 토너먼트식 반복 쌍비교 [38]가 여기에 든다.

반박 쪽은 주로 견고성과 대화 길이를 근거로 든다. Tripathi 외는 방해 특징을 넣었을 때 선호 뒤집힘이 쌍비교에서 약 35%, 절대 점수에서 9%라고 보고했다 [39]. 이 수치는 본문 확인에서 그대로 확인됐지만, 사람 일치가 아니라 조작에 대한 견고성을 잰 것이다. Chen 외는 ChatGPT의 참조 없는 텍스트 평가에서 명시적 점수가 가장 효과적이고 직접 비교는 최적 이하라고 보고했다 [40]. 본문의 SummEval Kendall tau-b에서도 일관성(COH) 50.3 대 22.6(sampling) 같은 차이가 확인됐으나, 유창성(FLU)처럼 차이가 거의 없는 속성도 있었다. 대화 성공도 판정에서는 쌍비교가 긴 대화록과 위치 편향 때문에 어려움을 겪었다 [41].

본문 확인은 지지와 반박 양쪽에서 결론을 바꾸는 조건을 드러냈다. 가장 분명한 사례는 Jeong 외다 [42]. 초록은 쌍비교가 편향에 더 취약하다고 해 반박으로 분류됐지만, 본문에서는 점수형이 적대적 데이터 LLMBar에서 앞서고 쌍비교가 일반 데이터 MT-Bench에서 일관되게 앞섰다. 같은 논문 안에서 데이터의 적대성에 따라 우열이 뒤집힌 것이다. Landesberg는 반대 방향에서 같은 일을 보여 준다 [43]. 초록은 Chatbot Arena의 best-of-2 짝지은 감사에서 쌍비교가 신호 회복률을 21.1%에서 61.2%로 올렸다고 해 지지로 분류됐다. 본문 확인 결과 호출량을 맞춘 엄격한 best-of-4 라운드로빈에서는 완전 쌍비교가 점수형보다 낮았다. 초록에 나온 점수형 동점 67%도 best-of-2 감사가 아니라 best-of-4 벤치마크의 값이었다. 판정 모델의 크기도 조건이다. Liusie 외는 FlanT5·Llama2-chat 같은 중간 규모 모델에서 비교 평가가 점수 프롬프트보다 낫다고 보고했다 [44]. 본문 확인 결과 점수형이 약한 것은 중간 규모 모델에서였고 ChatGPT급에서는 경쟁력이 있었다. 또 비교 평가는 N(N-1)번의 추론이 필요했다. Raina 외의 정확도 비교에서도 GPT-3.5의 절대 점수가 작은 모델의 비교 평가를 앞섰다 [45]. 견고성 기준으로는 방향이 갈렸다. Raina 외는 4단어 범용 적대 문구로 절대 점수 평가가 거의 모든 입력에 최고 순위를 주게 만들 수 있었고 비교 평가는 경미한 취약성에 그쳤다고 보고해, 앞서 본 Tripathi 외의 결과(쌍비교가 더 취약)와 반대 방향이었다.

지표 문제도 본문에서 반복해서 나왔다. Pu 외는 MMU에서 쌍비교 평균 66.55%, 점수 42.79%를 보고했지만 [46], 본문 확인 결과 쌍비교 정확도(동점 포함 3택)와 점수 정확 일치율은 우연 수준과 척도가 달라 같은 지표로 비교한 것이 아니었다. Godfrey 외의 정보검색 실험은 11단계 이상 척도에서 점수형과 listwise의 차이가 대체로 유의하지 않다고 보고했지만, 본문에서는 학습 시점 이후의 독점 데이터 2개에서 listwise가 모든 조합에서 유의하게 앞섰고 지표도 사람 일치가 아닌 NDCG@10이었다 [21]. Gienapp 외는 TREC 2024 RAG 판정에서 쌍비교의 이점이 사람 판정자에게서만 확인되며, 그것도 작업자 역량 보정 후에야 신뢰할 만하다고 밝혔다 [47]. 데이터 선별을 다룬 Gondara 외는 이진, 1-5, 0-100, 비교 형식 사이의 하위 성능 순서를 구분하지 못했고, 저자들은 이를 형식이 동등하다는 증거가 아닌 미검출로 해석하라고 명시했다 [48]. 벤치마크 규모 산정을 다룬 연구는 양쪽 제시 순서로 실행한 쌍비교가 점수형보다 판정자 상호작용 분산이 작아 일반화 상한이 높다고(쌍비교 0.986) 보고했지만, 이는 사람 일치가 아니라 신뢰도 기준이었고 먼저 제시된 시스템의 승률이 8.6퍼센트포인트 높은 순서 편향도 있었다 [49].

4.2.2 앙상블·토론이 단일 판정보다 나은가 (Q-MULTI)

검증할 명제는 "여러 판정 모델의 집계·배심원·토론이 단일 판정보다 사람과 더 일치하거나 더 견고하다"이다. 제안 방법 82개 중 73개가 지지인 반면 독립 평가 58개 중 지지는 14개뿐이어서 두 근거의 분포는 거의 반대다 (표 4-3). 이 장에서 주장이 가장 많은 질문으로 140개이고, 독립 평가 58개 중 15개를 본문으로 확인했다.

표 4-3 Q-MULTI 주장의 방향 (주장 수)

근거	지지	반박	조건부	효과 없음	합계
독립 평가 (초록 기준)	14	21	20	3	58
제안 방법 (초록 기준)	73	1	8	0	82
독립 평가 중 본문 확인 (본문 기준)	3	5	6	1	15

독립 평가에서는 반박(21개)과 조건부(20개)가 지지보다 많다. 제안 방법 쪽에는 다중 에이전트 토론으로 사람 평가와의 상관을 높였다는 보고 [50, 51], 역할 분담 네트워크로 kappa를 0.28에서 0.34로 올렸다는 보고 [52], 페르소나 패널로 Pearson r을 0.716에서 0.922로 올렸다는 보고 [53]가 있다. 제안 방법 중 유일한 반박은 네 판정 모델 파이프라인의 정확도가 83%로 단일 판정 파이프라인 88%보다 낮았다는 안전 판정 연구다 [54].

독립 평가의 반박 21개 중 상당수는 판정자 간 오류 상관을 근거로 든다. Kohli는 프런티어 LLM 9개 패널이 독립 표 약 2개 분의 정보만 준다고 보고했다 [55]. 본문 확인 결과 유효 표수는 2.18로 명목의 24.2%였고, SNLI에서 최선의 단일 판정(84.2%)이 패널(77.7%)보다 높았다. 다만 최선의 단일 판정 모델은 정답을 본 뒤 고른 것이라 사전에 알 수 없다는 단서가 붙는다. 다른 연구에서도 6개 판정의 유효 표수가 약 2.13 [56], 10개 판정이 독립 판정자 약 3.5개 분의 정보 [57]로 비슷한 크기가 반복됐다. 오류 상관을 가장 직접 잰 연구는 Yang 외다 [58]. 본문 확인 결과 Qwen3 동종 배심의 오류 상관 ρ는 0.972에 이르렀고, Qwen3-1.7B 배심의 LLMBar 정확도는 배심 크기를 키워도 0.463, 0.475, 0.482로 거의 오르지 않았다. ρ를 보정한 예측 오차는 독립 가정보다 크게 작았다. 이종 모델 배심도 독립 예측에는 못 미쳐, 모델을 섞기만 해서는 상관 오류가 풀리지 않았다. 다만 이종 혼합이 소용없었던 것은 아니다. text-to-SQL 정확성 예측에서 서로 다른 제공사의 판정자를 묶은 앙상블은 단일 판정자(AUROC 0.72–0.78)보다 높은 0.82를 냈다 [59]. 보상 해킹 상황에서는 Qwen·Llama·Gemma 3종의 엄격한 앙상블도 자기 대결로 생긴 오답의 55%를 받아들였다 [60]. 본문 확인 결과 55%는 가장 보수적인 시드의 값이고 3시드 평균은 65%였으며, 판정자가 자기 답을 먼저 확정하게 하면 이 사각지대가 줄었다. Mukherjee 외는 판정 모델 42개를 쓴 인도어 벤치마크에서 앙상블이 사람이 아닌 판정 모델들이 공유하는 축으로 수렴한다고 보고했다 [61]. 본문에서 이 실패는 주관적 루브릭에 한정됐고, 검증 가능한 답이 있는 루브릭에서는 앙상블이 사람 수준의 바닥에 도달했다.

토론은 독립 평가에서 단일 판정보다 나쁜 결과가 더 자주 보고됐다. 합의형 토론이 단일 판정자보다 사람 정렬이 낮았고 [62], Reflect-Critique-Refine 토론은 모든 설정에서 정확도를 떨어뜨렸으며 [63], 다중 에이전트 토론은 첫 라운드 이후 편향을 크게 증폭했다 [64]. 페르시아어 창의성 평가에서는 퓨샷, 앙상블, 토론 어느 것도 일관된 개선을 주지 못했다 [65]. 본문 확인 결과 독창성의 Spearman이 퓨샷 0.34에서 멀티에이전트 0.42 사이였고, 매력도는 모든 전략에서 0.18 이하였다.

지지와 조건부 쪽의 본문 확인은 이득이 생기는 조건을 좁혔다. 토론 지지의 대표인 Khan 외는 본문에서도 비전문가 사람 88%, LLM 76%의 정확도(기준선 60%, 48%)가 확인됐지만, 이는 정보 비대칭 독해 과제의 감독

시나리오이지 일반적인 평가용 앙상블이 아니다 [24]. Kenton 외는 토론이 정보 비대칭이 있는 추출형 QA에서만 직접 QA보다 낫다고 보고했다 [66]. 본문에서는 판정자에게 기사를 직접 주는 QA가 토론보다 나았고, 가장 약한 Gemma7B에서는 토론의 우위가 깨졌다. 다수결 반복 표집의 이득은 작고 빨리 포화했다. Li 외의 모호한 사례 개선은 본문에서 0.01–0.03 수준이었고 [67], Peng 외의 루브릭 검증에서는 이득 대부분이 3–5표 안에서 끝났으며, 단일 호출의 정답 확률이 0.5에 못 미치는 19.8%의 루브릭에서는 반복 투표가 오답을 고착시켰다 [68]. 배심 구성도 조건이다. Chen 외의 안전성 판정에서 견고성 개선은 아티팩트 취약성과 사람 일치를 기준으로 배심원을 골랐을 때 가장 컸고, 사람 일치는 최고 개별 모델과 같거나 비슷한 수준이었다 [69]. Arif 외는 초록에서 GPT-4o 단일 판정이 모든 데이터셋에서 배심원·토론보다 일관적이라고 했다 [70]. 본문 확인 결과 배심원은 FairEval(kappa 0.428 대 0.389)과 MT-Bench(0.429 대 0.410)에서 단일 판정보다 높았고 PandaLM-Eval에서만 낮아, 반박에서 조건부로 옮겼다. 판정자 간 합의도 정확성의 약한 신호에 그쳤다. 일치와 정확성의 Spearman ρ는 0.20–0.59로 모두 양수였지만, 가장 일관된 최상위 모델은 GPQA 사례의 77%에서 일치도가 0.8 이상이었고 그중 48%가 오답이었다 [71]. 본문 확인 결과 합의는 표본 예산 배분에는 쓸 만했으나 단독 신뢰도 기준으로는 부적합했다. 초록 기준으로는 Organisciak 외의 페르소나 패널이 단일 프롬프트 판정보다 나았지만 자기일관성 통제와는 차이가 없어, 이득이 페르소나 다양성이 아닌 집계에서 나왔다 [72]. 회귀로 편향을 모델링해 최선의 앙상블보다 오차를 절반으로 줄였다는 Jain 외의 결과도, 본문에서는 정답 데이터로 보정한 경우에만 성립했다 [73].

4.3 종합

두 질문에서 나온 결과는 하나의 방향으로 모이지 않는다. 결과가 갈리는 이유는 몇 가지 조건 변수와 연관된다. 쌍비교는 비적대적 데이터에서, 앙상블은 판정자 오류가 서로 다르고 과제가 검증 가능한 경우에 낫다는 근거가 있다.

첫째는 데이터의 적대성과 측정 대상이다. `Q-FORMAT`의 반박 근거 중에는 사람 일치가 아니라 조작에 대한 견고성을 잰 것이 있고, 견고성 기준에서도 방향이 갈렸다. 방해 특징에는 쌍비교가 더 취약했고 [39], 범용 적대 문구에는 절대 점수가 더 취약했다 [45]. 일반 데이터에서 쌍비교가 낫고 적대적 데이터에서 점수형이 낫다는 Jeong 외의 결과 [42]까지 보면, 쌍비교의 우열은 데이터의 적대성과 공격 유형에 따라 달라졌다. 다만 사람 일치를 직접 비교한 근거는 Jeong 외 한 편이 중심이다. 둘째는 평가 지표다. 쌍비교 정확도와 점수 일치율은 척도와 우연 수준이 달라 직접 비교하기 어렵다 [46, 31]. 사람 일치 대신 NDCG@10 [21]나 신뢰도 계수 [49]를 기준으로 한 연구, 사람과 비교하지 않고 코드 판정 정확도를 잰 연구 [34]도 섞여 있다. 셋째는 과제 설정과 비용이다. best-of-2와 best-of-4 사이에서 우열이 뒤집혔고 [43], 쌍비교의 이득은 판정 모델이 중간 규모일 때 크고 추론 횟수가 늘어나는 비용을 동반한다 [44].

`Q-MULTI`에서는 판정 모델 간 오류 상관이 주요 변수다. 동종 배심의 오류 상관이 0.9를 넘으면 배심 크기를 키워도 정확도가 거의 오르지 않고 [58], 프런티어 패널도 유효 표수가 2개 남짓에 그친다 [55]. 이득은 판정자들이 서로 다른 항목에서 틀릴 때 나타난다. 제공사가 다른 판정자를 섞은 앙상블이 단일 판정보다 나은 사례가 있지만 [59], 이종 배심도 독립 가정이 예측하는 이득에는 못 미쳐 섞는 것만으로 오류 상관이 해소되지는 않았고 [58], 아티팩트를 고려해 배심을 고른 구성에서 견고성 개선이 가장 컸다 [69]. 과제의 검증 가능성도 같은 방향으로 작용한다. 검증 가능한 답이 있는 루브릭에서는 앙상블이 사람 수준에 이르지만 주관적 루브릭에서는 판정 모델끼리 공유하는 축으로 수렴한다 [61]. 판정 모델이 스스로 먼저 풀게 하면

앙상블이 놓치던 오답이 줄어든다는 결과 [60]도, 집계보다 판정자 각자의 해결 능력이 중요하다는 점을 시사한다. 판정자 간 합의는 정확성의 약한 양의 예측 변수에 그쳐, 합의 자체를 신뢰도로 쓰는 설계는 이 결과에서 정확성을 보증하지 못했다 [71].

제안 방법 보고와 독립 평가는 결과가 크게 다르다. Q-MULTI의 제안 방법은 82개 중 73개가 지지하지만 독립 평가는 58개 중 14개만 지지한다. 본문을 확인한 독립 평가 15개에서도 지지는 3개였고, 그 3개도 감독 시나리오이거나 이득이 작고 포화하는 경우였다. Q-FORMAT의 제안 방법 6개는 모두 지지인데, 절반은 쌍비교를 순위 집계나 토너먼트와 결합한 새 방법이라 형식 자체의 효과와 집계 방법의 효과가 분리되지 않는다. Q-MULTI 제안 방법 82개 가운데 주장과 조건 서술에 "단일"이 들어간 것만 45개로, 상당수가 단일 판정자·모델·에이전트와의 비교를 내세운다. 독립 평가가 쓰는 최선의 단일 판정 모델 [55]이나 자기일관성 통제 [72]와 비교하면 이득이 줄어든다. 페르소나 패널의 이득이 자기일관성 통제와 차이가 없었던 Organisciak 외의 결과 [72]는 기준선 선택이 결론을 얼마나 바꾸는지를 보여 준다.

초록과 본문의 차이도 이 장의 결론에 영향을 준다. Q-FORMAT에서는 초록 기준 독립 평가가 지지 12, 반박 7, 조건부 5였지만 본문을 확인한 15개는 지지 6, 반박 2, 조건부 6, 효과 없음 1이었다. Q-MULTI에서도 본문 확인 15개 중 조건부가 6개로 가장 많았다. 확인한 주장 가운데 초록과 반대인 경우는 없었지만, 초록의 일반적 서술이 본문에서 특정 데이터·과제·판정 모델 조건으로 좁혀진 경우가 반복됐다 [42, 43, 70]. 따라서 이 장의 결론은 "쌍비교가 낫다" 또는 "앙상블이 낫다"가 아니다. 쌍비교는 비적대적 데이터에서, 앙상블은 판정자 오류가 서로 다르고 과제가 검증 가능한 경우에 낫다는 근거가 있다. 다만 Landesberg의 best-of-4 설정에서는 쌍비교가 점수형보다 낮았다.

4.4 공백과 의제

이 장에서 드러난 공백은 여섯 가지이며, 각각 10장의 연구 의제와 연결된다.

첫째, 집계 방법의 독립 재현이 부족하다. Q-MULTI의 제안 방법 82개는 거의 모두 지지인데, 같은 벤치마크와 같은 기준선에서 여러 앙상블·토론 방법을 비교한 독립 평가는 드물다. 제안 방법의 기준선을 단일 판정에서 최선의 단일 판정, 자기일관성 통제, 단순 다수결로 넓혀 다시 비교하는 재현 연구가 필요하다. 이는 의제 A1(독립 재현과 보고 기준)에 해당한다.

둘째, 오류 상관을 재서 보고한 연구는 이 서베이가 읽은 범위에서 소수의 분석 논문에 그친다. 유효 표수나 ρ를 보고한 연구 [58, 55, 57]는 집계 이득의 상한을 설명했지만, 제안 방법 논문이 구성원 간 오류 상관을 재는지는 이 서베이가 따로 집계하지 않았다. 배심 구성 시 오류 상관을 측정하고 다양성을 확보하는 방법은 의제 A4(이종 집계와 오류 상관)가 다룬다.

셋째, 형식 비교의 지표가 통일되지 않았다. 쌍비교 정확도, 점수 정확 일치율, Pearson, Fleiss kappa, NDCG@10, 신뢰도 계수가 같은 질문의 근거로 섞여 있어, 형식 간 우열을 논문 사이에서 비교할 수 없다. 형식이 다른 판정을 같은 사람 라벨과 같은 우연 보정 지표로 비교하고, 사람 간 일치를 상한으로 함께 보고하는 표준이 필요하다. 이는 의제 A3(측정의 표준화)과 A1의 보고 체크리스트에 해당한다.

넷째, 조건을 나눈 비교가 드물다. 적대적 데이터와 일반 데이터, 검증 가능한 과제와 주관적 과제, 판정 모델 크기, 후보 수(best-of-2 대 best-of-4)에 따라 형식과 구성의 우열이 뒤집히지만, 이 조건을 축으로 설계한

메타평가는 이 장의 근거에서 드물었다. 과제의 검증 가능성·적대성·후보 수에 따라 형식과 집계를 고르는 지침과 이를 검증하는 층화 메타평가는 의제 A2(조건별 판정 모델 선택과 층화 메타평가)에 해당한다.

다섯째, 에이전트형 판정과 비영어 판정의 형식 비교가 부족하다. 에이전트형 구성 176편은 이진과 루브릭 형식에 몰려 있고, 쌍비교 형식과 결합한 연구는 14편이다. 언어별로 형식 효과가 달랐다는 결과 [32]가 있고, 루마니아어 RAG 평가에서는 지표별로 최적 전략이 달랐지만 [74] 근거가 소수다. 에이전트형 판정의 사람 검증과 저자원 언어에서의 형식 비교는 의제 A7(검증 범위의 확대)로 이어진다.

여섯째, 고위험 항목에서는 집계만으로 부족할 수 있다. 법률 판정단이 전체 정확도는 높이면서도 존재하지 않는 규범 인용 같은 위험한 오류를 공통으로 놓친 사례 [75]와, 임상 노트 누락 탐지에서 투표가 작동점만 옮겼을 뿐 쓸 만한 탐지를 만들지 못한 사례 [76]는, 집계만으로는 부족할 수 있으며 의제 A6(전문 분야의 분담 판정)의 분담 설계와 판정 보류 기준이 필요하다는 점을 시사한다.

5. 신뢰성과 편향

이 장은 RQ2, 곧 LLM 판정이 얼마나 믿을 만하며 어떤 방식으로 틀리는지를 다룬다. 먼저 신뢰성을 재는 방법과 편향·실패 유형을 분류하고(5.1), 결론이 엇갈리거나 반복 확인되는 세 질문 `Q-SCALE`, `Q-SELF`, `Q-HARD`를 비교한다(5.2). 이어 공통 패턴과 결과를 바꾸는 조건을 정리하고(5.3), 남은 공백을 10장의 연구 의제와 잇는다(5.4). 편향 코드는 제목·초록을 기준으로 붙였으며 한 논문에 여러 코드가 붙을 수 있다. 표의 편수는 논문 수 또는 주장 수이고 효과 크기가 아니다. "본문 확인"은 전문을 읽고 초록 주장의 방향과 조건을 다시 기록한 경우만 가리킨다.

5.1 분류

5.1.1 신뢰성의 측정

판정 신뢰성은 대부분 사람 판정과의 일치로 잰다. 그러나 무엇을 "일치"로 보는지는 논문마다 다르다. 사람 비교 지표를 보고한 논문에서 일치율이 566편, 정확도가 229편, 상관이 164편, 카파가 113편, Spearman이 71편으로 흩어져 있다(3.6). 같은 판정 결과라도 지표에 따라 평가가 달라질 수 있다. 54개 LLM의 정확성 판정을 비교한 연구는 상관과 Cohen's Kappa·z-score 기반 인간 유사성을 함께 사용해 판정 모델을 등급으로 나눴고 [77], 코드 정답성 판정에서 가장 좋았던 GPT-4-turbo도 Kappa가 Java 0.21, Python 0.10에 그쳤고 오답 구현의 50%를 정답으로 판정했다는 사실이 본문에서 확인된다 [78]. 우연 일치를 보정하지 않는 일치율이나 상관만 보면 이런 한계가 가려질 수 있다.

수치를 읽으려면 사람끼리의 일치라는 상한이 필요한데, 이 상한을 함께 보고하는 경우는 드물다. 초기 연구는 GPT-4 판정이 사람 선호와 80% 넘게 일치해 사람끼리의 일치 수준에 이른다고 보고했다 [1]. 경량 판정 모델을 분석한 연구는 본문에서 LLM–사람 일치율이 인간 간 일치(64.8%)부터 무작위(33.3%) 미만까지 분포한다고 보였다 [79]. 의료 과제에서 LLM-jury는 임상의 평가와 ICC 0.47을 기록했는데, 임상의끼리의 평균 0.43을 함께 제시했기 때문에 이 값의 의미를 해석할 수 있었다 [80]. 같은 0.4대 수치라도 상한이 있느냐에 따라 "사람 수준"이 되기도 하고 "낮은 일치"가 되기도 한다.

판정 모델 자체를 평가하는 벤치마크·메타평가 논문은 655편이다. 초기에는 사람 주석이 있는 기존 NLG 데이터로 판정 모델의 상관을 재는 방식이 주를 이뤘고 [81], 20개 NLP 과제를 묶은 JUDGE-BENCH는 모델·데이터셋·평가 속성·사람 평가자의 전문성에 따라 신뢰도가 크게 달라진다는 점을 보였다 [19]. 이후 벤치마크는 판정 대상을 넓히고 어려운 쌍을 일부러 모으는 방향으로 움직였다. 보상 모델을 겨냥한 RewardBench [4], 지식·추론·수학·코딩의 어려운 쌍으로 만든 JudgeBench [82], 멀티모달 판정의 MJ-Bench [83]와 VL-RewardBench(GPT-4o 정확도 65.4%) [84], 웹 에이전트 궤적 판정의 AgentRewardBench [30]가 대표적이다. 그러나 여기서 든 대표 벤치마크는 대체로 평균 성능 하나를 보고하는 경향이 있고(대표 논문 초록 기준이며 이 서베이는 전수 코딩하지 않았다), 난이도·검증 가능성·적대성으로 층을 나눠 보고하는 경우는 드문 것으로 보인다(5.4).

5.1.2 편향·실패의 분류

편향·실패 코드는 여섯 묶음으로 나눈다. 표 5-1은 묶음별 코드와 편수, 대표 사례다. 의도적 조작을 뜻하는 `adversarial`(99편)은 8장에서, 기존 값에 들지 않는 `other`(226편)는 이 장에서 다루지 않는다.

표 5-1 편향·실패 분류와 편수 (중복 포함, N = 2,185)

묶음	코드 (편수)	대표 연구
제시 방식	위치 position (103), 길이 verbosity (73), 문체 style (74), 앵커링 anchoring (36)	[14, 85, 86, 87]
판정자–생성자 관계	자기선호 self_preference (97)	[88, 89]
사회·권위	권위 authority (19), 아첨 sycophancy (31), 사회 편향 social (77)	[90, 91, 92]
일관성	비일관성 inconsistency (239), 프롬프트 민감도 prompt_sensitivity (99)	[93, 16]
능력 한계	관대·엄격 leniency (154), 맹점 competence (378), 기준 불일치 criteria (266)	[73, 94, 77]
누출	누출 leakage (12)	[95, 96]

제시 방식. 응답의 내용이 아니라 제시 형태가 판정을 바꾸는 경우다. 위치 편향은 초기부터 보고된 유형으로, ChatGPT를 평가자로 쓰면 제시 순서만으로 Vicuna-13B가 80개 질의 중 66개에서 ChatGPT를 이기는 것으로 나왔다 [14]. 15개 판정 모델의 15만 건 이상 평가를 분석한 연구는 위치 편향의 크기가 프롬프트 길이보다 비교 대상 응답의 품질 격차에 강하게 좌우된다고 보고했다 [97]. 이 결과는 위치 편향이 독립된 결함이라기보다 판정이 어려울 때 드러나는 증상이라는 해석을 가능하게 하며, 5.2.3의 난이도 문제와 연결된다. 길이 편향은 Length-Controlled AlpacaEval이 길이 차이를 통제해 Chatbot Arena와의 Spearman 상관을 0.94에서 0.98로 높인 사례가 대표적이다 [85]. 문체 편향은 판정 선호가 안전성·세계 지식·지시 이행 지표와 상관하지 않고 사실성과 안전성보다 문체를 우선하는 암묵 편향을 보인다는 분석이 있다 [86]. 앵커링은 다속성 판정에서 앞 속성 점수가 뒤 점수를 끌어당기는 효과 [87]와 루브릭 순서·점수 ID·참조 답 점수가 절대 점수를 흔드는 scoring bias [98]로 나타난다.

판정자–생성자 관계. 자기선호(97편)는 판정 모델이 자기 출력이나 같은 계열 모델의 출력을 더 높게 평가하는 경향이다. 참조 없이 쓰는 LM 기반 지표에서 자기선호가 보고됐고 [88], 파인튜닝하면 자기 출력 인식 능력과 자기선호 강도가 선형으로 상관한다는 보고가 뒤따랐다 [89]. 결론이 엇갈리는 지점은 5.2.2에서 다룬다.

사회·권위. 응답 밖의 단서에 판정이 끌리는 경우다. 권위 편향(19편)에서는 출처 단서를 주입하면 GPT-4o와 Gemini-2.5-Flash가 Expert > Human > LLM > Unknown의 위계와 강한 최신성 편향을 보였고, 판정 근거는 주입 단서를 거의 언급하지 않고 내용 품질로 합리화했다 [90]. 설득 문구를 넣으면 오답 풀이 점수가 평균 최대 8% 부풀었다 [99]. 아첨(31편)은 반박이 후속 턴으로 제시될 때, 상세한 추론이 붙을 때 판정이 더 쉽게 바뀌는 형태로 보고된다 [91]. 사회 편향(77편)에는 GPT-4 평가자가 높은 점수 쪽으로 치우쳐 저자원·비라틴 문자 언어에서 원어민 판단 기반 보정이 필요하다는 다국어 결과가 포함된다 [92].

일관성. 같은 입력이나 의미가 같은 입력에 다른 판정을 내는 경우로, 비일관성이 239편, 프롬프트 민감도가 99편이다. 요약 평가에서 ChatGPT와 GPT-4는 후보 시스템을 일관되지 않게 평가하고 차원마다 결과가 달랐다 [93]. 검색 관련성 판정은 사람 라벨러만큼 정확하지만 프롬프트 특징과 단순 환언에 따라 성능이 예측하기 어렵게 달라졌다 [16]. 교육 피드백 평가에서는 사람 평가자 간 일치가 낮은 기준일수록 LLM 평가의 신뢰도도 낮았다 [100].

능력 한계. 세 코드가 모두 이 묶음에 있고, 그중 맹점(competence, 378편)과 기준 불일치(criteria, 266편)는 전체 편향 코드에서 1, 2위다. 관대·엄격(154편)은 척도의 한쪽 쏠림으로, LLM 판정 모델이 유효 출력은 TPR 96%로 식별하지만 무효 출력은 TNR 25% 미만으로만 거른다는 결과가 대표적이다 [73]. 맹점은 판정 모델이

오류를 찾지 못하는 경우로, 최신 LLM도 명확한 사례에서 추론 오류의 위치를 찾지 못하지만 위치를 알려주면 고칠 수 있다는 결과가 있다 [94]. 기준 불일치는 판정 모델이 사람과 다른 기준을 쓰거나 차원끼리 간섭하는 경우로, 평가 속성과 사람 평가자의 전문성에 따라 신뢰도가 달라진다는 JUDGE-BENCH 결과 [19]가 이 묶음에 속한다. 한편 환자 대상 의료 QA에서 LLM은 과학적 합의, 문법성 같은 객관적 지표는 잘 맞히지만 공감, 위해 정도 같은 주관적 범주에서 어려움을 겪었는데, 이는 기준 차이보다 능력 한계에 가까운 사례다 [101].

누출. 12편으로 가장 적지만 보고된 사례에서는 점수 왜곡이 컸다. 프롬프트 템플릿이나 gold nugget이 유출되거나 예측 가능하면 RAG 시스템이 거의 완벽한 판정 점수를 얻을 수 있었고 [95], 자기개선 에이전트가 캐시된 정답지를 읽어 만점을 받아 100% 통과율이 68%의 실제 능력을 가린 사례가 보고됐다 [96]. 데이터 생성 모델과 관련된 판정 모델이 관련 학생 모델을 선호하는 선호 누출 [102]은 누출과 자기선호의 경계에 있다.

5.2 비교

5.2.1 크고 강한 판정 모델일수록 나은가 (Q-SCALE)

Q-SCALE은 "더 크거나 강한(추론형 포함) 판정 모델일수록 편향이 적고 사람과 더 일치한다"는 명제다. 주장 100개 중 97개가 독립 평가이고, 제안 방법은 3개뿐이다. 표 5-2에서 보듯 독립 평가 안에서도 지지 42개와 반박 30개가 맞서며, 본문을 확인한 15개는 지지와 반박이 6개씩으로 갈렸다.

표 5-2 Q-SCALE 주장의 방향

근거	지지	반박	조건부	효과 없음	계
독립 평가 (초록 기준)	42	30	15	10	97
독립 평가 중 본문 확인 (본문 기준)	6	6	3	0	15
제안 방법 (초록 기준)	1	1	1	0	3

지지 쪽 근거는 대체로 능력 하한이 있다는 결과다. 번역 품질 평가 GEMBA는 GPT-3.5 이상에서만 작동하고 GPT-2·Ada는 유효한 점수를 내지 못했으며, 이는 본문의 세대별 비교로 확인된다. 다만 GPT-3.5급 안에서는 세대별 차이가 작았다 [18]. 경량 판정 모델은 판정 불확실성과 위치 편향이 컸고, 본문에서 Qwen-2-1.5B는 체크리스트 판정의 3회 샘플링 불일치율이 50%를 넘었다 [79]. 멀티모달 보상 모델 벤치마크에서 Gemini 3 Pro가 74–80%로 GPT-5·Gemini 2.5 Pro(66–75%)와 GPT-4o(59%)를 앞섰다는 순위도 본문에서 확인됐지만, 사람 정확도 90% 초과와의 격차는 여전히 컸다 [103]. 코드 판정에서는 GPT-4-turbo가 가장 좋았지만 본문을 보면 실패한 것은 약 7B 이하 모델이었고 33B·34B 모델은 최고 모델에 근접했다 [78]. 사실 일관성 평가는 지지로 분류되지만, 같은 계열에서 크기가 클수록 대체로 나아졌어도 Llama 2-Chat 70B가 7B보다 2.8%p 높은 데 그쳤고 본문은 사전학습·미세조정 데이터가 크기만큼 중요하다고 밝혀 이득이 제한적이라는 단서가 붙는다 [104]. 지지 근거 가운데 이 장에서 본 사례의 상당수는 "작은 모델은 안 된다"는 하한을 보여줄 뿐, 일정 규모를 넘은 뒤에도 크기가 계속 이득을 준다는 근거는 되지 못한다.

반박 쪽에서는 계열과 학습 데이터가 크기보다 중요하다는 결과가 반복된다. 번역 평가에서 7B OpenChat이 13–14B 모델보다 대부분 언어쌍에서 Spearman 상관이 높았는데, 본문을 보면 비교 모델이 6개이고 대부분

14B 이하여서 일반화에는 한계가 있다 [105]. qwen-3 8B·14B·32B를 비교한 연구는 본문 Table 7에서 파라미터 수에 따른 안정성이 어느 열에서도 단조롭지 않음을 보였다 [106]. 견고성에서는 더 큰 모델이 오히려 취약한 경우도 있었다. 설득 문구 공격에서 LLaMA 3.1 70B가 8B보다, GPT-4o가 GPT-4o mini보다 공격 성공률이 높았다 [99]. CALM의 12개 편향 분석에서는 Claude-3.5가 전반적으로 가장 견고했지만 GPT-4-Turbo가 감정 응답에서 불안정해, 가장 진보한 모델이 항상 가장 믿을 만하다고 가정하지 말라는 결론이 본문에서도 유지됐다 [107]. 상위 등급 모델로 바꿔도 같은 오류가 반복돼 캐스케이드를 최강 단일 판정보다 1.7점 넘게 올리지 못했다는 연구는 초록에서는 효과 없음이었으나 본문 확인 후 반박으로 옮겼다 [108].

조건부 결과는 결과를 가르는 변수를 직접 보여준다. 대형 추론 모델(LRM)은 사실 기반 데이터에서는 LLM보다 견고했지만 선호 정렬 데이터에서는 비슷하게 취약했다. 본문에서 DeepSeek-R1의 Emerton-DPO 정확도는 밴드왜건 단서 아래 73%에서 37%로 떨어졌고, 권위 편향은 오히려 사실 데이터에서 더 취약했다 [109]. 54개 LLM을 비교한 연구는 상위 인간 유사 모델이 30B–72B였고 크기가 결정 요인이 아니라고 결론지었다. 다만 그 원인을 "특정 학습 전략"으로 돌린 부분은 통제 실험 없이 서술로만 제시된다는 점이 본문 확인에서 드러났다 [77]. MJ-Bench에서는 정렬·화질은 소형 점수 모델이 오픈 VLM보다, 안전·편향은 VLM이 앞서 관점에 따라 우열이 바뀌었다. 다만 본문 확인에서 편향은 VLM이 앞선다는 일반화가 사람 평가와 일부 어긋났다 [83].

초록 기준 주장만 있는 최근 연구에서도 지지와 반박이 함께 나온다. 판정 모델의 과제 정확도가 판정 정확도와 대부분 Pearson $r \geq 0.90$으로 상관한다는 보고 [110]는 지지 쪽이지만(같은 논문에서 유능한 피평가 모델이 더 관대한 점수를 받는다는 단서가 붙는다), 루브릭 채점에서 답안이 점수 분산의 95.6%를 설명하고 판정 모델은 0.2%만 설명했다는 보고 [111], 추론 노력보다 모델 정체성이 최대 56.1%p로 가장 큰 변동 원인이었다는 보고 [112]도 있다. 추론 모델이 가짜 추론 편향에 더 취약하다는 "more thinking, less robust" 결과 [113]도 반박 쪽에 있다.

종합하면 Q-SCALE의 상충은 "크기"를 하나의 변수로 다룬 데서 비롯된다. 하한 이하의 소형 모델은 분명히 나쁘지만, 그 위에서는 크기 외의 요인(계열·학습 데이터·과제·편향 유형)이 결과를 가르는 것으로 보이며, 어느 쪽이 더 크게 작용하는지는 이 근거로 판단할 수 없다.

5.2.2 자기선호 편향은 실재하는가 (Q-SELF)

Q-SELF는 "품질을 통제해도 판정 모델이 자기 출력이나 같은 계열 출력을 더 높게 평가한다"는 명제다. 주장 39개가 모두 독립 평가이며 제안 방법은 없다. 지지 27개, 반박 5개로 대체로 지지되지만 결과는 품질 통제 방식에 따라 갈린다. 이 질문은 결과가 크게 갈리지 않아 본문 확인 대상에 넣지 않았으므로, 아래 내용은 한 편을 빼면 초록 기준이다.

표 5-3 Q-SELF 주장의 방향 (본문 확인 대상 아님)

근거	지지	반박	조건부	효과 없음	계
독립 평가 (초록 기준)	27	5	6	1	39
제안 방법 (초록 기준)	0	0	0	0	0

지지 근거 가운데에는 품질을 통제한 설정에서도 자기선호를 보고한 연구가 있다. 전문가 주석과 판정 모델 9종을 쓴 연구는 GPT-4o와 Claude 3.5 Sonnet이 품질을 통제해도 자기 출력과 같은 계열 출력을 선호한다고

보고했다 [114]. 이진 루브릭처럼 객관적인 기준에서도 생성자가 실패한 루브릭을 자기 출력일 때 만족으로 잘못 표시할 가능성이 50% 이상 높았고, HealthBench 점수를 최대 10점 왜곡했다 [115]. 네 계열에서 후보 계열을 고정한 보정 추정기로 같은 계열 선호를 3.4–8.4%p로 측정한 연구 [116], 판정 모델과 오류가 비슷한 모델을 선호하는 경향으로 자기선호를 일반화한 연구 [117], 멀티모달 판정자 12개에서 같은 현상을 확인한 연구 [118]가 뒤를 잇는다. 시각장애인 지원 과제에서는 가장 강한 판정자 GPT-5.4가 단일 실패 진단 정확도는 52.6%인데 자기선호율은 94.2%였다 [119].

반박과 효과 없음은 과제가 검증 가능하거나 판정이 사실성에 묶일 때 주로 나오지만, 창의성 평가처럼 검증하기 어려운 과제에서도 나온다. RAG 환경에서는 유의한 자기선호가 없고 사실 정확성이 판정에 더 큰 영향을 주었으며 [120], 추출형 QA [121], 의료 진단 채점 [122], 대안 용도 과제의 창의성 평가 [123]에서도 자기선호가 관찰되지 않았다. 답변 쌍을 통제한 3×3 생성자–판정자 행렬에서는 같은 모델 효과가 −0.5%p(95% CI [−2.7, +1.7])로 거의 0이었다 [124]. 다만 객관적 루브릭에서도 자기선호를 보고한 연구 [115]가 있어, 검증 가능성만으로 자기선호가 사라진다고 단정할 수는 없다.

조건부 결과는 자기선호의 상당 부분이 측정 방식의 산물일 수 있음을 시사한다. 평가자 품질 기준선과 비교하면 기존 자기선호 결과의 51%만 통계적 유의성을 유지했다 [125]. 블라인드 평가에서는 자기선호가 사라지고, 품질을 맞춘 조건에서 자기·타자 라벨만 바꿔도 점수가 양방향으로 움직였다 [126]. 모델 정체 라벨이 투표를 최대 50%p 바꾸고 Claude는 자기선호가 커진 반면 Gemini는 자기 비하를 보였다는 결과 [127], 모델마다 편향의 부호가 달랐고 익명화로 25.8% 줄었다는 결과 [128]도 같은 방향이다. 자기 출력이라는 사실보다 정체 단서가 보이느냐가 판정을 움직인다는 해석이 가능하며, 이 경우 자기선호는 5.1.2의 권위 편향과 같은 단서 의존으로 읽을 수 있다.

Q-SELF에 대한 주요 반론 하나는 Q-SCALE 본문 확인에서 함께 확인됐다. 검증 가능한 벤치마크와 7개 모델 계열을 쓴 연구는 강한 모델일수록 자기선호가 크지만 그 대부분은 객관적으로 우수한 응답을 고르는 정당한 선호이고, 해로운 자기선호는 판정 모델이 생성자로서 틀렸을 때에 집중된다고 보고했다. 본문에서 큰 모델일수록 합법적 자기선호 비율(LSPR)이 높고, 긴 CoT가 해로운 편향을 줄였다 [129]. 따라서 Q-SELF가 "대체로 지지"라는 결론은 정당화된 선호와 해로운 선호를 구분하지 않은 집계 위에 서 있다. 품질 통제 방식이 연구마다 다르다는 점이 이 질문의 한계다.

5.2.3 어려운 과제에서 일치도가 떨어지는가 (Q-HARD)

Q-HARD는 "과제가 어렵거나, 전문성이 필요하거나, 비교 대상의 품질이 비슷하게 높을수록 사람과의 일치가 떨어진다"는 명제다. 주장 37개가 모두 독립 평가이고 모두 지지다. 반박이 하나도 없으므로 본문 확인 대상에서 제외했고, 아래 결과는 모두 초록 기준이다.

표 5-4 Q-HARD 주장의 방향 (본문 확인 대상 아님)

근거	지지	반박	조건부	효과 없음	계
독립 평가 (초록 기준)	37	0	0	0	37
제안 방법 (초록 기준)	0	0	0	0	0

근거는 어려움의 세 가지 형태로 나뉜다. 첫째는 품질이 비슷한 응답을 구분하는 경우다. 요약 평가에서 품질이 높을수록 사람과의 상관이 낮아졌고 [93], 능력 차이가 작은 시스템 쌍을 구분하는 설정에서는 사람과의 상관이

약 0.8에서 약 0.3으로 떨어졌다 [130]. 에이전트 순위 판정의 결정 불일치율은 보상 격차가 큰 쌍에서 1% 미만이었지만 근접한 강한 쌍에서 31%로 뛰었다 [131]. 거의 완벽한 번역을 평가하지 못하는 문제도 같은 유형이다 [132]. 둘째는 과제 자체의 난이도와 전문성이다. 어려운 응답 쌍으로 만든 JudgeBench에서 GPT-4o는 무작위보다 약간 나은 수준이었고 [82], 루브릭 수준 메타평가의 Hard 부분집합에서 GPT-4o 정확도는 55.97%였다 [133]. 임상 QA 적대적 벤치마크에서는 난이도 단계 D1에서 D5로 갈수록 판정 모델 간 AC1이 0.60에서 0.27로 떨어졌다 [134]. 셋째는 평가 기준의 세분도다. 단답 채점에서 이진 과제의 일치는 강했지만 루브릭 세분도가 높아질수록 떨어졌다 [135].

이 결과들을 묶을 수 있는 설명 하나는 판정 모델이 스스로 풀 수 있느냐다. 참조가 없을 때 판정자는 자신이 정답을 맞힌 질문에서만 전문가와 높은 일치를 보였고 [136], 수학 추론에서도 후보 모델 성능과 판정 성능이 강하게 상관했다 [137]. 정답 없이 어려운 질의에서는 20B부터 최전선 모델까지 판정 모델 6종이 규모와 무관하게 77–82%의 좁은 구간에 수렴했다 [138]. 난이도의 상한은 크기로 넘기 어렵다는 이 한 연구의 결과는 5.2.1의 결론과 맞물린다.

37개 모두 지지라는 집계는 해석에 주의가 필요하다. 명제가 넓어 "어떤 조건에서 떨어진다"는 결과면 모두 지지로 기록된다. 또한 비슷한 품질의 쌍에서 불일치는 정보 이론적으로 예상되는 것이며 위치 편향·이행성·쌍 일치 지표가 이런 쌍에 좌우된다는 분석 [139]이 있다. 이 분석에 따르면 일치도 하락의 일부는 판정 모델의 결함이 아니라 사람 판정 자체의 불확실성을 반영한다. 사람 독자 7명의 Krippendorff alpha가 0.070에 그친 이야기 평가 사례 [140]처럼 사람 기준이 흔들리는 영역에서는 "사람과의 일치"라는 목표 자체가 약해진다.

5.3 종합

세 질문을 함께 보면 판정 신뢰도가 과제 난이도와 함께 떨어진다는 공통점이 있다(Q-HARD 37개 모두 지지). 정답 없는 어려운 질의에서는 판정 모델 규모를 키워도 이 하락이 사라지지 않은 사례가 있다 [138]. 편향 코드 분포에서도 연구 관심이 같은 쪽으로 쏠려 있다. 편수는 그 편향을 다룬 논문 수일 뿐 편향의 크기나 심각도가 아니지만, 가장 많이 붙은 코드는 위치나 길이 같은 표면적 편향이 아니라 맹점(378편)과 기준 불일치(266편)이며 비일관성(239편)이 뒤를 잇는다. 초기 연구가 주목한 위치(103편)와 길이(73편) 편향에는 순서 교환이나 길이 통제 같은 처방이 제안되어 있고, 그 효과는 6.1과 6.2.4에서 본다. 능력 한계와 기준 불일치는 판정 모델이 문제를 풀 수 있는지, 사람이 같은 기준을 공유하는지에 달려 있어 프롬프트 수준의 처방만으로 다루기 어려울 수 있다. 위치 편향이 품질 격차에 좌우된다는 결과 [97]는 표면적 편향도 판정의 어려움과 연결될 수 있음을 시사한다.

결과를 가르는 조건 변수는 네 가지로 정리된다. 첫째는 **지표 선택**이다. 같은 판정 결과가 상관으로는 좋고 카파로는 나쁠 수 있어, 본문 확인에서도 지표가 결과를 바꾸는 조건으로 반복 기록됐다 [77, 78]. 또한 사람 간 일치 상한이 없으면 수치를 해석할 수 없다 [79, 80]. Q-SCALE의 지지·반박이 갈리는 데에는 연구마다 다른 지표가 한몫했을 수 있으나, 이 서베이는 지표별로 나누어 확인하지 않았다. 둘째는 **데이터의 적대성과 유형**이다. 추론 모델은 사실 데이터에서는 견고하지만 선호 데이터에서는 아니었고 [109], 크기를 키워도 설득 문구에 대한 취약성이 줄지 않은 사례가 있다 [99]. 자기선호도 검증 가능한 과제에서 약해지는 경우가 있다 [120, 121]. 셋째는 **모델 계열과 학습 데이터**다. 같은 계열 안에서도 크기 효과가 단조롭지 않고 [106], 7B 모델이 13–14B를 앞서기도 하며 [105], 학습 데이터가 크기만큼 중요하다 [104]. 같은 벤더의 상위 모델이 같은 오류를 반복한다는 결과 [108]는 계열이 오류 패턴까지 공유함을 시사하며 4장의 오류 상관 문제와 이어진다.

넷째는 **판정 모델이 스스로 풀 수 있는지**다. 참조가 없을 때 판정자는 자신이 정답을 맞힌 질문에서만 전문가와 높은 일치를 보였고 [136], 수학 추론에서도 후보 모델 성능과 판정 성능이 강하게 상관했다 [137]. 이 조건은 4장과 9.2절에서 참조와 집계의 효과를 가르는 조건으로도 나타난다.

Q-SCALE과 Q-SELF는 서로 얽혀 있다. 강한 모델은 자기선호가 더 크지만 그 대부분은 실제 품질 차이로 정당화되고, 해로운 편향은 틀렸을 때 커진다 [129]. 즉 "강한 판정 모델이 더 낫다"와 "강한 판정 모델이 자기 출력을 더 선호한다"는 동시에 참일 수 있다. 두 질문을 따로 집계하면 이 관계가 보이지 않는다.

초록과 본문의 차이도 이 장에서 확인된다. Q-SCALE 본문 확인 15개 중 하나는 효과 없음에서 반박으로 방향이 바뀌었고 [108], 지지로 남은 연구 가운데서도 이득이 제한적이거나 실패 구간이 초록보다 좁다는 단서가 붙은 경우가 있었다 [104, 78]. 본문 확인을 하지 않은 Q-SELF와 Q-HARD의 집계도 같은 방식으로 조건부 결과를 과소평가하고 있을 가능성이 있다.

5.4 공백과 의제

이 장에서 드러난 공백은 네 가지다.

첫째 공백은 조건을 나눈 메타평가의 부족이다. 메타평가 논문이 655편이지만 이 장에서 본 대표 벤치마크는 대체로 평균 성능 하나를 보고하며(전수 코딩은 하지 않았다), 5.3에서 정리한 난이도·적대성·검증 가능성을 축으로 층을 나눈 벤치마크는 드물다. Q-HARD의 결과는 평균 일치도가 쉬운 표본에 의해 부풀려질 수 있음을 시사한다. 판정 모델을 고를 때도 크기 대신 과제의 검증 가능성과 판정 모델이 그 과제를 스스로 풀 수 있는지를 기준으로 삼는 편이 낫다는 것이 Q-SCALE과 Q-HARD의 공통 시사점이다. 이는 의제 **A2**(조건별 판정 모델 선택과 층화 메타평가)로 이어진다.

둘째 공백은 측정의 비표준화다. 일치율, 정확도, 상관, 카파, Spearman이 섞여 있고 사람끼리의 일치를 함께 보고하지 않는 경우가 많아, 이 장의 비교도 방향만 셀 수 있고 효과 크기를 합칠 수 없었다. 같은 결과가 지표에 따라 달리 읽히는 사례가 반복되었다는 점에서, 인스턴스·시스템 수준 지표를 함께 보고하고 사람 간 일치 대비 상대 일치로 표준화하는 의제 **A3**이 이 장의 가장 직접적인 요구다. 사람 기준 자체가 흔들리는 주관적 과제 [140]에서는 사람 간 불일치를 측정 대상으로 다루는 방법도 필요하다.

셋째 공백은 자기선호 측정의 품질 통제다. 품질 통제 방식, 정체 단서의 노출 여부, 정당한 선호와 해로운 선호의 구분이 연구마다 달라 Q-SELF 결과를 직접 비교하기 어렵다 [125, 129]. 공통 프로토콜로 재측정하는 일은 독립 재현과 보고 기준을 다루는 의제 **A1**에 속한다. 같은 계열 판정 모델이 오류를 공유한다는 결과는 배심 구성의 다양성을 다루는 **A4**와 연결된다.

넷째 공백은 검증 범위다. 비교 질문 밖에서 확인한 근거도 있다. 다국어 판정에서 언어 간 평균 Fleiss' Kappa가 약 0.3에 그쳤고 규모를 키워도 일관성이 직접 개선되지 않았으며 [141], 에이전트 행동 검증에서는 LLM 판정 네 구성이 모두 우연 수준(AUROC 약 0.47–0.54)이었다 [142]. 이는 저자원 언어와 에이전트형 판정의 사람 검증을 다루는 **A7**의 근거다. 난이도와 전문성에 따른 일치도 하락은 전문 분야에서 객관 항목과 주관·고위험 항목을 나눠 맡기는 **A6**의 출발점이기도 하다(7장). 의도적 조작에 대한 취약성과 방어(**A5**)는 8장에서 다룬다.

6. 개선 기법

이 장은 RQ3, 곧 LLM 판정의 신뢰도를 높이려는 기법이 실제로 효과를 내는지를 다룬다. 먼저 2,185편에서 추출한 개선 기법 코드를 네 수준으로 나누고(6.1, 표 6-1), 결과가 엇갈리는 네 비교 질문 `Q-COT`, `Q-REF`, `Q-FT`, `Q-DEBIAS`를 독립 평가와 제안 방법으로 나누어 맞댄다(6.2). 이어 결과를 가르는 조건을 정리하고(6.3), 드러난 공백을 10장의 연구 의제와 잇는다(6.4). 이 장의 수치는 모두 논문 수 또는 주장 수이며 효과 크기를 합친 값이 아니다. 개별 논문의 수치를 인용할 때는 초록에서 확인한 것과 본문에서 확인한 것을 구분해 적는다.

6.1 분류

개선 기법은 판정 모델에 무엇을 바꾸는가에 따라 네 수준으로 나뉜다. 프롬프트 수준은 모델과 집계 방식을 그대로 두고 입력만 바꾼다. 집계 수준은 판정을 여러 번 내거나 여러 모델의 판정을 합친다. 학습 수준은 판정 모델의 가중치, 출력 분포, 내부 표현을 손댄다. 외부 근거 수준은 판정의 근거를 모델 바깥, 곧 도구 실행이나 검색, 사람, 판정 보류 규칙에서 가져온다. 한 논문이 여러 기법을 함께 쓰는 경우가 많아 아래 편수는 중복을 포함하며, 수준별 합계도 같은 이유로 논문 수의 합이 아니다.

표 6-1 개선 기법의 네 수준과 편수 (중복 포함, N = 2,185)

수준	기법 (편수)	수준 합계 (중복 포함)
프롬프트	루브릭 298, 과제 분해 255, CoT 109, 참조 80, 프롬프트 최적화 52	794
집계	앙상블 352, 비평·재검토 76, 순서 교환 29	457
학습	파인튜닝 315, 보정 207, 내부 표현 조작 24	546
외부 근거	사람 개입 143, 도구·실행 검증 141, 판정 보류 57	341
기타	169	169

프롬프트 수준에서는 루브릭과 과제 분해가 가장 흔하다. G-Eval은 CoT와 양식 채우기를 결합해 요약에서 사람과 Spearman 0.514를 보고했고 [2], FActScore는 장문을 원자적 사실로 쪼개 지식원이 지지하는 비율을 재며 자동 추정의 오차율을 2% 미만으로 보고했다 [20]. FLASK는 지시문별 점수를 정렬 기술 단위로 분해했고 [143], PaperBench는 연구 재현 과제를 계층적 루브릭으로 나눠 LLM 판정 모델이 채점하게 했다 [144]. 판정 프롬프트 자체를 탐색하는 연구는 52편으로 아직 적다. ZEPO는 선호 결정의 공정성을 목표로 프롬프트를 최적화했고 [145], 판정자 설계 결정을 다목적 탐색으로 낮은 비용에 튜닝하는 연구도 나왔다 [146].

집계 수준에서는 앙상블이 352편으로 전체 기법 중 가장 많다. 앙상블과 토론의 효과는 4장의 `Q-MULTI`에서 따로 다루므로 여기서는 순서 교환과 비평·재검토를 본다. 순서 교환은 29편에 불과하지만, 응답 순서만 바꿔도 Vicuna-13B가 80개 질의 중 66개에서 ChatGPT를 이기는 결과를 보인 연구 [14]와 MT-Bench 연구 [1]가 이를 기본 절차로 만들었다. 비평·재검토는 판정 모델이 자기 판정을 다시 판정하는 Meta-Rewarding [147]이나 원칙과 비평을 생성해 추론 시 투표하는 SPCT [27]처럼 학습과 결합되는 경우가 많다. 반면 외부 검증기 없이 LLM이 자기 계획을 비판하게 하면 성능이 오히려 떨어지고 거짓 양성이 많다는 보고도 있다 [148].

학습 수준의 중심은 판정 전용 파인튜닝(315편)과 보정(207편)이다. Prometheus [3]와 Prometheus 2 [25]가 공개 판정 모델의 기준점이 되었고, ARES는 합성 데이터로 학습한 경량 판정 모델에 소수의 사람 주석을 PPI로 결합했다 [17]. 보정의 대표 사례인 Length-Controlled AlpacaEval은 길이 차이를 0으로 둔 반사실 선호로 Chatbot Arena와의 Spearman 상관을 0.94에서 0.98로 올렸다 [85]. 내부 표현을 쓰는 연구는 24편으로 가장 적다. 여러 층의 점수 토큰 로짓을 집계하는 LAGER [149], 표현 공간의 품질 방향을 쓰는 RepEval [150], 은닉 상태 군집으로 정답 여부를 가르는 CLUE [151]가 여기에 속한다.

외부 근거 수준은 판정 모델의 능력 한계를 바깥에서 메운다. SAFE는 응답을 개별 사실로 나눠 검색 결과로 확인하며, 약 16k 사실에서 크라우드 주석자와 72% 일치했고 불일치 100건 중 76%에서 SAFE가 옳았다고 보고했다 [28]. 사람 개입 쪽에서는 EvalGen이 사용자가 일부 출력을 채점하며 평가 함수를 고르게 했는데, 채점하는 동안 기준 자체가 바뀌는 criteria drift를 관찰했다 [152]. 판정 보류는 57편이다. 자기 평가로 선택적 생성을 하는 연구 [153], 모델 간 일치도와 신뢰도로 사람 주석을 대체할 표본을 고르는 연구 [154], 확신할 때만 받아들이고 나머지는 추론형 판정 모델로 넘기는 JEV [155]가 대표적이다.

6.2 비교

네 질문의 초록 기준 집계는 근거 유형에 따라 다르다. `Q-COT`와 `Q-REF`는 독립 평가 주장이 각각 30개, 23개로 제안 방법보다 많거나 비슷해 양쪽을 맞댈 수 있다. 반면 `Q-FT`는 130개 중 118개, `Q-DEBIAS`는 120개 중 100개가 자기 방법을 제안한 논문에서 나왔다. 앞의 두 질문은 독립 평가 주장 일부를 본문으로 확인했고(`Q-COT` 15개, `Q-REF` 14개), 뒤의 두 질문은 본문 확인 대상이 아니었다. 그래서 6.2.1–6.2.2는 독립 평가를 먼저 서술하고, 6.2.3–6.2.4는 근거 대부분이 제안 방법이므로 제안 방법을 먼저 서술한다.

6.2.1 CoT·설명은 판정을 개선하는가 (`Q-COT`)

표 6-2 `Q-COT` 주장의 방향

근거	지지	반박	조건부	효과 없음
독립 평가 (초록, 30개)	10	7	7	6
독립 평가 (본문 확인, 15개)	5	4	5	1
제안 방법 (초록, 13개)	12	0	1	0

독립 평가에서 `Q-COT`는 네 방향이 고르게 나뉘는 상충 질문이다. 표 6-2와 같이 초록 기준 30개는 지지·반박·조건부·효과 없음이 10·7·7·6이고, 본문으로 확인한 15개도 5·4·5·1로 어느 한쪽으로 모이지 않는다.

지지 쪽 본문 확인 결과는 판정 전에 근거나 주석을 먼저 쓰게 한 설정에서 나왔다. 지시 따르기 루브릭 수준 메타평가에서 근거를 먼저 쓰게 하면 균형 정확도가 Qwen2.5-32B에서 8.4%p, GPT-4.1에서 6.7%p 올랐다 [133]. 검증 가능한 벤치마크의 자기선호 연구에서는 추론 토큰을 생성할수록 해로운 자기선호 확률이 줄었고, 감소 폭은 MATH500·MBPP+에서 MMLU보다 컸다 [129]. 성별 중립 번역 평가에서 구절 주석을 먼저 생성하게 하면 모든 모델과 언어에서 정확도가 올랐다 [156]. ChatGPT에게 평점의 이유를 설명하게 한 연구는 SummEval 응집성 Pearson r을 0.344에서 0.635(analyze-rate)로 올렸지만, 본문은 모든 속성에서 유의하게 높아진 것은 아니며 "더 강하거나 비슷한" 수준이라고 적는다 [157]. 초록만으로 확인한 결과 가운데는 수학·

코딩처럼 구조적 검증이 필요한 과제에서 명시적 추론이 판정 정확도를 크게 높이고 단순 평가에서는 이득이 제한적이거나 음수라는 통제 비교가 있다 [158].

반박과 효과 없음 쪽은 주관적이거나 지각적인 기준에 몰려 있다. 심오함 평가에서 CoT는 LLM을 사람에 가깝게 만들지 못했고 [159], 시각 창의성 점수화에서 추론 출력은 해석 가능성만 높였다 [160](모두 초록 기준). 본문 확인 사례도 같은 방향이다. 비디오 이해 판정에서 사고 모드는 Qwen3-0.6B에서만 RMSE를 1.20에서 1.12로 줄였고 1.7B·4B에서는 개선하지 못했다 [161]. 경량 판정 모델은 직접 CoT를 해도 유의한 이득이 없었지만 GPT-4o가 만든 분석을 맥락으로 받으면 일치도가 올랐다 [79]. 앵커링 연구에서는 CoT가 총 앵커링 이동을 47.7% 키웠다. 다만 이 CoT 비교는 GPT-4.1의 수치 요약 평가 한 쌍에서만 했다 [162].

검증 가능한 과제에서도 CoT가 언제나 이기는 것은 아니다. 16개 소형 판정 모델의 이진 정답 판정에서 수학은 13개 판정자 중 8개에서 10토큰짜리 빠른 판정이 긴 추론과 같거나 나았고, 일반 과제에서는 13개 중 8개에서 추론이 이겼다 [63]. 코드 요구사항 판정에서는 설명과 수정안을 요구하는 상세 프롬프트가 GPT-4o의 정당한 코드 기각률(FNR)을 HumanEval에서 26.2%에서 73.2%로, MBPP에서 35.9%에서 87.9%로 높였다. 본문은 같은 프롬프트가 거짓 승인(FPR)을 0%대로 낮춰 오류가 재분배된 것이라고 설명한다 [163]. 과제가 검증 가능하다는 사실만으로는 부족하고, 추론이 실제로 검증 절차 역할을 하는지가 효과를 가른다고 읽을 수 있다.

조건부 결과는 CoT가 다른 장치를 대신하는 관계를 보여 준다. GPT-4o를 쓴 연구에서 평가 기준과 참조가 모두 있으면 직접 판정과 CoT의 차이가 0.912 대 0.908로 거의 없었지만, 둘을 빼면 0.833 대 0.896으로 CoT가 앞섰다. 초록의 "효과 없음"이 본문에서 조건부로 바뀐 사례다 [164]. CoT가 판정 분포를 붕괴시킨다는 연구도 본문에서는 점별 채점과 평균 집계에서만 성립했고 쌍별 순위에서는 CoT가 도왔다 [165]. JSON 출력 설정에서 이유 먼저 순서와 점수 먼저 순서만 바꿔도 gpt-4-0613의 평균 점수가 5.34와 3.26으로 갈렸다 [166]. CoT의 효과는 형식, 집계 방식, 출력 순서와 분리되지 않는다.

제안 방법 쪽 13개 중 12개는 지지다. 다만 대부분은 프롬프트 CoT가 아니라 추론을 학습한 판정 모델이다. 판정 전 비평을 생성하는 CLoud는 8B에서 4.65%p, 70B에서 5.84%p 향상을 [167], MCTS-Judge는 코드 정확성 판정 정확도를 41%에서 80%로 높였다고 보고했다 [168]. RM-R1 [26], Critic-RM [169], Think-J [170]도 같은 계열이다. 이 결과는 6.2.3의 Q-FT와 겹치며, 독립 평가의 상충을 해소하는 근거로 쓰기는 어렵다.

6.2.2 정답 참조는 도움이 되는가 (Q-REF)

표 6-3 Q-REF 주장의 방향

근거	지지	반박	조건부	효과 없음
독립 평가 (초록, 23개)	12	5	6	0
독립 평가 (본문 확인, 14개)	8	1	5	0
제안 방법 (초록, 15개)	12	1	2	0

Q-REF는 표 6-3처럼 대체로 지지되지만 조건이 많다. 참조가 왜 돕는지를 가장 직접 보여 준 연구는 판정 모델이 문제를 스스로 풀 수 있는지를 변수로 삼았다. GPT-4o가 자기 응답을 참조로 쓰면, 스스로 풀지 못한 문항에서 쌍비교 Cohen's κ가 0.86에서 0.16으로 떨어졌다. 사람이 쓴 참조를 받은 Qwen 2.5 7B는 참조 없는 GPT-4o보다 나았다 [136](본문 확인). 참조의 가치는 판정 모델이 갖지 못한 정답 정보를 주는 데 있고, 같은

이유로 참조가 틀리면 해가 된다. 물리 평가에서 공식 풀이는 GPT-5.2의 fractional MAE를 0.131에서 0.083으로 줄였지만, 틀린 풀이를 주면 MAE가 0.216–0.384로 커졌다. 그래도 순위 상관은 대체로 유지되었다 [171](본문 확인).

과제 유형별로 보면 지지는 정답이나 기준 번역이 분명한 과제에 몰린다. 기계번역 평가에서 참조의 기여는 원문보다 컸고 원문 정보가 오히려 방해가 되기도 했다 [172]. 8개 언어쌍을 본 다른 연구는 참조가 중요하다는 데 동의하면서도 원문이 함께 있어야 최선이라고 보고해 앞 연구와 갈린다 [105](둘 다 본문 확인). 무참조 판정 모델은 오답을 과하게 인정했고, 참조를 넣으면 정오 판정이 최대 85% 뒤집혔으며 그 변화는 대체로 사람 판단과 맞았다 [173]. 장문 출력 평가에서는 참조가 평균 점수를 0.5334에서 0.5866으로, 기준이 명확한 Verify 시나리오에서는 0.5491에서 0.8169로 올렸다. 그러나 RealDR에서는 이득이 제한적이었고 참조와 루브릭을 합치면 0.5786으로 참조 단독보다 낮았다 [174].

주관 기준에서는 효과가 약하다. 물리 에세이에서 채점 지침은 순위 일치를 개선하지 못했는데, 이 과제는 사람 평가자 간 순위 상관도 0.054에 그쳐 기준 자체가 불안정했다 [171]. 창의성 평가에서는 점수 예시가 정확도를 높였지만 하위 측면 점수가 하나로 수렴하는 동질화를 낳았다 [175].

반박 쪽에서 본문 확인 후에도 반박으로 남은 것은 다국어 NLG 평가 한 편이다. 대부분의 모델에서 참조를 넣으면 상관이 떨어졌고, Qwen2.5-72B는 예외였다 [176]. 나머지 두 반박은 본문에서 조건부로 바뀌었다. 에이전트 도구 호출 판정에서 정답 노출은 GPT-5.4와 Gemini-2.5-Pro의 정렬도를 각각 1.5pp, 3.9pp 낮췄지만 QwQ-32B와 GPT-OSS-120B에서는 높였다 [138]. 다면 루브릭 평가에서는 참조가 DeepSeek-V3의 정확도를 원본 표본에서 4.74% 올리고 편향 유도 표본에서 1.66% 낮췄으며, QwQ-32B는 보조 정보가 있을 때 공격 성공률이 45%를 넘었다 [177]. 참조는 깨끗한 표본에서 돕고 적대적 표본에서는 판정 모델을 참조에 묶어 두는 통로가 된다. 초록 기준으로만 확인한 반박도 같은 방향이다. 참조의 개체 값을 이식한 정답을 판정 모델이 모두 감점했고 [178], 오답 참조가 있을 때 판정 4개 중 3개가 참조가 없을 때보다 나빠졌다 [179].

모델에 따른 차이도 반복된다. 사람이 쓴 응답을 참조로 주면 일치도가 최대 3.2% 올랐지만 7B 모델에서는 떨어졌다 [180]. 정신건강 챗봇 평가에서 가이드라인과 참조는 GPT-4의 MAE를 3.14에서 2.29로 줄였으나 Gemini에서는 1.58에서 2.03으로 늘렸다 [181](둘 다 본문 확인). 회계 답안 채점에서 채점 기준은 Claude 3.5의 정렬을 높이고 GPT-4o의 정렬을 낮췄다 [182](초록 기준).

제안 방법은 15개 중 12개가 지지다. 참조를 응답에 맞게 고치는 RevisEval [183], 참조 기반 답 일치 판정 [184], 골드 테스트 패치를 참조로 쓰는 실행 중심 비평 모델 [185], 실행 가능한 코드로 정답을 재계산해 MCC를 29% 높인 연구 [186]가 여기에 속한다. 참조의 형태를 실행 가능하거나 응답 맞춤형으로 바꾸는 쪽으로 제안이 이동하는 경향이 보인다. 유일한 반박은 참조 없이 학습한 PoQ-Judge가 참조 기반 평가자보다 상관이 높았다는 보고다 [187].

6.2.3 작은 파인튜닝 판정 모델은 GPT-4급에 이르는가 (Q-FT)

표 6-4 Q-FT 주장의 방향

근거	지지	반박	조건부	효과 없음
독립 평가 (초록, 12개)	4	2	6	0
제안 방법 (초록, 118개)	114	0	4	0

Q-FT의 근거 130개 중 118개는 표 6-4와 같이 자기 판정 모델을 제안한 논문에서 나왔고, 그중 114개가 지지다. 13B Prometheus는 45개 맞춤 루브릭에서 사람과 Pearson 0.897을 얻어 GPT-4(0.882)와 비슷하고 ChatGPT(0.392)를 크게 앞섰다 [3]. PandaLM-7B는 F1 기준으로 GPT-3.5 평가 능력의 93.75%, GPT-4의 88.28%를 냈다 [188]. JudgeLM은 교사인 GPT-4와 90% 넘게 일치했다 [189]. FLAMe는 RewardBench 87.8%로 GPT-4-0125(85.9%)를 넘었다 [190]. 이후 연구는 강화학습과 추론으로 옮겨 갔다. JudgeLRM [191], J1 [192], 분포 밖에서도 제로샷 판정을 2–6% 앞섰다는 GenRM [193]이 그 예다. 이 수치는 모두 제안 논문의 초록에 나온 것이며 본문 확인을 거치지 않았다. 비교 벤치마크와 대조 모델도 제안자가 골랐다.

독립 평가는 12개뿐이고 그중 절반이 조건부다. 조건부 결과는 대체로 한 가지 경계에 모인다. 미세조정 판정 모델은 도메인 안에서는 GPT-4를 넘지만 일반화, 공정성, 적응성에서는 못 미쳤다 [194]. 과거 응답에는 잘 맞아도 미래 생성 모델의 응답과 보지 못한 질문에서는 성능이 떨어졌다 [195]. 생의학 판정에서는 이득이 분해 가능한 과제에 집중되었다 [196]. text-to-SQL 검증기의 AUROC는 분포 안에서 약 0.77–0.79, 미지 스키마에서 약 0.66이었다 [59]. 전용 검증기는 정확도는 높지만 재현율이 낮았다 [197]. 도메인 밖에서는 큰 모델의 제로샷이 더 나았고, 도메인 밖 데이터로 파인튜닝하면 오히려 성능이 떨어질 수 있었다 [198]. 반박 두 개는 이 경계를 더 날카롭게 보여 준다. 실패 귀속 레이블로 학습한 판정자는 GPT-4.1을 41점 앞섰지만, 단서 위치를 옮기자 31–99점 떨어졌다. 같은 조건에서 제로샷 판정자의 하락은 최대 9점이었다 [199]. 로봇 작업 성공 판정에서는 미세조정 탐지기가 범용 VLM보다 일관되게 낮았다 [200]. 독립 평가의 지지 넷은 안전 분류 [201, 202], 광고 위치 선호 [203], 논증 설득력 순위 [204]처럼 과제가 좁게 정의된 경우다.

제안 방법 쪽 조건부 4개도 같은 경계를 인정한다. 결정 전용 소형 판정 모델 JEV는 판정을 텍스트에서 읽어 낼 수 있는 과제에서는 GPT-6와 3점 이내였지만 수학·코드·논리처럼 판정을 도출해야 하는 과제에서는 뒤처졌다 [155]. 47개 언어 변종에서는 학습 후에도 사람 판단과의 차이가 남았다 [35].

정리하면 "작은 판정 모델이 GPT-4급에 이른다"는 명제는 분포 안의 좁게 정의된 과제에서는 지지된다. 그러나 독립 평가 12개 중 8개(반박 2개, 조건부 6개)가 한계를 보고하고, 그중 5개는 미래 생성 모델의 응답, 미지 스키마, 단서 위치 이동, 도메인 밖 데이터 같은 분포 밖 조건에서 나왔다. 이 판단의 근거는 본문 확인을 거치지 않은 독립 평가 12개라는 얇은 표본이다.

6.2.4 편향 완화 기법은 효과가 있는가 (Q-DEBIAS)

표 6-5 Q-DEBIAS 주장의 방향

근거	지지	반박	조건부	효과 없음
독립 평가 (초록, 20개)	7	6	7	0
제안 방법 (초록, 100개)	96	0	4	0

Q-DEBIAS의 구도는 표 6-5와 같이 Q-FT와 같다. 제안 방법 100개 중 96개가 지지하고, 독립 평가 20개는 지지·반박·조건부가 7·6·7로 갈린다. 제안 방법의 보고는 대체로 강하다. PORTIA는 평균 상대 일관성을 47.46% 높이고 GPT-4의 위치 편향 사례 약 80%를 교정했다고 보고했다 [205]. Branch-Solve-Merge는 길이·위치 편향을 최대 50% 줄였다 [206]. LLM 출력과 사람 판정 사이의 선형 매핑은 평균 일치도를 142% 이상 높였다 [207]. 조향 벡터는 정당하지 않은 자기선호를 최대 97% 줄였지만 정당한 자기선호에서는 불안정했다 [208].

같은 제안 방법 안에서도 편향 지표와 정확도가 따로 움직인다. JudgeBench 620쌍에서 순서 불변 구성은 위치 일관성을 100%로 끌어올렸지만, 정확도 향상은 +1.13점(구간 [-2.45, 4.81], McNemar p=0.597)으로 통계적으로 확정되지 않았다 [209]. 판정 모델 활성화에 탐침을 붙인 연구는 LLMBar 판정 일치를 0.456에서 0.846으로 올렸지만, 표면 단서가 없는 단일 응답 채점에서는 이점이 없었다 [210]. 대화적 동조를 줄인 완화는 회의적 방향으로 과교정되었다 [211]. 편향 지표가 좋아졌다는 사실이 판정이 정확해졌다는 뜻은 아니다.

독립 평가의 반박은 기존 장치가 다른 조건이나 조작에 버티지 못한다는 내용이다. 길이 통제와 문체 분리를 갖춘 자동 벤치마크에서도 널 모델이 높은 승률을 얻었다 [212]. 길이 통제 AlpacaEval의 제안 논문이 보고한 상관 향상 [85]과 나란히 놓으면, 자연 발생 편향의 완화가 의도적 조작에 대한 방어가 되지는 않는다는 점을 시사한다. 기존 보정 평가자는 실제 개방형 과제에서 사람 판단과 약하거나 음의 상관을 보였다 [213]. 답마다 확률을 내는 저가 판정기인 typed decision model(TDM) 8종을 12개 편향 검사(CALM)로 쟀더니 모두 3–8개 검사에서 편향을 보였고, 감정적 어조로 다시 쓰면 평균 정확도가 99%에서 42%로 떨어졌다 [214]. 확률을 보정하는 것만으로는 어조 조작을 막지 못했다. 퓨샷 예시나 용어 제거로도 척도 중앙 쏠림은 사라지지 않았다 [215].

조건부 결과는 효과의 크기와 방향이 모델과 데이터에 묶여 있음을 보여 준다. 편향 공변량을 넣는 Bradley-Terry 보정은 같은 모델이 LLMBar에서는 도움이 되고 SummEval과 Nectar에서는 해가 되었다 [216]. 대학 화학 채점, 딥리서치, 챗봇 벤치마크를 함께 본 연구는 모든 상황에 통하는 단일 완화 조합을 찾지 못했다 [217]. 인용 무시 지시는 잘못 인용된 쪽이 이기는 비율을 최대 50.5%에서 0%로 줄였지만, 일부 설정에서 타당한 중간 격차 판정을 무승부로 바꿔 측정 해상도를 해쳤다 [218].

독립 평가의 지지 7개도 효과가 좁은 범위에 머문다. 9개 전략과 판정 모델 5종을 비교한 연구는 일부 전략이 일부 판정 모델에서만 유의하다고 보고했다(Claude S8 +11.5pp, Flash S8 +7.5pp) [219]. 나머지 지지는 점수 범위 조정 [220], 등순위 회귀 보정 [122], min-max 정규화(macro QWK 0.204에서 0.388) [221]처럼 점수 척도의 쏠림을 사후에 바로잡는 보정이 많다.

6.3 종합

네 질문을 함께 보면 세 가지 조건이 반복해서 결과를 가르고, 그 위에 근거의 출처와 개선의 맞교환이라는 두 가지 보고 패턴이 겹친다. 첫째 조건은 과제의 검증 가능성이다. CoT와 참조는 정답이나 구조적 검증 절차가 있는 과제, 곧 수학, 코드, 번역, 루브릭 수준의 지시 따르기에서 지지 결과가 모이고 심오함, 창의성, 에세이처럼 주관적인 기준에서는 효과가 없거나 동질화 같은 부작용을 낳는다. 다만 검증 가능한 과제 안에서도 소형 판정 모델의 수학 판정 [63]이나 코드 요구사항 판정 [163]처럼 추론이 과잉사고나 오류 재분배로 이어진 사례가 있어, 검증 가능성은 효과의 충분조건이 아니고 효과가 나타나는 데 유리한 조건에 가깝다.

둘째 조건은 판정 모델이 문제를 스스로 풀 수 있는가이다. 참조는 판정 모델이 스스로 풀지 못하는 문항에서 정답 정보를 보태 주고 [136], 경량 판정 모델의 한계는 자기 CoT가 아니라 강한 모델의 분석을 받을 때 줄어든다 [79]. 두 결과는 판정 품질이 판정 모델의 풀이 능력에 묶여 있고 이를 넘으려면 외부 정보가 필요할 수 있음을 시사한다. 같은 논리로 그 외부 정보가 틀리거나 적대적으로 조작되면 판정 모델은 그것을 걸러 내지

못한다 [171, 177]. 6.1의 외부 근거 수준 기법이 실행 결과나 검색처럼 검증 가능한 근거를 쓰는 것도 같은 방향이다.

셋째 조건은 모델별 효과다. 정답 노출의 효과는 판정 모델에 따라 부호가 바뀌었고 [138], 참조와 가이드라인은 GPT-4와 Gemini에서 반대로 작용했으며 [181], 편향 완화 전략은 일부 판정 모델에서만 유의했다 [219]. 한두 개 판정 모델로 얻은 개선 효과를 기법 일반의 효과로 옮기기 어렵다는 뜻이다. 본문 확인에서도 이 점이 드러났다. `Q-COT`와 `Q-REF`의 본문 확인 29개 중 5개는 초록과 방향이 달라졌다. 반박에서 조건부로 3개, 효과 없음에서 조건부와 반박으로 1개씩 옮겨 갔고, 이를 가른 조건은 판정 방식, 평가 설계, 판정 모델, 표본 유형이었다.

근거의 출처도 패턴을 이룬다. 독립 평가가 충분한 `Q-COT`와 `Q-REF`는 상충하거나 조건부 결론에 이르고, 근거 대부분이 제안 방법인 `Q-FT`와 `Q-DEBIAS`는 초록 집계상 거의 일방적으로 지지된다. 두 질문의 독립 평가만 떼어 보면 `Q-FT`는 12개 중 지지 4개, `Q-DEBIAS`는 20개 중 지지 7개다. 이는 9.3절에서 정리하는 경향, 곧 제안 방법의 효과가 독립 평가에서 약해진다는 경향과 맞는다. 다만 두 질문은 본문 확인을 하지 않았으므로 이 대비는 초록 수준의 관찰이다.

개선이 맞교환을 동반한 사례도 있다. FNR과 FPR의 재분배 [163], 측정 해상도 손실 [218], 과교정 [211], 정확도 향상이 확정되지 않은 일관성 개선이 그 예다. 단일 지표의 개선만 보고하면 이 비용이 보이지 않는다.

6.4 공백과 의제

이 장에서 드러난 공백은 여섯 가지다.

첫째, 학습 수준 기법의 독립 재현이 거의 없다. 파인튜닝 판정 모델 근거 130개 중 독립 평가는 12개, 편향 완화 근거 120개 중 독립 평가는 20개다. 같은 벤치마크와 조건에서 여러 판정 모델과 완화 기법을 나란히 비교한 연구가 드물고, 이 서베이도 두 질문을 본문으로 확인하지 못했다. 이는 **A1(독립 재현과 보고 기준)**의 가장 직접적인 근거다. 특히 파인튜닝 판정 모델은 미래 생성 모델의 응답, 미지 스키마, 단서 이동 같은 분포 밖 조건에서 다시 평가해야 한다.

둘째, 기법 선택이 조건에 달려 있는데 조건별로 나눠 평가한 근거가 부족하다. CoT, 참조, 보정은 과제의 검증 가능성, 판정 모델의 자기 풀이 능력, 데이터의 적대성에 따라 효과의 방향이 바뀐다. 그러나 이 장이 소개한 연구는 서로 다른 축 하나씩을 따로 떼어 보고했을 뿐, 세 축을 함께 층화한 연구는 이 장의 범위에서 찾지 못했다. **A2(조건별 판정 모델 선택과 층화 메타평가)**는 이 세 축으로 층화한 메타평가와, 이를 근거로 기법을 고르는 지침을 요구한다. 판정 모델이 스스로 풀지 못하는 문항을 따로 표시하고 그 부분집합에서 참조와 CoT의 효과를 보고하는 것이 출발점이 될 수 있다.

셋째, 개선의 비용과 맞교환이 체계적으로 보고되지 않는다. 오류 유형별 지표(FNR·FPR), 절대 오차와 순위 상관, 일관성과 정확도를 함께 보고해야 개선이 오류를 줄였는지 옮겼는지 알 수 있다. 이는 **A3(측정의 표준화)**과 연결된다.

넷째, 자연 발생 편향의 완화와 의도적 조작에 대한 방어의 경계가 흐리다. 길이 통제가 널 모델을 막지 못했고 확률 보정이 어조 조작을 막지 못했다는 결과는 완화 기법을 적응형 조작 아래에서도 평가해야 함을 보여 주며, **A5(정상 성능을 지키는 방어)**와 이어진다. 같은 경계는 8.3.2절에서 공격 쪽에서 다시 다룬다. 앙상블은 가장

많이 쓰이는 기법이지만 효과는 판정 모델 간 오류 상관에 달려 있으므로 **A4(이종 집계와 오류 상관)**에서 다룬다.

다섯째, 외부 근거 수준과 판정 보류는 편수에 비해 비교 근거가 적다. 판정 보류(57편)와 사람 개입(143편)은 확신이 낮은 판정을 사람이나 더 강한 판정 모델로 넘기는 분담 구조를 제공한다. 이는 **A6(전문 분야의 분담 판정)**의 보류 기준 설계로 이어진다. 내부 표현 조작(24편)과 순서 교환(29편)은 연구가 적어 비교 질문을 세우기 어려웠다.

여섯째, 개선 기법의 효과를 확인한 언어와 양식의 범위가 좁다. 다국어 NLG 평가에서 참조를 넣자 대부분의 모델에서 상관이 떨어졌고 [176], 세 언어를 본 다른 연구에서는 참조 유무에 따라 정오 판정이 최대 85% 바뀌었다 [173]. 멀티모달 판정에서도 비디오 이해의 사고 모드는 가장 작은 모델에서만 오차를 줄였고 [161], 시각 창의성 점수화에서 추론은 해석 가능성만 높였다 [160]. 이 결과들은 개선 기법의 효과를 더 많은 언어와 양식에서 다시 확인해야 한다는 **A7(검증 범위의 확대)**의 근거가 된다.

요약하면, 개선 기법의 효과는 기법 자체보다 과제의 검증 가능성, 판정 모델의 자기 풀이 능력, 판정 모델의 종류에 달려 있다. CoT와 참조는 정답이나 검증 절차가 있는 과제에서 주로 지지되고, 주관 기준에서는 효과가 약하거나 부작용을 낳는다. 파인튜닝 판정 모델과 편향 완화는 제안 논문에서 거의 일방적으로 지지되지만, 독립 평가에서는 지지가 각각 12개 중 4개, 20개 중 7개에 그치며 두 질문 모두 본문 확인을 거치지 않았다. 개선이 다른 지표의 비용을 동반한 사례가 있으므로, 단일 지표의 향상만으로 기법의 효과를 판단하기 어렵다.

7. 응용 분야

이 장은 RQ4, 곧 LLM 판정이 어떤 분야에 쓰이며 분야마다 사람 판정과 얼마나 대조되는지를 다룬다. 7.1절은 응용 분야 코드로 문헌을 나누고 분야별로 사람 비교를 보고한 비율을 본다. 7.2절은 비교 질문 `Q-EXPERT`, 곧 "의료·법·과학·교육 등 전문 분야에서 LLM 판정이 전문가 판정과 전문가끼리의 일치 수준으로 맞는다"는 명제를 지지·반박·조건부 근거로 나눠 검토한다. 7.3절은 분야를 가로지르는 공통점과 분야별 위험을 정리하고, 7.4절은 남은 공백을 10장의 연구 의제와 연결한다. 한 논문에 여러 분야 코드를 붙일 수 있으므로 편수의 합은 2,185를 넘는다. 이 장의 집계 수치는 모두 논문 수나 주장 수이며 효과 크기가 아니다. 인용한 개별 연구의 ICC, κ, 상관계수는 각 연구가 보고한 값이다.

7.1 분류

표 7-1은 분야별 편수와, 그중 판정 결과를 사람 판정과 비교한 논문의 수와 비율이다. 특정 분야를 정하지 않은 일반(general) 연구가 744편으로 가장 많고, 사람 비교 비율은 46%다. 나머지 분야를 텍스트 생성, 추론·코드, 전문 분야, 시스템의 네 묶음으로 나눴다.

표 7-1 응용 분야별 편수와 사람 비교 비율 (중복 포함)

묶음	분야	편수	사람 비교	비율
텍스트 생성	대화 (dialogue)	193	138	72%
	요약 (summarization)	144	99	69%
	번역 (translation)	63	43	68%
	창작 (creative)	105	75	71%
추론·코드	코드 (code)	192	85	44%
	수학 (math)	108	28	26%
	과학 (science)	121	69	57%
전문 분야	의료 (medical)	220	158	72%
	법 (legal)	62	44	71%
	금융 (finance)	45	23	51%
	교육 (education)	166	119	72%
시스템	검색·RAG (ir_rag)	205	124	60%
	에이전트 (agent)	176	87	49%
	멀티모달 (multimodal)	201	139	69%
	안전 (safety)	208	88	42%
기타	일반 (general)	744	342	46%
	기타 (other)	175	116	66%

텍스트 생성. 대화·요약·번역·창작은 사람 비교 비율이 68–72%로 고르게 높다. 이 묶음은 사람 평가를 기준으로 자동 지표를 검증해 온 자연어 생성 평가의 관행을 이어받았다. 대화에서는 GPT-4 판정이 통제·크라우드 사람 선호와 80% 넘게 일치해 사람끼리의 일치 수준에 이른다고 보고한 MT-Bench 연구 [1]와, 응답

순서만 바꿔도 판정이 왜곡됨을 보인 연구 [14]가 기준점이다. 요약에서는 G-Eval이 사람과 Spearman 0.514를 얻었고 [2], ChatGPT가 기존 자동 지표보다 사람과 경쟁력 있는 상관을 보이지만 참조에 의존한 메타평가 데이터에서는 효과가 떨어질 수 있다는 보고 [81]가 함께 인용된다. 번역에서는 GPT 3.5 이상 모델에서만 작동하고 시스템 수준에서 MQM 라벨과 맞는다는 결과 [18]가, 창작에서는 전문가가 높게 평가한 글을 LLM도 높게 평가한다는 결과 [222]가 대표적이다. 초기 대표 연구들이 긍정적 결과를 보고한 묶음이지만, 7.2–7.3절에서 보듯 문학 번역과 창작물처럼 전문가의 미적 판단이 필요한 경우에는 반박 근거가 나온다.

추론·코드. 수학은 사람 비교 비율이 26%로 모든 분야 중 가장 낮고, 코드는 44%, 과학은 57%다. 인용 상위 연구도 보상 모델 벤치마크 RewardBench [4], 추론형 보상 모델 RM-R1 [26], 과정 보상 모델 GenPRM [223]처럼 정답 라벨이나 실행 결과로 판정 모델을 재는 연구다. 정답이 정해진 과제에서는 사람 판정 대신 정오 라벨을 기준으로 삼는 경우가 많아 사람 비교 비율이 낮은 것으로 보인다. 과학은 이 묶음 안에서 성격이 다르다. 논문 심사 [224]와 연구 재현 평가 PaperBench [144]처럼 정답이 없는 판단이 섞이고, 이 경우 전문가와의 대조가 다시 필요해진다. 과학의 사람 비교 비율이 수학·코드보다 높은 것도 이와 맞는다.

전문 분야. 의료(72%), 법(71%), 교육(72%)은 사람 비교 비율이 가장 높은 축에 속한다. 고위험 판단을 다루므로 전문가 대조 없이는 결과를 받아들이기 어렵기 때문으로 보인다. 의료에서는 GPT-4의 치료 권고 평가가 의사 평가와 모든 기준에서 유의하게 상관했다는 초기 연구 [225]와, LLM 배심원이 임상의와 ICC 0.47로 임상의끼리의 평균 0.43을 넘었다고 보고한 MedHELM [80]이 많이 인용된다. 법에서는 한국어 법률 QA에서 검색 근거를 결합하면 변호사 평가와 더 잘 맞는다는 연구 [226]와 법률 사례 검색의 관련성 판정 연구 [227]가, 교육에서는 확산적 사고 채점 [228]과 AI 튜터의 교육학적 능력 평가 체계 [229]가 대표적이다. 금융은 45편으로 가장 작고 사람 비교 비율도 51%에 그친다. 이 분야의 대표 연구는 금융 전문가가 만든 벤치마크 BFF-Bench에서 정답 참조가 없으면 판정 모델이 스스로 맞힌 문항에서만 전문가와 높게 일치한다고 보고했고 [136], 전문 지식이 필요한 루브릭 벤치마크 ProfBench에서는 GPT-5-high도 65.9%에 그쳤다 [230].

시스템. 검색·RAG는 60%, 멀티모달은 69%로 비교적 높고, 에이전트는 49%, 안전은 42%로 낮다. 검색·RAG에서는 LLM 관련성 판정이 사람 라벨러만큼 정확하지만 프롬프트와 환언에 따라 예측하기 어렵게 달라진다는 보고 [16]와 소량의 사람 주석으로 RAG를 평가하는 ARES [17]가 대표적이다. 멀티모달에서는 VL-RewardBench가 GPT-4o도 정확도 65.4%에 그친다고 보고해 [84], LMM 판정 모델 학습 연구 [231]의 긍정적 결과와 대조된다. 에이전트에서는 웹 에이전트 평가용 판정이 사람과 약 85% 일치했다는 연구 [29]가 있는 반면, 검증자 LLM이 계획 평가에서 false positive를 많이 낸다는 연구 [148]도 있다. 안전 분야는 RLAIF [232]나 SALAD-Bench [233]처럼 판정 모델을 학습 신호나 벤치마크 채점기로 쓰는 연구가 중심이어서 판정 자체를 사람과 대조한 비율이 낮다.

정리하면, 사람 비교 비율은 분야의 위험도만으로는 설명되지 않고, 판정의 기준을 무엇으로 삼느냐와 함께 달라지는 것으로 보인다. 이 서베이는 두 요인의 영향을 따로 분석하지는 않았다. 안전은 고위험 분야인데도 비율이 42%로 낮다. 수학·코드는 정오 라벨을 기준으로 삼아 사람 대조가 적고, 안전·에이전트는 판정을 파이프라인 부품으로 쓰는 경우가 많아 대조가 적다. 반면 텍스트 생성과 전문 분야는 사람 평가가 기준으로 자리 잡아 대조 비율이 높다. 다만 사람 비교를 했다는 사실이 전문가 대조를 했다는 뜻은 아니다. 그 차이는 다음 절의 Q-EXPERT가 다룬다.

7.2 비교: 전문 분야에서 LLM 판정은 전문가를 대신하는가

7.2.1 집계

Q-EXPERT 주장은 168개다. 표 7-2는 이를 근거 유형별로 나눈 것이다. 결과가 갈린 질문이므로 독립 평가 주장 중 15개를 본문으로 확인했다.

표 7-2 Q-EXPERT 주장의 방향 (주장 수)

근거	지지	반박	조건부	효과 없음	계
독립 평가 (초록 기준)	22	57	53	0	132
제안 방법 (초록 기준)	33	0	3	0	36
독립 평가 중 본문 확인 (본문 기준)	2	7	6	0	15

두 근거 유형의 방향은 정반대다. 기존 판정 방식을 독립적으로 전문가와 대조한 132개 중 지지는 22개뿐이고, 반박 57개와 조건부 53개가 대부분을 차지한다. 반면 자기 방법을 제안한 연구의 36개는 33개가 지지이고 반박은 하나도 없다. 9.3절에서 다룰 제안 방법과 독립 평가의 격차가 이 질문에서 뚜렷하게 나타난다. 본문 확인 15개 중 13개는 초록 주장이 본문과 그대로 맞았고 2개는 일부 조건에서만 성립했으며, 방향이 바뀐 주장은 없었다. 따라서 이 질문의 결론, 곧 "범용 LLM 판정은 대체로 전문가를 대신하지 못하고, 대신할 수 있는 경우에도 항목과 조건이 제한된다"는 결론은 초록 기준과 본문 기준에서 같다.

7.2.2 지지 근거

독립 평가의 지지 22개는 대부분 의료와 교육에서 나왔다. 본문으로 확인한 두 편이 대표적이다. AI 챗봇의 자살 위험 대응을 VERA-MH 루브릭으로 평가한 연구는 LLM 판정과 임상의 합의의 IRR이 0.81로 임상의끼리의 IRR 0.77과 비슷했다고 보고했다 [234]. 본문은 이 수치를 그대로 뒷받침하지만, 차원별 IRR은 변동이 크고 신뢰구간이 넓으며 위험을 과소평가한 오류가 1,350건 중 61건(4.5%) 있었다. 평균 일치가 전문가 수준이어도 안전 평가에서 놓친 사례가 남는다는 뜻이다. 금융 딥리서치 보고서를 평가한 연구는 LLM 판정 3개와 전문가 3인이 동시에 만장일치한 항목에서 라벨 일치가 98.67%라고 보고했다 [235]. 본문 확인 결과는 "일부 조건에서만 성립"이었다. 이 수치는 만장일치 항목에 한정되고, 전체 다수결 일치는 90.42%이며, 저자도 보편적 대체가 아닌 보수적 루브릭 선별 용도로만 주장한다.

초록 기준 지지 근거에도 비슷한 단서가 붙는다. 추론 모델 GPT-o3-mini가 EHR 요약 평가에서 사람과 ICC 0.818을 보였다는 보고 [236], eConsult 답변 판정에서 LLM이 Cohen's kappa 0.75로 의사 간 0.69–0.90 범위 안에 들었다는 보고 [237], One Health 문서 루브릭 평가에서 사람–모델 κ 0.513–0.692가 사람–사람 κ 0.649와 비슷했다는 보고 [238]는 모두 사람 간 일치를 함께 제시해 비교 기준을 갖춘 사례다. 대학 컴퓨터과학 시험 채점에서 Pearson 0.948을 얻은 연구 [239]처럼 정답이 비교적 분명한 채점 과제도 지지 쪽에 있다. 지지 근거는 대체로 구조화된 루브릭이 있고, 기준이 객관적이며, 사람 간 일치를 함께 보고한 연구에서 나온다.

7.2.3 반박 근거

반박 57개는 분야가 넓다. 본문으로 확인한 일곱 편은 영양·정신건강부터 문학 번역까지 여러 분야에서 판정이 전문가나 정답 라벨에 미치지 못한 정도를 수치로 보고했다. 영양학·정신건강 전문가와 LLM의 쌍비교 선호

일치는 각각 68%와 64%였고, 전문가 페르소나 프롬프트로 다소 올랐지만 전문가끼리의 일치보다 낮았다 [240]. 임상 요약의 사실 불일치 탐지에서는 GPT-4를 포함한 모든 방법이 balanced accuracy 50% 기준선 근처(GPT-4-ZS 51.0)에 머물렀다 [104]. 올림피아드 수학에서는 o1·o3-mini를 포함한 판정 모델이 명백히 틀린 풀이와 정답을 우연 수준으로만 구분했다(쌍비교 정확도 46–57) [241]. 과학 연구의 소거 설계 평가에서는 인스턴스 수준 Pearson이 약 −0.020–0.338에 그쳤고 [242], 웹 개발 품질 평가에서는 최고 GPT-4.1의 일치율이 70.34%로 80%를 넘는 사람 주석자 간 일치보다 약 15% 낮았다 [243]. 생의학 관계 추출 판정에서는 대부분의 판정 모델 정확도가 50% 미만이었다 [244]. 문학 번역에서는 LLM 기반 지표를 포함한 자동 지표가 사람 번역을 가려내는 비율이 최대 20%였는데, 본문은 학생이 MQM으로 평가할 때도 약 60%를 오판한다고 밝혀 사람 평가 방식 자체의 문제도 함께 드러냈다 [245]. 다만 본문 확인은 20%가 자동 지표 전체의 수치임을 확인했을 뿐, LLM 판정만의 수치는 확인하지 않았다.

초록 기준 반박 근거는 세 가지 실패를 반복해서 보고한다. 첫째, 오류를 놓치고 틀린 출력을 승인한다. 희귀 질환 임상 추론에서 GPT-4o-mini는 임상적으로 틀린 출력의 47.9%를 승인했고 [246], 임상 예측 판정에서는 사람이 찾은 오류 30건 중 16건을 수용했으며 [247], 의료 챗봇의 불완전 응답 판별은 AUC 0.49–0.66에 그쳤다 [248]. 둘째, 점수가 한쪽으로 쏠린다. 보건 메시지 평가의 세 LLM은 모두 전문가보다 높은 점수를 줬고 [249], 의료 교육의 공감 평가에서는 ICC 0.146에 +0.80점 과대평가, 점수의 76%가 4.2–4.3에 몰렸다 [250]. 반대로 온라인 강좌 품질 평가에서는 모든 LLM이 설계자보다 낮게 채점했다 [251]. 쏠림의 방향이 과제마다 다르므로 일률적인 보정 상수로 바로잡기 어렵다. 셋째, 판정 모델끼리도 맞지 않는다. MIMIC-IV 임상 요약에서 "문제 있음" 비율은 Codex-GPT-5 93.4%, Phi-4 10.5%, 의사 59.5%였고 쌍별 κ는 0.009–0.151이었다 [252]. 에세이 채점에서는 판정자 간 엄격도 차이가 ASAP 점수 범위의 15–33%로 훈련된 사람 간 약 1%보다 훨씬 컸다 [253].

7.2.4 조건 1: 평가 항목의 객관성

조건부 53개 중 가장 많이 반복되는 조건은 평가 항목의 성격이다. 같은 연구 안에서 사실·문법·형식 같은 객관 항목은 전문가와 맞고, 공감·위해·의사소통 품질 같은 주관적이거나 고위험인 항목은 어긋난다. 표 7-3은 항목별 수치를 함께 보고한 연구를 모은 것이다.

표 7-3 같은 연구 안에서 항목에 따라 갈린 전문가 일치

연구	분야	잘 맞는 항목	어긋나는 항목	확인
[101]	환자 대상 의료 QA	과학적 합의 0.976, 문법 0.990 (정확도)	공감 0.486, 피해 정도 0.700	본문
[254]	임상 노트 일관성	나이 κ 0.79, 성별 κ 1.00	신체 부위 κ 0.32	본문
[255]	한국 학생 글	유창성 93%, 문법성 87% (타당 비율)	일기 20%, 논증문 36.36% (글 유형)	본문
[154]	소프트웨어 공학 주석	의미 유사도 0.64–0.77 (사람 간 0.71–0.83)	정적 분석 경고 0.15 (사람 간 0.80)	본문
[256]	임상시험 동의서 소통	안전 선별·사실 검증 ρ > 0.80	의사소통 품질 ρ < 0.60	초록
[171]	물리 평가	그래프 ρ > 0.83, 문항 ρ > 0.6	에세이 순위 일치 거의 0	초록
[257]	내과 MCQ	부정문 줄기 κ 0.897	학습 성과 정렬 ICC 0.121–0.380	초록
[258]	간담도 e-consult	정확성·정밀성·포괄성 (TOST 동등)	잠재적 위해 판정 67% 대 전문의 20%	초록

본문 확인을 거친 네 편은 모두 객관 항목에서 잘 맞고 주관 항목에서 어긋나는 방향이다. 다만 한국 학생 글 연구는 본문 확인에서 일부 조건에서만 성립했다. 이 연구에서 판정의 타당 비율은 관련성 77%를 포함해 모든 기준에서 77–93%였고, 어긋남은 주로 일기(20%)·논증문(36.36%) 같은 주관적 글 유형에서 나타났다. 이 결과는 9.2절에서 다룰 조건 변수 가운데 "과제의 검증 가능성"과 일치한다. 정답이 텍스트 안에서 확인되는 항목은 맞고, 해석과 가치 판단이 필요한 항목은 어긋난다. 이 해석에는 두 가지 단서가 붙는다.

첫째, 주관 항목에서는 사람 기준선도 불안정하다. 의료 QA 연구는 공감 같은 주관 차원에서 사람 주석자 간 일치가 낮다고 밝혔고 [101], 임상 노트 연구에서도 일관성 항목의 사람 간 Fleiss kappa가 최소 수준이었다 [254]. 교육 피드백 평가에서는 사람 간 일치가 낮을수록 LLM 평가의 신뢰도도 낮았다 [100]. 주관 항목의 낮은 일치에는 기준 자체의 모호함이 한 원인으로 작용했을 수 있다.

둘째, 위해 판정에서 LLM이 늘 관대하지는 않다. 간담도 e-consult에서 OpenAI-o1은 전문의보다 훨씬 엄격했지만 [258], 내시경 보고서 평가에서는 안전성에 +0.94점 관대 편향을 보였다 [259]. 두 연구만 보면 고위험 항목의 어긋남은 방향이 일정한 편향이 아니라 연구마다 달랐다.

7.2.5 조건 2: 지표와 기준 전문가

두 번째 조건은 일치를 어떤 지표로 재느냐다. 같은 데이터에서도 지표에 따라 결론이 달라진다. 안과 환자 질문에 대한 챗봇 응답 평가에서 GPT-4는 임상의 순위와 Spearman 약 0.90, Kendall Tau 약 0.80을 보였지만 Cohen 카파는 0.50 수준이었다 [260]. 본문을 보면 6개 임상의 비교 중 4개에서만 Spearman이 0.70을 넘었다. 같은 결과가 순위상관으로 보면 "대체 가능", 카파로 보면 "보통 일치"가 된다. 브라질 포르투갈어 법률 검색에서는 쌍 수준 kappa가 0.32–0.53이었지만 nDCG@10·MRR 기준 시스템 순위의 Kendall tau는 0.90 이상이었다 [261]. 농업 XAI 설명 평가에서는 LLM이 1.4–2.3점 과대 채점했지만 순위 Spearman은 0.58–0.90이었고 [262], 영어–인도네시아어 번역 평가와 직무 AI 출력 평가에서도 순위는 맞고 절대 점수나 수용률은 어긋났다 [263, 264]. 후자에서 수용 응답 비율은 판정자에 따라 3.0%에서 97.9%까지 퍼졌고 근로자 평가는 61.1%였다. 상대 순위가 필요한 모델 비교에는 LLM 판정을 쓸 수 있어도, 합격·불합격 같은 절대 판정에는 쓰기 어렵다는 뜻이다.

어떤 전문가를, 몇 명을 기준으로 삼느냐도 결론을 바꾼다. 의료 요약 쌍비교 연구에서 전문가 전체의 일치는 19.2%, 3인 그룹 일치는 54%였고, GPT-4는 전문가 최소 1인과 83.06% 일치했다 [265]. 흉부 CT 보고서 번역 평가에서는 LLM–전문의 QWK가 −0.04–0.15였지만 전문의끼리도 0.01–0.06에 그쳤다 [266]. 사람 간 일치가 이렇게 낮으면 "전문가 수준의 일치"를 기준으로 삼기 어렵다. 반대로 사람 간 일치가 높은 사례에서는 LLM이 그에 못 미친 것으로 보인다. 위장관기질종양 치료 권고 평가에서 LLM 판정과 전문의의 κ는 0.647이었고 전문의 간 ICC는 0.929였다 [267]. 이 비교는 지표가 서로 달라 직접 견줄 수 없다는 한계도 함께 보여 준다.

기준 전문가의 직급과 구성도 변수다. 안과 응답 채점에서 상급 전문의는 더 보수적으로 채점했다 [268]. 태국 변호사 시험 서술형 평가는 전문가 간 불일치가 정보라는 점을 보여 준다. LLM 패널의 α는 0.77로 사람 패널의 0.36보다 높았지만, 사람 전문가가 갈린 쟁점에서 LLM은 다수 해석으로만 쏠리고 소수 해석을 재현하지 못했다 [269]. 높은 내부 일치가 전문가 판단의 다양성을 지운 결과일 수 있다는 것이다. 한국 학생 글 연구는 검증자가 전문 교사가 아닌 학생 본인이어서 "전문가 대조"라는 이름 아래 기준의 질이 다를 수 있음을 보여 준다 [255].

7.2.6 격차를 메우려는 시도: 분야 특화 프롬프트와 학습

분야 특화 프롬프트나 학습이 격차를 메운다는 보고는 제안 방법 쪽에 몰려 있고, 독립 평가에서는 효과가 부분적이다. 임상 요약 연구에서 임상 지침을 넣은 프롬프트(GPT-4-ZS-Treat)는 52.1로 기본 프롬프트의 51.0과 거의 같았다 [104]. 전문가 페르소나 프롬프트는 일치를 올렸지만 전문가 간 일치에 이르지 못했다 [240]. 루브릭과 예시 응답을 준 사용자 정의 GPT도 공학경제학 과제 채점에서 Cohen's κ 0.128에 그쳤다 [270]. 유럽사법재판소 판결 평가에서는 루브릭 판정이 전체 점수 직접 평가보다 전문가에 가까웠지만 세밀한 차이에는 둔감했다 [271]. 반면 형식과 소량 예시는 뚜렷한 효과를 보였다. 생의학 관계 추출에서는 구조화 출력(JSON)만으로 전 모델이 평균 약 15% 개선됐고 [244], 이탈리아 민법 질의 판정에서는 예시 두 개로 사람과의 격차가 크게 줄었다 [272]. 일반 프롬프트의 프런티어 LLM은 의사와 자주 불일치하지만 소수 사례로 미세조정한 모델은 의사 수준의 일관된 채점이 가능하다는 보고도 있으나 초록 기준이다 [273].

제안 방법 36개는 이 공백을 메우는 기법을 보고한다. 전문가 작성 근거를 참조로 쓰는 평가 [274], 루브릭 SFT와 전문가 DPO로 학습해 평균 QWK 0.944를 보고한 MentalEval [275], 임상의 간 최고 일치 88.5%를 넘는 92.7%를 보고한 VeriFact [276], 단일 전문가와 통계적으로 열등하지 않다는 MedVAL [277]이 그 예다. 같은 문헌 리뷰 평가에서 기존 LLM 판정은 전문가와 Spearman 0.467에 그쳤지만 전문가 선호로 보정한 LitJudge는 0.78에 이르렀다 [278]. 한 논문이 반박과 지지를 동시에 내놓은 이 사례는 범용 판정의 실패와 보정 판정의 성공이 한 논문에서 함께 보고됨을 보여 준다. 그러나 이 성과들은 모두 저자 자신의 데이터와 기준에서 측정한 것이고, 이 서베이가 확인한 범위에서는 독립 재현이 없다. 6장의 `Q-FT`에서 본 독립 검증 공백이 전문 분야에서도 그대로 나타난다.

7.3 종합

분야를 가로지르는 결과는 세 가지로 정리된다. 두 가지는 분야에 공통된 경향이고, 하나는 분야마다 다른 위험이다. 첫째, 전문성과 난이도가 높아질수록 일치가 떨어진다. 이는 5장의 `Q-HARD`, 곧 주장 37개가 모두 같은 방향이었던 공통 패턴의 응용 분야 판이다. 고교 수학 채점에서 판정 모델의 오차는 합성 LLM 풀이(MSE 약 1.17)보다 실제 학생 답안(약 2.96)에서 훨씬 컸고 [279], 대학 수학 증명에서는 이산수학·그래프 이론에서 일치가 크게 떨어졌다 [280]. 아키텍처 문서 평가에서는 문서 품질이 높을수록 LLM과 아키텍트의 일치가 커졌다 [281]. 이 사례들에서 판정 모델은 깔끔하고 전형적인 입력에서 강하고, 실제 현장의 불규칙한 입력과 전문 판단이 필요한 경계 사례에서 약한 경향을 보였다. 뉴스 매체 평가 연구는 LLM이 전문가 출력과 자주 일치하더라도 맥락 추론이 아닌 어휘 연관에 기댈 수 있다고 해석했다 [282]. 일치가 높다는 사실만으로 판정 근거가 전문가와 같다고 볼 수 없다는 뜻이다.

둘째, 결론은 항목, 지표, 기준 전문가라는 세 조건에 달려 있다. 7.2.4–7.2.5절의 사례는 "LLM이 전문가를 대신하는가"라는 물음이 분야 단위로는 답할 수 없는 질문임을 보여 준다. 같은 의료 분야 안에서도 사실 검증 항목은 전문가 수준에 가깝고 공감·위해 항목은 그렇지 않으며, 순위로 보면 맞고 절대 점수로 보면 어긋난다. 의료 분야 LLM 판정 134편을 검토한 범위 리뷰도 사람 검증을 보고한 연구에서 중간에서 강한 일치를 보이지만 과제별 편차가 크다고 결론지었다 [12].

셋째, 분야마다 고유한 위험이 있다. 의료에서는 누락 오류와 틀린 출력의 승인이 주된 위험이다. 방사선 보고서 판정은 전반적으로 상관되지만 누락 오류를 놓쳤고 [283], 임상 추론 판정은 유창하지만 근거가 약한 응답을 과잉 수용했다 [284]. 정신건강 분야에서는 판정자 간 불일치가 안전 핵심 지표에 집중된다는 보고 [285]와

전문가가 짚은 안전 문제를 놓친다는 보고 [286]가 있다. 법에서는 소수 해석의 소실 [269]과 사람보다 덜 비판적인 판정 [287]이 문제다. 과학과 연구 평가에서는 참신성 판단이 뒤집힌다. LLM 판정은 모델이 만든 연구 질문을 더 참신하다고 봤지만 전문가는 저자 질문을 선호했고 [288], 연구비 심사에서는 사람이 새롭다고 평가한 제안서를 덜 선정했다 [289]. 번역과 창작에서는 판정 모델이 기계 생성물을 선호한다. 흉부 CT 보고서 번역에서 LLM 판정은 LLM 번역을 70–99% 선호했고 [266], 문학 번역 창의성 평가에서는 기계 번역문을 체계적으로 선호했으며 [290], 한시 평가에서는 운율 규칙을 어긴 기계 생성 시를 과대평가했다 [291]. 이는 5장의 자기선호 편향(Q-SELF)이 사람 전문가의 미적 기준과 부딪히는 지점이다. 교육에서는 점수 압축과 판정자 간 엄격도 차이가 [250, 253], 공정성이 걸린 채점에 영향을 줄 수 있다.

이상을 종합하면, 이 장의 근거는 범용 판정 모델을 전문가의 전면 대체로 쓰기보다는 객관 항목의 선별과 순위 비교에 한정해 쓰는 쪽을 지지한다. 금융 보고서 연구 [235]는 지지 근거인데도 보수적 선별로 용도를 제한했고, 반박 근거인 교육 데이터 연구 [292]와 디지털 자산 백서 연구 [293]도 선별·의사결정 지원 도구로만 쓸 수 있다고 결론 냈다. 이 세 연구는 모두 대체보다 보조 용도를 권한다.

7.4 공백과 의제

이 장에서 드러난 공백은 10장의 의제 가운데 다섯 개와 연결된다.

전문 분야의 분담 판정 (A6). 표 7-3의 패턴은 항목 단위 분담 설계의 근거가 된다. 객관 항목은 LLM이 맡고, 주관·고위험 항목은 전문가가 맡거나 판정 모델이 판정을 보류하는 방식이다. 그러나 이 서베이가 확인한 범위에서 이 분담을 실제로 설계하고 평가한 독립 연구는 드물다. 독일어 임상 QA 연구는 강한 판정 모델이 의사 기준에 근접(kappa 0.694 대 0.709)했지만 판정 보류율이 낮아 의사 검증이 필요하다고 밝혔다 [294]. 어떤 항목을 넘기고 어떤 사례에서 판정을 보류할지에 대한 기준, 그리고 그 기준으로 놓친 오류가 얼마나 줄었는지를 측정하는 연구가 필요하다.

검증 범위 확대 (A7). 검증 범위는 판정 대상과 언어 양쪽에서 좁다. 판정 구성 코드에서 에이전트형으로 분류한 논문은 176편이고 그중 사람 판정과 대조한 연구는 89편이다. 응용 분야 코드에서도 에이전트 분야가 176편이고 그중 사람 비교는 87편(49%)이다. 두 코드는 각각 판정 구성과 응용 분야를 가리키므로 편수가 같아도 같은 논문 집합이 아니며, 겹치는 논문은 82편이다. 전문 분야에서 에이전트를 판정 대상이나 판정 주체로 삼은 연구는 인용한 네 편에서 대조 결과가 엇갈렸다. 웹 개발 평가의 에이전트 판정은 전문가와 큰 격차를 보였고 [243], 수술 동의 대화형 에이전트 평가에서는 어떤 단일 판정 구조도 임상의의 실패 판정을 재현하지 못했다 [295]. 과학 발견 에이전트 결과의 판정은 전문가와 중간 수준으로 일치했고 [296], 특허 초안 에이전트 판정은 지표에 따라 일치가 크게 달라졌다 [297]. 에이전트형 판정에 대한 개관 연구도 사람 감독을 대체하기보다 보완한다고 정리했다 [9].

언어 범위도 좁다. 영어 외 언어를 다룬 연구는 250편(11%)이다. 르완다 보건 인력 질문 평가에서 최고 판정 모델도 11개 기준 중 4개에서만 임상의와 일치했고 영어에서 키냐르완다어로 가면 성능이 떨어졌다 [298]. 아랍어 방언 평가에서는 5개 판정자 중 4개가 체계적으로 관대했고 암묵적 문화 추론에서 실패했으며 [299], 4개국 문화 오류 탐지에서는 최강 판정자도 F1 0.52에 그쳤다 [300]. 일본어 법정 통역 평가는 거의 모든 설정에서 상관이 0.4 아래였다 [301].

측정 표준 (A3). 7.2.5절에서 본 것처럼 순위상관과 카파, 인스턴스 수준과 시스템 수준이 서로 다른 결론을 낸다. 사람 간 일치를 함께 보고하지 않으면, 초기 의료 연구처럼 유의한 상관을 보고해도 전문가 간 일치와 비교할 수 없다 [225]. 사람 간 일치를 같은 지표로 보고하고 그 대비 상대 일치로 표준화해야 연구 간 비교가 가능해진다. 기준 전문가의 수, 직급, 선정 방식도 함께 보고해야 한다.

독립 재현과 조건별 선택 (A1, A2). 제안 방법 36개 중 33개가 지지인 반면 독립 평가 132개 중 지지는 22개라는 격차는, 분야 특화 판정 모델을 다른 기관의 데이터와 전문가로 다시 검증하는 재현 연구가 필요함을 보여 준다. 또한 항목의 객관성, 입력의 현장성(합성 대 실제), 필요한 전문성 수준을 축으로 나눈 층화 메타평가가 있어야 분야별로 판정 모델을 언제 써도 되는지 지침을 만들 수 있다.

요약하면, 응용 분야의 문헌은 사람 비교를 많이 하지만, 전문가 판정과의 대조는 범용 LLM 판정이 전문가를 대신한다는 명제를 대체로 부정한다. 독립 평가 132개 중 지지는 22개였다. 대신할 수 있는 영역은 객관 항목, 순위 비교, 구조화된 루브릭, 사람 간 일치가 높은 과제로 좁혀진다. 다만 주관 항목과 일부 의료 과제에서는 전문가끼리의 일치도 낮아, 낮은 일치에는 판정 모델의 한계뿐 아니라 기준 자체의 불안정이 함께 작용했을 수 있다. 이 범위를 넓히려는 제안 방법의 성과는 아직 독립적으로 확인되지 않았다.

8. 보안

이 장은 RQ5, 곧 판정 모델을 의도적으로 조작하는 공격과 그에 대한 방어를 다룬다. 5장의 편향이 판정 모델이 스스로 드러내는 체계적 오차라면, 이 장의 대상은 누군가 그 오차를 찾아내어 판정 결과를 원하는 방향으로 옮기려는 상황이다. 판정 모델이 리더보드 순위, 강화학습의 보상, 과제 채점, 논문 심사, 에이전트의 도구 호출 승인처럼 이해관계가 걸린 결정에 쓰이면서 이 구분은 실무에서 중요하다. 근거 묶음에 담긴 보안 관련 논문은 116편이며, 비교 질문은 `Q-ATTACK`(판정 모델 공격은 쉬운가)과 `Q-DEFENSE`(방어는 효과가 있는가) 두 가지다. 공격은 범주와 결과 수준에서만 기술하고 구체적 절차는 다루지 않는다.

8.1 분류

8.1.1 공격 유형

공격은 조작이 어디에 들어가는가에 따라 나눌 수 있다. 근거 묶음의 논문에서 다음 여섯 범주와 하나의 인접 범주가 반복된다. 한 논문이 여러 범주에 걸치는 경우가 많고 범주 경계를 정한 것은 이 서베이이므로, 범주별 편수는 제시하지 않는다.

문구·접미사 삽입은 평가 대상 응답 앞뒤에 짧은 문자열을 덧붙여 점수를 올리거나 판정을 뒤집는 방식이다. 대리 모델에서 찾은 범용 문구가 미지의 판정 모델로 전이된다는 보고 [45], 경사 기반으로 최적화한 시퀀스가 다른 후보와 무관하게 해당 응답을 선택되게 한다는 보고 [302, 303]가 대표적이다. 최적화가 없어도 효과가 난다. 판정 모델 자신의 분포에서 뽑은 짧은 토큰 [304], ':'나 'Thought process:' 같은 단일 입력 [305], 추론을 흉내 내는 문구 [109, 113], 내용은 그대로 둔 채 붙인 고정 문구 [306, 307]가 모두 판정을 움직였다. 강화학습으로 판정 모델의 선호에 맞춘 서문 생성기 [308]는 응답을 직접 고치지 않아 탐지가 어렵다.

프롬프트 주입은 판정 지시 자체를 덮어쓰거나 판정 목표와 기준을 바꾸는 방식이다. 콘텐츠 작성자와 시스템 프롬프트 공격을 나눈 연구 [309], 텍스트 랭킹의 목표·기준 하이재킹 [310], 다국어 질의 기반 주입 [311], 이력서 심사 [312], 정답과 무관한 블라인드 공격 [313]이 이 범주에 속한다. 실제 강의에서 학생들이 GPT-4 평가자를 조작해 루브릭을 충족하지 않고 높은 점수를 얻은 사례 [314]는 이 공격이 실험실 밖에서도 일어남을 보여 준다.

형식·스타일 조작은 의미를 보존하면서 표현만 바꾼다. 밴딧으로 문체 편집을 고르는 BITE [315], 출력 스타일 변화가 안전 판정의 거짓 음성률을 올린다는 메타평가 [316], 방해 특징 삽입 [39], 키워드 채우기 [317], 응답 순서 교환 [14], 기준이 많은 일괄 판정에서 제시 방식만 바꾸는 탐색 [318]이 여기에 든다. 입력과 무관한 상수 응답을 내는 널 모델이 자동 벤치마크에서 최상위 점수를 얻은 결과 [212]도 형식만으로 판정을 끌어낸 극단적 사례다. 토큰 수준에서는 이모지 삽입이 토큰 분할을 바꿔 유해성 판정을 흐린다 [319]. 멀티모달 판정에서는 시각적 조작 [320]과 MGSIA [321]가 같은 역할을 한다.

설득·권위 신호는 판정 모델의 사회적 반응을 겨냥한다. 아리스토텔레스 수사학에 기반한 7가지 설득 기법 [99], 권위 편향을 이용한 공격 [322], 판정 후 대화에서의 표적 도전과 권위 프레이밍 [323], 정적 반박과 적대적 LLM 설득자 [324], 역할극 기반 학술 탈옥 [325], TRPG 심판에 대한 의사논리·권위적 강압 [326]이 대표적이다. 다중 판정 구성에서는 위조된 동료 판정 인용 [327]과 토론 참여자의 거짓 인과 주장 [328]이 같은 경로로 작동한다.

백도어·데이터 오염은 판정 시점이 아니라 판정 모델이나 평가 구성요소를 만드는 단계에 개입한다. BadJudge [329]는 웹 오염, 악의적 주석자, 가중치 오염의 세 접근 수준을 구분했다. 루브릭을 벤치마크 검증을 통과하도록 수정해 선호를 옮기는 공격 [330], 평가 프롬프트 템플릿이나 골드 너깃의 유출 [95], 생성 루브릭의 악용 [331]은 평가 기준 자체가 공격면이 된다는 점을 보인다.

판정 대상 응답을 통한 간접 주입은 판정 모델이 읽는 문서, 궤적, 로그에 조작을 숨긴다. PDF에 보이지 않는 텍스트를 넣어 논문 심사의 거절을 수락으로 바꾼 연구 [332]와 사소한 산술 문제에서도 숨은 주입에 속은 결과 [333], 질의어 삽입만으로 무관한 문단이 관련 있다고 판정된 결과 [334, 335, 336]가 있다. 에이전트 평가에서는 행동과 관찰은 고정한 채 추론 사슬만 다시 쓰거나 [337], 판정 모델이 읽는 확인 데이터를 위조하거나 [338], 부분 점수 평가를 겨냥한 궤적을 만들거나 [339], 악성 스킬을 정상 목적으로 포장해 [340] 판정을 통과한다.

인접 범주로 **최적화 압력에 의한 보상 해킹**이 있다. 공격자가 따로 없어도 판정 모델을 보상으로 쓰는 학습 자체가 판정의 거짓 양성을 찾아낸다. 추론 판정자로 학습한 정책이 다른 판정자를 속이는 출력을 익히고 [341], 자기 대국이 통과율만 올리며 [60], 판정 능력(AUC)이 해킹이 멈추는 수준과 상관한다는 보고 [342]가 이에 해당한다.

8.1.2 방어 유형

방어는 어디에 개입하는가에 따라 다섯 범주로 나뉜다.

탐지는 공격 입력을 걸러 낸다. 알려진 정답·퍼플렉시티 탐지 [302], 의도적으로 틀린 정답으로 재평가해 두 조건 모두에서 인정되는 답을 공격으로 보는 반사실 평가 [313], 법정식 다중 에이전트 분류기 CourtGuard [343], 구절 분류기 [336]가 대표적이다.

견고화 학습은 판정 모델 자체를 바꾼다. 적대적 음성 예시로 증강 학습한 Master-RM [305], 메커니즘 분류로 층화한 LoRA 미세조정 [304], 백도어에 대한 모델 병합 [329]이 있다.

프롬프트 방어는 판정 지시를 고친다. 톤을 무시하라는 채점 프롬프트 [306], 조작을 의식하게 하는 프롬프트 [337], 판정 모델이 먼저 답을 확정하는 commit-first [344, 60], 증거를 먼저 고정하는 PROOF-BEFORE-PREFERENCE [345], 신뢰할 수 없는 입력을 모의 도구 호출로 감싸는 격리 [346]가 여기에 든다.

재토큰화·전처리는 판정 전에 입력을 정제한다. RobustJudge의 재토큰화 [347], 0.13B Sentry로 주입 구간을 찾아 제거하는 StableJudge [348], 주입 탐지를 강화한 PromptArmor 변형 [311], 주관적 표현을 걷어 내고 증거 단위만 남기는 SEED [349]가 있다.

집계·구조 분리는 판정 구조를 바꾼다. 패널 합의 검증 [327], 기준을 작은 묶음으로 나누는 샤딩 [318], 기하 중앙값으로 합의를 내는 RoPoLL [350], 결정적 증거를 공격자가 쓸 수 없는 채널로 옮기는 설계 [338], 판정을 조언자로 낮추고 결정적 검증 계층을 관문으로 두는 입장 [96]이 이 범주에 속한다.

8.2 비교

8.2.1 판정 모델 공격은 쉬운가 (Q-ATTACK)

Q-ATTACK은 적은 비용의 조작으로 판정 결과를 크게 바꿀 수 있다는 명제다. 주장 58개의 분포는 표 8-1과 같다.

표 8-1 Q-ATTACK 주장의 방향 (초록 기준)

근거	지지	반박	조건부	효과 없음	계
독립 평가	45	1	3	0	49
제안 방법	8	0	1	0	9

58개 중 53개가 지지하며, 독립 평가만 보아도 49개 중 45개가 지지한다. Q-MULTI나 Q-DEBIAS는 지지가 제안 방법 쪽에 치우쳤지만, Q-ATTACK은 독립 평가에서도 지지 비율이 높다(표 8-1). 공격 연구의 다수는 새 공격을 제안하기보다 기존 판정 설정을 독립적으로 시험했다. 다만 Q-ATTACK은 결과가 갈리지 않은 질문이라 본문 확인 대상에서 빠졌고, 아래 수치는 모두 초록 기준이다.

효과 크기는 판정이 사실상 무력화되는 수준까지 보고된다. 프롬프트 주입 성공률은 최대 73.8%였고 다른 모델로의 전이율은 50.5–62.6%였다 [309]. 논문 심사에서는 결정 뒤집기 비율이 최대 86.26%였고 [332], 학술 코드 채점의 탈옥 성공률은 최대 97%였다 [325]. 안전 판정에서는 무해한 문구를 덧붙이는 것만으로 LLM 판정 3종의 판정이 57–100% 뒤집혔다 [307]. 규제 원칙 판정에서 120B 판정 모델의 정확도는 키워드 채우기로 0.74에서 0.27로 떨어졌다 [317]. 널 모델은 AlpacaEval 2.0 LC 승률 86.5%, Arena-Hard-Auto 83.0점, MT-Bench 9.55점을 얻었다 [212]. 사회적 압력도 강하다. 9개 최신 모델이 정적 반박만으로 판정을 25–71% 번복했고 적대적 설득자 앞에서는 62–91%를 번복했으며, 판정을 바꾼 압력은 거의 항상 정답을 해쳤다 [324]. 학습 단계의 공격은 소량의 오염으로도 효과를 냈다. 학습 데이터 1%를 단일 토큰 백도어로 오염시키면 공격자의 점수가 세 배가 되었다 [329].

반박·조건부 주장 4개는 공격이 언제 약해지는지를 보여 준다. 참조 답과 비교하는 답변 매칭에서는 장황한 응답이나 복수 답변이 점수를 올리지 못했고 이진 채점이 연속 채점보다 견고했다 [351]. 루브릭 기반 단답 채점에서 Qwen 2.5-72B는 프롬프트 주입에는 견고했지만 동의어 치환에는 민감했다 [135]. 이력서 심사의 주입은 주입자가 적을 때만 순위를 올렸고 주입이 퍼지면 효과가 사라졌다 [312]. 스타일 래퍼는 GPT-4o-mini의 올바른 unsafe 판정 19.9%를 safe로 바꿨지만 Claude는 0.4%만 움직였고 gpt-oss-safeguard-20b는 영향이 없었다 [306]. 네 연구 가운데 세 연구는 참조가 있거나 과제가 닫혀 있거나 안전 판정에 특화된 판정 모델을 썼고, 이력서 심사에서는 주입자가 늘어난 조건에서 효과가 사라졌다.

판정 형식의 효과는 일관되지 않다. 방해 특징 삽입에서는 쌍비교가 약 35%, 절대 점수가 9% 뒤집혀 절대 점수가 견고했지만 [39], 범용 적대 문구에는 절대 점수가 비교 평가보다 훨씬 취약했다 [45]. 이는 4장 Q-FORMAT의 상충과 같은 구조로, 형식의 견고성이 공격 유형에 따라 달라진다는 뜻이다.

8.2.2 방어는 효과가 있는가 (Q-DEFENSE)

Q-DEFENSE는 제안된 방어가 공격 성공률을 의미 있게 낮춘다는 명제다. 표 8-2는 초록 기준 분포와, 독립 평가 주장 가운데 본문으로 확인한 10개의 본문 기준 방향을 함께 보인다.

표 8-2 Q-DEFENSE 주장의 방향

근거	지지	반박	조건부	효과 없음	계
독립 평가 (초록)	1	6	4	0	11
제안 방법 (초록)	10	2	1	0	13
독립 평가 중 본문 확인 (본문 기준)	1	4	5	0	10

두 근거의 방향이 정반대다. 제안 방법 13개 중 10개가 지지하지만, 독립 평가 11개 중 지지는 1개뿐이다. 본문 확인은 이 차이를 좁히지 않았다. 10개 중 8개는 초록 주장 그대로였고, 1개 [336]는 일부 조건에서만 성립했으며, 1개는 방향이 옮겨 갔다. 다국어 주입 연구 [311]는 초록에서 반박으로 분류되었지만 본문에서는 직접 질의 주입이 거의 제거되고 질의 변형에는 우회되는 조건부 결과로 옮겨 갔다. 본문 확인을 거치지 않은 독립 평가 반박 1개 [352]는 시험한 어떤 구성도 공격 90% 초과 탐지와 정상 차단 10% 미만이라는 운영점에 이르지 못했다고 보고한다. 표 8-3은 본문으로 확인한 주장을 방어 유형별로 정리한 것이다.

표 8-3 본문으로 확인한 Q-DEFENSE 독립 평가 주장

연구	방어 유형	본문 기준 방향	본문에서 확인한 조건
[306]	프롬프트	지지	단일 래퍼·단일 모델
[302]	탐지	반박	질의 10개 소표본
[320]	프롬프트	반박	GPT-4.1-mini 단일 판정자, CoT가 일부 편향 증가
[99]	프롬프트	반박	CoT가 설득 효과 증폭
[336]	탐지·프롬프트	반박 (partly)	도메인 밖 분류기 실패, 프롬프트는 MAE 증가
[347]	전처리·탐지	조건부	견고성·정상 성능·비용의 맞교환
[113]	프롬프트	조건부	사실 과제에서만 효과
[337]	프롬프트·연산 확대	조건부	재현율 10–20점 하락, 모델별 차이
[344]	프롬프트 (commit-first)	조건부	판정 모델 자체 답의 정오
[311]	전처리	조건부	질의 변형에 우회 (예비 실험)

본문 확인 결과는 세 가지 한계로 모인다.

첫째, 방어는 공격 성공률을 낮추지만 정상 성능을 대가로 치른다. RobustJudge의 방어 8종 비교에서 번역 과제 기준으로 재토큰화는 잔존 공격 성공률을 가장 크게 낮췄지만 정상 성능 손실도 가장 컸고, 단순 LLM 탐지는 균형이 나은 대신 응답당 LLM 호출 1회를 더 요구했다. 저자들은 견고성, 정상 성능, 비용 사이의 최적 맞교환을 이룬 방어가 없다고 결론지었다 (본문 확인) [347]. 웹 에이전트 판정에서 조작을 의식하게 하는 프롬프트는 GPT-4o의 오탐률 증가분을 27%에서 18%로 줄였지만 재현율을 10–20점 낮췄다 (본문 확인) [337]. 관련성 판정에서 신중한 방어 프롬프트는 GPT-4o의 공격 성공률을 낮췄으나 사람 판단과의 MAE가 늘었다 (본문 확인) [336]. 초록 기준으로도 CourtGuard는 오탐률을 낮춘 대신 주입 탐지 성능이 대체로 나빠졌다 [343].

둘째, 방어 효과는 과제와 판정 모델을 넘어 일반화되지 않는 경우가 많다. 완화 프롬프트는 사실 과제(Chemistry)에서 정확도를 6–10% 올렸지만 주관적 과제(Truthy-DPO)에서는 일관된 이득이 없었고 LRM의

자기 성찰은 최대 8% 성능을 낮췄다 (본문 확인) [113]. commit-first 판정은 구간 병합 과제에서 수락을 두 시드 모두 0/96으로 없앴지만, 판정 모델의 자체 답이 틀린 두 번째 과제에서는 오히려 악화되었다 (본문 확인) [344]. 판정 모델이 스스로 풀 수 있어야 방어가 성립한다는 점은 9.2절의 조건 변수(표 9-2)와 일치한다. 구절 분류기는 학습 도메인 밖(TREC-COVID 등)에서 취약했다 (본문 확인) [336]. 프롬프트 방어는 CoT와 함께 쓸 때 효과가 거꾸로 나타나기도 했다. 설득 공격에서 CoT는 설득 문구가 근거에 섞이며 점수를 부풀렸고 [99], 시각 편향에서 CoT는 경계상자 편향을 높였다 [320] (둘 다 본문 확인). 유일한 지지 주장인 톤 무시 채점 프롬프트도 GPT-4o-mini의 뒤집힘률을 19.9%에서 1.7%로 낮췄지만, 단일 래퍼와 단일 모델에서 얻은 결과이고 바뀐 것이 톤 무시 지시만이 아니라 루브릭 전체였다 (본문 확인) [306].

셋째, 방어를 아는 공격자에 대한 시험은 근거 묶음에서 적었고, 시험한 경우에는 우회되는 결과가 보고되었다. 주입 탐지를 강화한 PromptArmor 변형은 직접 질의 주입을 거의 모두 제거했지만 질의 변형과 방해 내용에는 우회되었다 (본문 확인, 예비 실험) [311]. 기존 방어를 소표본으로 시험한 연구들도 방어가 공격을 따라가지 못함을 보였다. JudgeDeceiver에 대해 알려진 정답 탐지의 거짓 음성률은 MTBench에서 100%였다 (본문 확인) [302]. BITE는 표준 문체 통제와 여러 탐지 기준선을 회피했고 [315], Pretext는 공동 적응하는 탐지기를 상대로도 77%의 회피 성공률을 보였다 [340].

제안 방법의 지지 주장 10개는 큰 효과를 보고한다. 모델 병합은 백도어 공격 성공률을 거의 0%로 낮췄고 [329], 증거 채널 분리는 공격 성공률을 97%에서 0%로 줄였으며 [338], 패널 합의 검증은 위조 인용 공격의 84.9%를 차단했다 [327]. 그러나 이 수치는 모두 초록 기준이고, 대부분의 방어는 자신이 겨냥한 공격 계열 중심으로 보고되었다. 저자 스스로 한계를 적은 경우도 있다. 증거 채널 분리는 스캔 대상 호스트 자체가 적대자이면 실패하고 [338], 샤딩은 best-of-N 탐색에는 효과가 있지만 기준별 설득 공격에는 토론식 대립을 더해야 했다 [318]. 제안 방법 쪽 반박 2개도 있다. 하나는 앞서 본 BITE [315]로, 방어를 회피한 공격 연구다. 다른 하나는 모의 도구 호출로 입력을 격리하는 방어로, 공격 성공률을 전반적으로 낮추지 못했고 GSM8K 채점 같은 이진 과제에서는 오히려 높였다 [346].

8.3 종합

8.3.1 공격–방어 비대칭

8.2의 결과는 공격과 방어 사이의 비대칭으로 요약된다. 근거의 양에서 공격 주장은 58개, 방어 주장은 24개다. 근거의 방향에서 공격은 독립 평가로 거의 일관되게 지지되지만, 방어는 독립 평가에서 지지가 11개 중 1개에 그친다. 비대칭을 설명할 수 있는 요인으로 세 가지를 들 수 있다. 어느 것도 이 서베이가 직접 시험한 것은 아니다.

첫째, 공격은 전이되고 방어는 국소적이다. 대리 모델에서 찾은 문구 [45], 주입 [309], 서문 생성기 [308]가 다른 판정 모델로 옮겨 가는 반면, 방어는 특정 과제·모델·공격 계열에서만 효과가 확인된다.

둘째, 공격은 판정 모델의 일반 능력과 같은 곳을 노린다. 더 강한 LLM이 랭킹 하이재킹에 더 취약했다는 보고 [310]와 새 모델이나 명시적 추론이 심판 견고성을 보장하지 않는다는 보고 [326]가 이를 뒷받침한다. 판정 모델을 키우는 것만으로 해결되지 않는다는 점은 5장 Q-SCALE의 상충과도 맞닿아 있다.

셋째, 방어 평가의 기준이 비어 있다. 공격 연구는 성공률 하나로 결과를 보고할 수 있지만, 방어는 정상 성능, 비용, 적응형 공격을 함께 보고해야 의미가 있다. 방어 주장 24개를 읽은 범위에서는 이 셋을 한 연구 안에서 함께 보고한 사례가 눈에 띄게 적었다(별도로 집계하지는 않았다).

여러 판정 모델의 합의가 해결책이 된다고 보기도 어렵다. 한 연구에서 보안 게이트용 합의 패널은 오류 상관 때문에 이득이 약 2개의 유효 표에 제한되었다 [352]. 4장 `Q-MULTI`에서 같은 계열 배심의 오류 상관이 집계 이득을 지운 것과 같은 현상이다.

다만 비대칭이 방어 불가능을 뜻하지는 않는다. 효과가 컸던 것으로 보고된 방어 가운데 일부에는 공통점이 있다. 판정 모델이 공격자가 통제하는 내용을 읽지 않거나 [338], 판정 전에 독립적인 근거를 먼저 확정하거나 [344, 60], 참조 답이나 결정적 검사가 판정을 받쳐 줄 때 [351] 공격의 여지가 줄었다. 이는 서로 다른 연구의 초록 수치이고 직접 비교한 결과가 아니다. 공격자 입력을 격리한다는 같은 취지의 모의 도구 호출 방식은 효과가 없었다 [346]. 같은 조건이 성립하지 않으면 방어도 실패한다. commit-first는 판정 모델의 자체 답이 틀린 과제에서 그 오류를 물려받았다 [344].

8.3.2 자연 편향과의 연결

공격 중 여럿은 5장에서 다룬 자연 편향을 의도적으로 증폭한 것으로 읽을 수 있다. 권위 편향은 권위 신호를 이용한 공격 [322], 판정 후 대화의 권위 프레이밍 [323], 권위적 강압 [326]으로 이어진다. 아첨은 반박과 설득 압력에 판정을 번복하는 현상 [324]으로 나타나며, RoPoLL [350]은 아첨을 판정 패널을 오염시키는 실패 유형으로 다룬다. 장황함·문체 선호는 BITE [315]와 딥리서치 보고서 평가의 피상적 단서 의존 [353]에서 공격 수단이 된다. 위치 편향은 응답 순서만 바꿔 순위를 조작한 초기 결과 [14]로 이어졌고, 추론처럼 보이는 문구에 대한 반응 [109, 113]은 판정 모델이 추론의 형식을 내용의 대리 지표로 쓴다는 점을 드러낸다.

이 연결은 두 가지를 시사한다. 하나는 5장의 편향 측정이 공격면을 가늠하는 단서가 될 수 있다는 점이다. 자연 편향이 크게 측정된 판정 설정은 공격 후보가 될 수 있다. 다만 편향 크기와 공격에 필요한 탐색량의 관계는 확인된 바 없다. BITE의 제목이 말하듯 편향은 버그가 된다. 다른 하나는 편향 완화와 공격 방어가 같은 기법을 공유하면서도 같은 효과를 내지 않는다는 점이다. 6장 `Q-DEBIAS`의 근거는 대부분 제안 방법이고, 같은 프롬프트 완화가 의도적 설득 앞에서는 효과가 없거나 CoT로 오히려 악화되었다 [99]. 자연 편향의 평균적 크기를 줄이는 기법이 그 편향을 겨냥해 최적화된 입력까지 막아 주지는 않는다.

8.3.3 측정 도구로 쓰인 판정 모델

공격과 방어의 효과를 재는 도구로 판정 모델을 쓰면 같은 문제가 한 겹 더 생긴다. 레드팀 평가의 판정 모델은 분포 변화가 겹치면 우연 수준에 가깝게 떨어지고, 많은 공격이 실제 유해 콘텐츠를 끌어내기보다 판정의 부족함을 이용해 성공률을 부풀렸다 [354]. 판정 LLM만 바꿔도 보고되는 탈옥 성공률이 최대 82%p 달라졌다 [355]. 이 두 보고는 공격 성공 여부를 별도의 판정 모델이 채점하는 레드팀·탈옥 평가에 해당하며, 그런 채점에 기댄 성공률은 측정 도구 자체의 견고성을 함께 읽어야 한다. 이 장에서 인용한 성공률 가운데 그런 채점에 기댄 것이 몇 개인지는 세지 않았다.

8.4 공백과 의제

이 장에서 드러난 공백은 10장의 의제 가운데 A5에 가장 직접 연결되고, A1–A4와 A7에도 걸친다.

A5. 정상 성능을 지키는 방어. 방어 연구의 가장 큰 공백은 평가 틀이다. 본문 확인에서 방어의 비용은 재현율 하락, 사람 판단과의 MAE 증가, 추가 호출 비용으로 나타났지만 [337, 336, 347], 이를 보고한 연구는 3편뿐이었고, 나머지 방어 연구의 보고 여부는 확인하지 못했다. 방어 논문은 (1) 방어 전후 사람 판정과의 일치 변화, (2) 방어를 아는 공격자의 적응형 공격에 대한 결과, (3) 공격 대상이 아닌 과제·도메인에서의 성능을 함께 보고해야 한다. 공격 90% 초과 탐지와 정상 차단 10% 미만 같은 운영점 기준 [352]을 미리 정해 두는 방식이 하나의 출발점이 된다.

A1. 독립 재현. 방어의 지지 근거는 제안 방법에 몰려 있다. 모델 병합, 증거 채널 분리, 패널 합의 검증, Master-RM 같은 방어를 공통 공격 집합에서 다시 비교하는 독립 평가가 필요하다. RobustJudge [347]처럼 공격과 방어를 같은 틀에서 교차 평가하는 연구가 이 방향의 예다.

A2. 조건별 선택. 방어의 효과는 사실 과제와 주관적 과제 [113], 판정 모델이 스스로 풀 수 있는 과제와 그렇지 않은 과제 [344]에서 갈렸다. 판정 형식의 견고성도 공격 유형에 따라 달랐다 [39, 45]. 검증 가능성과 적대성을 축으로 판정 구성과 방어를 고르는 지침이 필요하다.

A3. 측정 표준. 공격 성공률은 채점 방식과 판정 모델 선택에 크게 좌우된다 [355, 354]. 공격 성공률을 보고할 때 그 판정 자체의 사람 일치와 거짓 양성률을 함께 보고해야 연구 간 비교가 가능하다.

A4. 이종 집계와 오류 상관. 합의 패널의 이득은 오류 상관으로 제한되며 [352], 다중 판정 구성은 위조 인용이나 토론 오염이라는 새 공격면을 만든다 [327, 328]. 집계를 방어로 쓰려면 판정 모델 간 오류 상관과 상호 참조 경로를 함께 설계해야 한다.

A7. 검증 범위 확대. 다국어 주입은 기존 방어를 회피했고 [311], 에이전트 궤적 [337, 339]과 멀티모달 판정 [320, 321]에서도 취약성이 보고되었지만, 이 영역들에서는 방어 평가가 적게 보고되었다.

요약하면, 판정 모델을 속이기 쉽다는 결론은 독립 평가의 초록 기준으로 거의 일관되게 지지되지만(49개 중 45개), 이를 막는 방어가 효과적이라는 결론은 아직 독립 평가에서 확인되지 않았다(11개 중 지지 1개). 본문 확인에서는 방어가 공격 성공률을 낮추는 대신 정상 성능, 재현율, 비용 가운데 하나를 대가로 치른 사례가 세 편 보고되었고, 과제와 판정 모델을 넘어 일반화되지 않은 사례도 여럿이었다. 판정 모델이 공격자가 통제하는 내용을 읽지 않게 하는 설계는 유망한 방향이지만, 그 근거는 제안 방법의 초록 수치이고 같은 취지의 격리 방어가 실패한 사례도 있다. 판정 모델을 이해관계가 걸린 결정에 쓰려면 이런 설계부터 독립 평가로 확인해야 한다.

9. 종합 논의

4–8장은 연구 질문마다 분류, 비교, 종합, 공백을 차례로 다뤘다. 이 장은 장을 가로질러 결과를 묶는다. 9.1은 비교 질문 12개의 결론을 연구 질문별 답으로 정리하고, 9.2는 여러 질문에 걸쳐 결과를 가르는 조건을, 9.3은 제안 방법과 독립 평가의 격차를, 9.4는 이 종합의 한계를 다룬다.

9.1 연구 질문별 답

표 9-1은 비교 질문 12개의 결론을 연구 질문 순서로 모은 것이다. 초록 기준 집계는 독립 평가와 제안 방법을 나눠 적었다. 본문 확인은 결과가 갈린 7개 질문의 독립 평가 주장 일부(99개)만 대상으로 했으므로, 셋째 열의 '–'는 본문 확인 대상이 아니어서 초록 기준 결과만 있다는 뜻이다.

표 9-1 비교 질문별 결론 (초록 기준은 "독립 평가 / 제안 방법"의 지지·반박·조건부·효과 없음 순서, 제안 방법 주장이 없으면 0)

RQ	질문	초록 기준	본문 확인 후 (독립 평가)	결론
RQ1	Q-FORMAT 쌍비교가 점수형보다 낫다	12·7·5·1 / 6·0·0·0	6·2·6·1	상충
RQ1	Q-MULTI 앙상블·토론이 단일 판정보다 낫다	14·21·20·3 / 73·1·8·0	3·5·6·1	상충, 제안 방법 쪽 치우침
RQ2	Q-SCALE 큰·강한 판정 모델일수록 낫다	42·30·15·10 / 1·1·1·0	6·6·3·0	상충
RQ2	Q-SELF 자기선호 편향은 실재한다	27·5·6·1 / 0	–	대체로 지지 (초록 기준)
RQ2	Q-HARD 어려운 과제일수록 일치도 하락	37·0·0·0 / 0	–	한 방향 (초록 기준)
RQ3	Q-COT CoT가 판정을 개선한다	10·7·7·6 / 12·0·1·0	5·4·5·1	상충
RQ3	Q-REF 정답 참조가 도움이 된다	12·5·6·0 / 12·1·2·0	8·1·5·0	대체로 지지, 조건 다수
RQ3	Q-FT 작은 파인튜닝 판정 모델이 GPT-4급에 이른다	4·2·6·0 / 114·0·4·0	–	독립 검증 공백
RQ3	Q-DEBIAS 편향 완화 기법이 효과가 있다	7·6·7·0 / 96·0·4·0	–	독립 검증 공백
RQ4	Q-EXPERT 전문가를 대신한다	22·57·53·0 / 33·0·3·0	2·7·6·0	대체로 부정
RQ5	Q-ATTACK 판정 모델 공격은 쉽다	45·1·3·0 / 8·0·1·0	–	한 방향 (초록 기준)
RQ5	Q-DEFENSE 공격 방어가 효과가 있다	1·6·4·0 / 10·2·1·0	1·4·5·0	대체로 부정·조건부

질문 12개는 네 무리로 나뉜다. 첫째는 근거가 한 방향으로 모이는 질문이다. 어려운 과제에서 일치도가 떨어진다는 것(Q-HARD, 37개 모두 지지)과 판정 모델이 싼 조작에 흔들린다는 것(Q-ATTACK, 58개 중 53개 지지)은 반박이 거의 없고, 자기선호 편향(Q-SELF, 39개 중 지지 27개)도 대체로 같은 방향이다. 다만 세 질문은 본문 확인을 하지 않았으므로 이 방향은 초록 기준이다. 둘째는 결과가 갈리거나 조건에 달린 질문이다. 모델 크기(Q-SCALE), 집계(Q-MULTI), CoT(Q-COT), 판정 형식(Q-FORMAT)은 독립 평가 안에서도 지지, 반박, 조건부가 갈린다. 정답 참조(Q-REF)는 본문 확인 14개 중 지지가 8개로 가장 많지만 조건부도 5개여서, 대체로 도움이 되되 조건에 달린 질문으로 이 무리에 넣었다.

셋째는 독립 평가에서 대체로 부정되거나 조건부인 질문이다. 전문가 대체(Q-EXPERT)는 독립 평가 132개 중 지지가 22개, 방어 효과(Q-DEFENSE)는 11개 중 1개이고, 본문 확인에서도 지지는 각각 15개 중 2개, 10개 중 1개였다. 넷째는 독립 검증이 비어 있는 질문이다. 파인튜닝 판정 모델(Q-FT)과 편향 완화(Q-DEBIAS)는 근거 대부분이 자기 방법을 제안한 논문에서 나왔고, 독립 평가는 각각 12개, 20개뿐이다. 아래에서는 이 결론을 연구 질문별로 정리한다.

RQ1. 판정 구성. 판정 형식(Q-FORMAT)과 다중 판정 집계(Q-MULTI)는 모두 결과가 갈렸다. 4.3은 이를 조건부 답으로 정리했다. 쌍비교는 비적대적 데이터에서, 앙상블은 판정자 오류가 서로 다르고 과제가 검증 가능한 경우에 낫다는 근거가 있다. 어느 형식이나 구성이 조건과 무관하게 사람 판정과 더 잘 맞는다는 근거는 이 서베이가 모은 주장에서 나오지 않았다.

RQ2. 신뢰성과 편향. 신뢰성은 대부분 사람 판정과의 일치로 재지만, 지표가 일치율, 정확도, 상관, 카파 등으로 흩어져 있고 사람끼리의 일치를 상한으로 함께 보고하는 경우는 드물다(3.6, 5.1.1). 편향 코드에서는 맹점(378편)과 기준 불일치(266편)가 위치(103편)·길이(73편) 같은 표면적 편향보다 많았다(5.3). Q-HARD는 한 방향이었지만, 명제가 넓어 어떤 조건에서든 하락을 보고하면 지지로 기록되고, 하락의 일부는 사람 판정 자체의 불확실성을 반영할 수 있다(5.2.3). Q-SCALE에서 근거가 일치하는 것은 하한 이하의 소형 모델이 나쁘다는 데까지다. 그 위에서는 크기 외 요인이 결과를 가르는 것으로 보이나, 어느 쪽이 더 크게 작용하는지는 판단할 수 없다(5.2.1). Q-SELF는 대체로 지지되지만, 강한 판정 모델의 자기선호 대부분은 실제 품질 차이로 정당화된다는 연구가 있어(5.2.2), 품질을 통제하지 않은 측정은 편향을 과대평가할 수 있다.

RQ3. 개선 기법. CoT(Q-COT)는 상충했고, 정답 참조(Q-REF)는 대체로 도움이 되었으나 판정 모델, 형식, 데이터에 따라 효과가 달랐다(6.2.1, 6.2.2, 6.3). 파인튜닝 판정 모델(Q-FT)과 편향 완화(Q-DEBIAS)는 초록 집계상 거의 일방적으로 지지되지만, 독립 평가만 보면 각각 12개 중 4개, 20개 중 7개만 지지다(6.3). 6.3은 개선이 오류 유형의 재분배나 측정 해상도 손실 같은 맞교환을 동반한 사례도 들었다.

RQ4. 응용 분야. 전문 분야에서 LLM 판정이 전문가를 대신한다는 명제(Q-EXPERT)는 독립 평가에서 대체로 부정되었다. 독립 평가 132개 중 지지는 22개이고 반박이 57개, 조건부가 53개였으며, 본문 확인 15개에서도 지지는 2개였다(7.2.1). 사실 확인 같은 객관 항목은 전문가에 가깝고 공감·위해 같은 주관 항목은 어긋났으며(7.2.4), 7장의 근거는 범용 판정 모델을 객관 항목의 선별과 순위 비교에 한정해 쓰는 쪽을 지지한다(7.3).

RQ5. 보안. 판정 모델에 대한 공격은 쉽다는 근거가 모였다(Q-ATTACK 58개 중 53개 지지, 독립 평가만 보면 49개 중 45개). 다만 본문 확인을 하지 않았고, 공격 성공률 일부는 별도의 판정 모델이 매긴 값이어서 측정 도구의 견고성도 함께 읽어야 한다(8.2.1, 8.3.3). 방어의 효과(Q-DEFENSE)는 독립 평가에서 확인되지 않았다. 독립 평가 11개 중 지지는 1개, 본문 확인 10개 중 지지도 1개였고, 효과가 확인된 방어도 정상 성능을 잃거나 특정 과제·판정 모델에서만 효과를 냈다(8.2.2). 공격 중 여럿은 5장의 자연 편향(권위, 아첨, 장황함·문체 선호)을 의도적으로 증폭한 것으로 읽을 수 있어(8.3.2), 신뢰성과 보안은 겹치는 문제로 볼 수 있다.

9.2 결과를 가르는 조건

본문으로 확인한 주장 99개에서 결과를 바꾸는 조건을 기록해 묶으면, 같은 조건 변수가 여러 질문에 걸쳐 반복해서 나타난다(표 9-2). 각 변수의 근거는 4–8장의 해당 절에서 다뤘으므로, 여기서는 변수가 어느 질문에

걸치는지와 장별 결론에 붙은 단서를 정리한다. 이 표는 조건이 반복해서 기록되었음을 보여 줄 뿐이며, 각 변수가 상충의 어느 정도를 설명하는지는 계산하지 않았다.

표 9-2 여러 질문에 걸친 조건 변수

조건 변수	나타난 질문	결과가 갈리는 방식
과제의 검증 가능성	Q-REF, Q-COT, Q-MULTI, Q-EXPERT	정답이 있는 과제에서 참조·CoT·집계의 지지 결과가 모이고, 주관적 기준에서는 효과가 없거나 해롭다. 검증 가능한 과제 안에서도 반례가 있어 충분조건은 아니다
판정 모델이 스스로 풀 수 있는가	Q-REF, Q-MULTI, Q-DEFENSE	판정 모델이 풀지 못하는 문항에서 참조가 정보를 보태고, 스스로 먼저 풀게 하면 집계의 사각지대가 줄며, 자기 답을 먼저 확정하는 방어는 그 답이 틀리면 실패한다
평가 지표	Q-SCALE, Q-EXPERT, Q-FORMAT	순위상관으로는 높고 카파로는 낮다. 형식마다 지표가 달라 직접 비교가 어렵다
데이터의 적대성·유형	Q-FORMAT, Q-REF, Q-SCALE	일반 데이터와 적대적 데이터에서 형식·참조의 효과가 뒤집힌다
모델 계열·학습 데이터	Q-SCALE, Q-REF	하한 이상에서는 크기 외 요인이 결과를 가르는 것으로 보이며(크기와 어느 쪽이 큰지는 판단할 수 없다), 같은 기법이 모델마다 반대로 작용한다
판정 모델 간 오류 상관	Q-MULTI	동종 배심은 오류가 강하게 상관해 집계 이득이 작고, 이종 혼합만으로는 충분하지 않다
정상 성능과의 맞교환	Q-DEFENSE	일부 방어는 공격을 줄이는 대신 정상 성능, 사람 일치, 재현율을 잃는다

과제의 검증 가능성은 가장 많은 질문에 걸친다. 집계에서는 검증 가능한 답이 있는 루브릭에서 앙상블이 사람 수준에 이르지만 주관적 루브릭에서는 그렇지 않았고(4.3), CoT와 참조는 수학, 코드, 번역처럼 정답이나 검증 절차가 있는 과제에서 지지 결과가 모였으며(6.3), 전문 분야에서도 객관 항목은 맞고 주관 항목은 어긋났다(7.2.4). 그러나 검증 가능한 과제 안에서도 소형 판정 모델의 수학 판정처럼 추론이 과잉사고로 이어진 사례가 있다. 6.3의 정리대로 검증 가능성은 효과의 충분조건이 아니라 효과가 나타나는 데 유리한 조건에 가깝다.

판정 모델이 스스로 풀 수 있는가는 참조, 집계, 방어에 함께 걸친다. 참조는 판정 모델이 스스로 풀지 못하는 문항에서 정답 정보를 보태고(6.3), 판정자가 자기 답을 먼저 확정하게 하면 앙상블이 놓치던 오답이 줄며(4.3), 자기 답을 먼저 확정하는 commit-first 방어는 판정 모델의 자체 답이 틀린 과제에서 오히려 악화되었다(8.2.2). 본문 확인 대상은 아니지만, 5.2.3은 Q-HARD의 일치도 하락을 설명할 수 있는 하나로 같은 변수를 들었다.

평가 지표는 같은 결과를 다르게 읽게 한다. 같은 판정이 상관이나 순위상관으로는 높고 카파로는 낮게 나올 수 있고(5.1.1, 7.2.5), 쌍비교 정확도와 점수 일치율은 척도와 우연 수준이 달라 형식 비교를 어렵게 한다(4.3).

데이터의 적대성은 판정 형식과 참조의 우열을 바꾼다. 쌍비교는 일반 데이터에서 점수형보다 낫지만 적대적 데이터에서는 더 나빠지고(4.3), 참조는 원본 표본에서 정확도를 높이지만 편향을 유도한 표본에서는 편향을 키운다(6.2.2). 4.3은 이와 별도로, best-of-2와 best-of-4 사이에서 형식의 우열이 뒤집힌 평가 설정과 비용도 조건으로 들었다.

모델 계열과 학습 데이터는 크기와 얽혀 있다. 하한 이하의 소형 모델은 분명히 나쁘지만, 그 위에서는 계열, 학습 데이터, 과제 같은 크기 외 요인이 결과를 가르는 것으로 보인다. 다만 5.2.1의 결론대로 크기와 이 요인 중 어느 쪽이 더 크게 작용하는지는 현재 근거로 판단할 수 없고, 크기가 결정 요인이 아니라는 결과도 그 원인을

특정 학습 전략으로 돌린 부분은 통제 실험 없이 서술로만 제시되었다(5.2.1). 정답 노출의 효과가 판정 모델에 따라 부호가 바뀐 결과(6.3)는 같은 기법이 모델마다 반대로 작용할 수 있음을 보여 준다.

판정 모델 간 오류 상관은 집계의 이득을 제한한다. 동종 배심은 오류 상관이 높아 배심 크기를 키워도 정확도가 거의 오르지 않았다(4.3). 이종 모델을 섞어 나아진 사례가 있지만, 이종 배심도 독립 가정이 예측하는 이득에는 못 미쳐 섞는 것만으로는 충분하지 않았다(4.2.2, 4.3).

정상 성능과의 맞교환은 방어 연구에서 반복된다. 본문으로 확인한 방어 10개 중 3개는 공격 성공률을 낮추는 대신 정상 성능, 사람 판단과의 일치, 재현율을 잃었고, 방어 8종을 비교한 연구는 견고성, 정상 성능, 비용 사이의 최적 맞교환을 이룬 방어가 없다고 보고했다(8.2.2). 6.3도 개선 기법이 오류 유형의 재분배나 과교정 같은 맞교환을 동반한 사례를 들었다.

이 변수들을 함께 보면, "LLM 판정이 믿을 만한가"는 판정 모델 하나의 성질보다 과제, 데이터, 지표, 판정 모델의 조합에 대한 질문에 가깝다. 평균 성능 하나로 판정 모델을 고르면 이 조합이 가려진다.

9.3 제안 방법과 독립 평가의 격차

다섯 질문에서 제안 방법 쪽 근거와 독립 평가 쪽 근거가 서로 다른 그림을 보인다. 격차는 두 유형이다.

첫째는 방향의 차이다. 앙상블·토론(Q-MULTI)은 제안 방법 주장 82개 중 73개가 지지하지만 독립 평가 58개 중 지지는 14개이고, 본문 확인 15개에서는 3개였다(4.2.2, 4.3). 전문가 대체(Q-EXPERT)는 제안 방법 36개 중 33개가 지지하지만 독립 평가 132개 중 지지는 22개, 본문 확인 15개 중 2개다(7.2.1). 방어(Q-DEFENSE)는 제안 방법 13개 중 10개가 지지하지만 독립 평가는 11개 중 1개, 본문 확인은 10개 중 1개다(8.2.2). 세 질문 모두에서 본문 확인은 이 차이를 좁히지 않았다.

둘째는 독립 근거의 부족이다. 파인튜닝 판정 모델(Q-FT)은 근거 130개 중 독립 평가가 12개, 편향 완화(Q-DEBIAS)는 120개 중 20개다. 제안 방법 쪽은 각각 118개 중 114개, 100개 중 96개가 지지인데, 독립 평가만 보면 지지는 12개 중 4개, 20개 중 7개다(6.2.3, 6.2.4, 6.3). 두 질문은 본문 확인을 하지 않았으므로 이 대비는 초록 수준의 관찰이다.

이 격차는 문헌의 구성과 함께 읽어야 한다. 3장에서 보았듯 포함 논문의 51.5%가 판정 방식을 제안하는 논문이다(3.2). 출판 관행이 제안 방법 쪽 지지의 쏠림에 영향을 줬을 수 있지만, 이 서베이는 그 원인을 확인하지 않았다. 다만 제안 방법의 효과를 모아 세면 기법의 효과가 과대평가될 수 있다. 이 서베이가 근거를 제안 방법과 독립 평가로 나눈 것은 이 치우침을 드러내기 위해서이며, 같은 구분은 이후 서베이와 메타평가에도 필요하다.

9.4 이 종합의 한계

먼저 집계의 대부분이 초록 기준이라는 점을 고려해야 한다. 본문으로 확인한 99개 안에서 초록은 방향을 뒤집어 쓰지는 않았지만, 조건을 지우고 일반화하는 경향이 있었다. 99개 중 75개는 초록 주장 그대로였고 24개는 일부 조건에서만 성립했으며, 본문이 초록과 반대인 경우는 없었다. 이 중 11개는 본문 기준 방향이 바뀌었고(partly 7개, confirmed 4개), 그중 9개는 조건부로 옮겨 갔다(2.5).

이 결과는 두 가지를 뜻한다. 첫째, 초록만으로 만든 집계는 조건부 결과를 과소평가할 수 있다. 결과가 갈린 7개 질문은 표 9-1의 본문 확인 열을 기준으로 읽어야 하고, 본문 확인을 하지 않은 5개 질문(Q-HARD, Q-ATTACK, Q-SELF, Q-FT, Q-DEBIAS)의 집계도 같은 방식으로 조건부 결과를 과소평가하고 있을 수 있다. 9.1의 한 방향 결론에 초록 기준이라는 단서를 붙인 것은 이 때문이다. 둘째, LLM 판정 연구를 인용할 때 "X가 판정을 개선한다"는 초록의 문장을 조건 없이 옮기면 오해를 만들 수 있다. 9.2의 조건 변수는 이런 인용을 점검하는 목록으로 쓸 수 있다.

본문 확인 표본에도 한계가 있다. 표본은 질문마다 방향별 비율로 나누되 인용이 많은 순으로 골랐으므로, 인용이 적은 최근 논문의 결과는 덜 반영되었을 수 있다. 본문을 읽을 수 있는 arXiv와 ACL Anthology 논문으로 한정해(99개 중 arXiv 95개, ACL Anthology 4개), 저널 논문과 다른 분야의 관행을 대표하지 못할 수 있다. 본문 확인은 사람이 아니라 LLM 서브에이전트가 했고 사람이 따로 검수하지 않았으며, 7개 질문의 선정도 정량 기준이 아니라 집계를 읽은 판단이다(2.5).

그 밖의 한계, 곧 선별·추출·주장 기록의 1차 작업을 LLM이 한 점, 집계가 효과 크기가 아니라 주장의 개수라는 점, 애매로 남은 1,868편을 검토하지 않은 점, 포함 논문의 62.7%가 arXiv 프리프린트라는 점은 2.6에 적었다. 여기에 포함 논문의 54.6%가 2026년 논문이어서(3.1), 결과 일부는 동료 심사나 후속 재현을 거치며 바뀔 수 있다.

10. 연구 의제

9장의 연구 질문별 답(9.1절), 조건 변수(9.2절), 제안 방법과 독립 평가의 격차(9.3절)와 3장의 문헌 분포에서 일곱 개의 연구 의제를 끌어낸다. 각 의제는 근거가 된 장과 함께, 바로 시작할 수 있는 연구의 형태로 적는다.

A1. 독립 재현과 보고 기준

근거. 앙상블·토론(제안 방법 82개 중 지지 73개, 독립 평가 58개 중 지지 14개), 전문가 대체(36개 중 33개, 132개 중 22개), 방어(13개 중 10개, 11개 중 1개)는 제안 방법과 독립 평가의 방향이 달랐다. 파인튜닝 판정 모델(근거 130개 중 독립 평가 12개)과 편향 완화(120개 중 20개)는 독립 근거 자체가 적다 (4장, 6–8장, 9.3절).

의제. 제안된 판정 모델과 개선 기법을 같은 벤치마크, 같은 판정 대상, 같은 지표로 다시 비교하는 재현 연구가 필요하다. 아울러 판정 연구의 최소 보고 항목을 정해야 한다. 판정 모델의 정확한 버전, 사람끼리의 일치(상한), 두 개 이상의 일치 지표, 표본 수와 시드, 실패 사례의 분포가 그 후보다. 초록에 판정 모델을 특정한 논문이 드물고 버전 없이 쓴 이름이 섞여 있다는 3장의 초록 기준 집계는 이 항목이 필요한 이유를 보여 준다.

A2. 조건별 판정 모델 선택과 층화 메타평가

근거. 과제의 검증 가능성은 참조·CoT·집계의, 판정 모델이 스스로 풀 수 있는지는 참조·집계·방어의, 데이터의 적대성은 형식·참조의 효과를 가른다 (9.2절).

의제. 판정 모델과 기법을 평균 성능 하나로 비교하지 말고, 이 조건 변수를 축으로 층을 나눈 메타평가가 필요하다. 예컨대 같은 판정 모델을 검증 가능한 과제와 주관적 과제, 판정 모델이 풀 수 있는 문항과 풀 수 없는 문항, 일반 표본과 적대적 표본으로 나눠 평가하는 벤치마크다. 그 결과는 "어떤 과제에서는 쌍비교, 어떤 과제에서는 참조 기반 점수형"처럼 조건별 선택 지침으로 이어질 수 있다.

A3. 측정의 표준화

근거. 사람 판정과 비교한 논문의 지표가 일치율, 정확도, 카파, 종류를 밝히지 않은 상관, Spearman·Pearson 같은 상관 계수로 흩어져 있고, 같은 결과가 지표에 따라 다르게 읽힌다 (3.6절, 5장, 9.2절).

의제. 사람끼리의 일치를 상한으로 두고 그 대비 상대 일치로 보고하는 방식, 인스턴스 수준과 시스템 수준 지표를 함께 보고하는 방식, 우연 일치를 보정한 지표를 기본으로 쓰는 방식을 표준으로 정할 필요가 있다. 판정 형식마다 지표가 달라 쌍비교와 점수형을 직접 비교할 수 없다는 문제(4장)도 같은 표준으로 풀 수 있다.

A4. 이종 집계와 오류 상관

근거. 같은 판정 모델이나 같은 계열로 만든 배심은 오류 상관이 높아 집계 이득이 작다. 이종 모델을 섞어 나아진 사례가 있지만, 이종 배심도 독립 가정이 예측하는 이득에는 못 미쳐 섞는 것만으로는 충분하지 않다 (4.2.2절, 4.3절, 9.2절).

의제. 배심을 구성하기 전에 판정 모델 간 오류 상관을 측정하고, 상관이 낮은 조합을 고르는 방법이 필요하다. 판정 모델의 다양성이 계열, 학습 데이터, 프롬프트 중 어디에서 오는지를 분해하는 연구, 그리고 집계가 언제

단일 최선 모델보다 나은지를 사전에 예측하는 기준이 의제가 된다.

A5. 정상 성능을 지키는 방어

근거. 공격 근거 58개 중 53개가 공격이 쉽다고 지지하지만, 방어 근거는 24개이고 독립 평가 11개 중 지지는 1개뿐이며 나머지는 반박이나 조건부다. 방어는 공격을 줄이는 대신 사람 일치나 재현율을 잃는다 (8장, 9.3절).

의제. 방어를 평가할 때 적응형 공격(방어를 아는 공격자)에 대한 견고성과 방어 전후의 사람 일치 변화를 함께 보고하는 평가 틀이 필요하다. 판정 대상 응답 안의 지시를 판정 지시와 분리하는 구조적 방어, 그리고 자연 발생 편향(권위, 아첨, 길이)이 공격 경로로 이어진다는 점(8.3.2절, 9.1절)을 이용해 편향 완화와 방어를 함께 다루는 연구가 의제다.

A6. 전문 분야의 분담 판정

근거. 전문 분야에서 LLM 판정이 전문가를 대신한다는 명제는 독립 평가 132개 중 22개만 지지하고 나머지는 반박이나 조건부이며, 객관 항목은 맞고 주관·고위험 항목은 어긋난다. 어려운 과제일수록 일치가 떨어진다는 결과도 같은 방향이다 (5장, 7장).

의제. LLM 판정을 전문가의 대체물이 아니라 분담자로 설계하는 연구가 필요하다. 사실 확인이나 형식 점검처럼 객관적인 항목은 LLM이 맡고, 공감·위험·임상 판단처럼 주관적이거나 고위험인 항목은 전문가가 맡는 분업, 그리고 판정 모델이 확신하지 못하는 사례를 사람에게 넘기는 판정 보류(abstention) 기준이 그 예다. 이때 "어느 전문가를 기준으로 삼는가"에 따라 결론이 달라진다는 점(7장)도 설계에 반영해야 한다.

A7. 검증 범위의 확대

근거. 에이전트형 판정 176편 중 사람 판정과 대조한 연구는 89편이고, 영어 외 언어를 다룬 연구는 250편 (11.4%)이다. 번역, 법, 금융 분야의 연구는 각각 3% 미만이다 (3장, 7장).

의제. 에이전트의 행동 궤적을 판정하는 모델을 사람 판정과 대조하는 연구, 다국어·저자원 언어와 다문화 맥락의 판정 연구, 오류 비용이 큰 법·금융 분야의 판정 연구가 필요하다. 5장과 6장의 결론이 영어 밖에서도 성립하는지는 현재 근거로 말할 수 없다.

의제 사이의 관계

일곱 의제는 독립적이지 않다. A1(재현)과 A3(측정의 표준화)는 나머지 의제의 전제다. 같은 지표와 같은 조건으로 재현할 수 없으면 A2의 조건별 지침도, A4의 집계 기준도, A5의 방어 평가도 논문마다 다른 결론으로 이어질 수 있다. A2(조건별 선택)는 A6(전문 분야 분담)과 A7(검증 범위)을 묶는 틀이 된다. 전문 분야와 저자원 언어는 조건 변수의 한 값으로 다룰 수 있기 때문이다. 이 판단에 따르면 가장 먼저 필요한 것은 조건 변수로 층을 나누고, 사람 간 일치를 상한으로 보고하며, 제안 방법을 함께 재현하는 공용 메타평가 기반이다.

11. 결론

이 서베이는 2023년 1월부터 2026년 10월까지의 LLM-as-a-Judge 문헌 2,185편을 판정 구성, 신뢰성과 편향, 개선 기법, 응용 분야, 보안의 다섯 축으로 분류하고, 결론이 갈리는 질문 12개에 대한 주장 928개를 지지·반박·조건부·효과 없음으로 집계했으며, 결과가 갈린 7개 질문은 독립 평가 주장 99개를 본문으로 확인해 결과를 바꾸는 조건을 기록했다.

다섯 연구 질문에 대한 답은 다음과 같다. RQ1(판정 구성)에서 판정 형식과 다중 판정 집계는 결과가 갈렸다. 쌍비교는 비적대적 데이터에서, 앙상블은 판정자 오류가 서로 다르고 과제가 검증 가능한 경우에 낫다는 근거가 있다. RQ2(신뢰성과 편향)에서 신뢰성을 재는 지표는 표준 없이 흩어져 있고, 판정 신뢰도는 과제가 어려울수록 떨어지며, 모델 크기는 하한을 넘은 뒤에는 결과를 일관되게 가르지 못했다. 자기선호 편향은 대체로 확인되지만, 한 연구는 강한 판정 모델의 자기선호 대부분이 실제 품질 차이로 정당화된다고 보고했다. RQ3(개선 기법)에서 CoT는 상충했고 정답 참조는 대체로 도움이 되었으나 조건에 달렸으며, 파인튜닝 판정 모델과 편향 완화는 독립 검증이 부족했다. 개선이 맞교환을 동반한 사례도 있었다. RQ4(응용 분야)에서 LLM 판정이 전문가를 대신한다는 명제는 독립 평가에서 대체로 부정되었고(132개 중 지지 22개), 쓸 수 있는 범위는 객관 항목의 선별과 순위 비교에 가까웠다. RQ5(보안)에서 판정 모델에 대한 공격은 쉬웠지만(58개 중 지지 53개), 방어의 효과는 독립 평가에서 확인되지 않았다(11개 중 지지 1개).

장을 가로지르면 세 가지 결론이 나온다. 첫째, 근거가 한 방향으로 모이는 결과가 있다. LLM 판정의 신뢰도는 과제가 어려워질수록 떨어지고, 판정 모델은 적은 비용의 조작에 쉽게 흔들린다. 다만 이 두 결과와 자기선호 편향은 본문 확인을 거치지 않은 초록 기준이다. 둘째, 결과가 갈리거나 조건에 달린 질문의 상충은 과제의 검증 가능성, 판정 모델이 스스로 풀 수 있는지, 평가 지표, 데이터의 적대성, 판정 모델 간 오류 상관 같은 조건 변수와 함께 나타났다. 이 변수가 상충의 어느 정도를 설명하는지는 계산하지 않았다. 셋째, 앙상블·토론, 전문가 대체, 방어는 제안 방법 쪽 근거와 독립 평가의 방향이 달랐고, 파인튜닝 판정 모델과 편향 완화는 독립 평가 자체가 적었다.

이 서베이는 LLM 서브에이전트로 선별·추출·주장 기록과 본문 확인을 하고, 사람은 선별 판정을 표본으로 검수했다. 추출과 주장 기록은 시범 배치 검토와 형식 검사로 확인했다. 판정 연구를 정리하면서 판정을 LLM에 맡긴 셈이다. 선별 단계의 사람 일치율(98.5%, 포함·제외 판정 200편 표본)은 이 방식이 선별에서 쓸 만할 수 있다는 부분적 근거가 된다. 본문 확인에서 본문이 초록과 반대인 경우는 없었지만, 99개 중 11개는 방향이 바뀌었고 24개는 일부 조건에서만 성립했다. 초록에 기댄 주장 기록은 조건을 놓칠 수 있다는 뜻이다. 이 본문 확인도 LLM이 했으므로, LLM이 기록한 주장의 정확도를 사람이 검증한 결과는 아니다. 애매 판정, 추출·주장 기록, 본문 확인은 사람이 검수하지 않았다. 선별 과정에서 LLM 작업자가 근거 문장을 되풀이하거나 결과를 섞은 사례도 있어, 문헌 정리 도구에도 판정 모델과 비슷한 한계가 있을 수 있다.

따라서 "LLM 판정을 믿을 수 있는가"라는 질문에는 하나의 답이 없다. 답은 과제, 데이터, 지표, 판정 모델의 조합에 따라 달라진다(9.2절). 이 서베이가 제시한 일곱 개의 연구 의제, 곧 독립 재현과 보고 기준, 조건별 판정 모델 선택과 층화 메타평가, 측정의 표준화, 이종 집계와 오류 상관, 정상 성능을 지키는 방어, 전문 분야의 분담 판정, 검증 범위의 확대는 이 조합을 드러내고 다루기 위한 것이다.

참고문헌

1. Lianmin Zheng, Wei-Lin Chiang, Ying Sheng 외 (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. arXiv. arXiv:2306.05685
2. Yang Liu, Dan Iter, Yichong Xu 외 (2023). G-Eval: NLG Evaluation using GPT-4 with Better Human Alignment. arXiv. arXiv:2303.16634
3. Seungone Kim, Jamin Shin, Yejin Cho 외 (2023). Prometheus: Inducing Fine-grained Evaluation Capability in Language Models. International Conference on Learning Representations. arXiv:2310.08491
4. Nathan Lambert, Valentina Pyatkin, Jacob Daniel Morrison 외 (2024). RewardBench: Evaluating Reward Models for Language Modeling. arXiv.org. arXiv:2403.13787
5. Jiawei Gu, Xuhui Jiang, Zhichao Shi 외 (2024). A Survey on LLM-as-a-Judge. arXiv. arXiv:2411.15594
6. Dawei Li, Bohan Jiang, Liangjie Huang 외 (2024). From Generation to Judgment: Opportunities and Challenges of LLM-as-a-judge. arXiv. arXiv:2411.16594
7. Haitao Li, Qian Dong, Junjie Chen 외 (2024). LLMs-as-Judges: A Comprehensive Survey on LLM-based Evaluation Methods. arXiv. arXiv:2412.05579
8. Yixin Cao, Shibo Hong, Xinze Li 외 (2025). Toward Generalizable Evaluation in the LLM Era: A Survey Beyond Benchmarks. arXiv. arXiv:2504.18838
9. Fangyi Yu (2025). When AIs Judge AIs: The Rise of Agent-as-a-Judge Evaluation for LLMs. arXiv.org. arXiv:2508.02994
10. Hugo Silva, Mateus Mendes, Hugo Gonçalo Oliveira (2026). Meta-Judging with Large Language Models: Concepts, Methods, and Challenges. arXiv. arXiv:2601.17312
11. Aiman Al Masoud, Antony Anju, Marco Arazzi 외 (2026). Security in LLM-as-a-Judge: A Comprehensive SoK. arXiv. arXiv:2603.29403
12. Lingyao Li, Deyi Li, Chen Chen 외 (2026). LLM-as-a-Judge in Healthcare: A Scoping Analysis of Applications, Methods, and Human Alignment. arXiv. arXiv:2605.25273
13. Junda He, Jieke Shi, Terry Yue Zhuo 외 (2025). LLM-as-a-Judge for Software Engineering: Literature Review, Vision, and the Road Ahead. arXiv. arXiv:2510.24367
14. Peiyi Wang, Lei Li, Liang Chen 외 (2023). Large Language Models are not Fair Evaluators. Annual Meeting of the Association for Computational Linguistics. arXiv:2305.17926
15. Anisha Gunjal, Anthony Wang, Elaine Lau 외 (2025). Rubrics as Rewards: Reinforcement Learning Beyond Verifiable Domains. arXiv. arXiv:2507.17746
16. Paul Thomas, S. Spielman, Nick Craswell 외 (2023). Large Language Models can Accurately Predict Searcher Preferences. Annual International ACM SIGIR Conference on Research and Development in Information Retrieval. arXiv:2309.10621
17. Jon Saad-Falcon, O. Khattab, Christopher Potts 외 (2023). ARES: An Automated Evaluation Framework for Retrieval-Augmented Generation Systems. North American Chapter of the Association for Computational Linguistics. arXiv:2311.09476
18. Tom Kocmi, C. Federmann (2023). Large Language Models Are State-of-the-Art Evaluators of Translation Quality. European Association for Machine Translation Conferences/Workshops. arXiv:2302.14520
19. Anna Bavaresco, Raffaella Bernardi, Leonardo Bertolazzi 외 (2024). LLMs instead of Human Judges? A Large Scale Empirical Study across 20 NLP Evaluation Tasks. Annual Meeting of the Association for Computational Linguistics. arXiv:2406.18403
20. Sewon Min, Kalpesh Krishna, Xinxi Lyu 외 (2023). FActScore: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation. Conference on Empirical Methods in Natural Language Processing. arXiv:2305.14251
21. Charles Godfrey, Ping Nie, Natalia Ostapuk 외 (2025). Likert or Not: LLM Absolute Relevance Judgments on Fine-Grained Ordinal Scales. arXiv. arXiv:2505.19334
22. Pat Verga, Sebastian Hofstatter, Sophia Althammer 외 (2024). Replacing Judges with Juries: Evaluating LLM Generations with a Panel of Diverse Models. arXiv. arXiv:2404.18796
23. Chi-Min Chan, Weize Chen, Yusheng Su 외 (2023). ChatEval: Towards Better LLM-based Evaluators through Multi-Agent Debate. arXiv. arXiv:2308.07201

24. Akbir Khan, John Hughes, Dan Valentine 외 (2024). Debating with More Persuasive LLMs Leads to More Truthful Answers. International Conference on Machine Learning. arXiv:2402.06782
25. Seungone Kim, Juyoung Suk, Shayne Longpre 외 (2024). Prometheus 2: An Open Source Language Model Specialized in Evaluating Other Language Models. Conference on Empirical Methods in Natural Language Processing. arXiv:2405.01535
26. Xiusi Chen, Gaotang Li, Zi-Qi Wang 외 (2025). RM-R1: Reward Modeling as Reasoning. arXiv.org. arXiv:2505.02387
27. Zijun Liu, Pei-Yi Wang, Run-Xin Xu 외 (2025). Inference-Time Scaling for Generalist Reward Modeling. arXiv.org. arXiv:2504.02495
28. Jerry W. Wei, Chengrun Yang, Xinying Song 외 (2024). Long-form factuality in large language models. Neural Information Processing Systems. arXiv:2403.18802
29. Tianci Xue, Weijian Qi, Tianneng Shi 외 (2025). An Illusion of Progress? Assessing the Current State of Web Agents. COLM 2025. arXiv:2504.01382
30. Xing Han Lù, Amirhossein Kazemnejad, Nicholas Meade 외 (2025). AgentRewardBench: Evaluating Automatic Evaluations of Web Agent Trajectories. arXiv. arXiv:2504.08942
31. Dongping Chen, Ruoxi Chen, Shilin Zhang 외 (2024). MLLM-as-a-Judge: Assessing Multimodal LLM-as-a-Judge with Vision-Language Benchmark. arXiv. arXiv:2402.04788
32. Ishaan Watts, Varun Gumma, Aditya Yadavalli 외 (2024). PARIKSHA: A Large-Scale Investigation of Human-LLM Evaluator Agreement on Multilingual and Multi-Cultural Data. arXiv. arXiv:2406.15053
33. Ruihang Li, Leigang Qu, Jingxu Zhang 외 (2026). GenArena: How Can We Achieve Human-Aligned Evaluation for Visual Generation Tasks?. arXiv. arXiv:2602.06013
34. Hongchao Jiang, Yiming Chen, Yushi Cao 외 (2025). CodeJudgeBench: Benchmarking LLM-as-a-Judge for Coding Tasks. arXiv. arXiv:2507.10535
35. Chenxi Whitehouse, Sebastian Ruder, Tony Lin 외 (2025). MENLO: From Preferences to Proficiency -- Evaluating and Modeling Native-like Quality Across 47 Languages. arXiv. arXiv:2509.26601
36. Yinhong Liu, Han Zhou, Zhijiang Guo 외 (2024). Aligning with Human Judgement: The Role of Pairwise Preference in Large Language Model Evaluators. arXiv. arXiv:2403.16950
37. Takumi Shibata, Yuichi Miyamura (2025). LCES: Zero-shot Automated Essay Scoring via Pairwise Comparisons Using Large Language Models. arXiv. arXiv:2505.08498
38. Isik Baran Sandan, Tu Anh Dinh, Jan Niehues (2025). Knockout LLM Assessment: Using Large Language Models for Evaluations through Iterative Pairwise Comparisons. arXiv. arXiv:2506.03785
39. Tuhina Tripathi, Manya Wadhwa, Greg Durrett 외 (2025). Pairwise or Pointwise? Evaluating Feedback Protocols for Bias in LLM-Based Evaluation. arXiv. arXiv:2504.14716
40. Yi Chen, Rui Wang, Haiyun Jiang 외 (2023). Exploring the Use of Large Language Models for Reference-Free Text Quality Evaluation: An Empirical Study. International Joint Conference on Natural Language Processing. arXiv:2304.00723
41. Maike Züfle, Patrícia Schmidtová, Vilém Zouhar 외 (2026). Calibrating LLM Judges for Human and AI Conversations. arXiv. arXiv:2609.29431
42. Hawon Jeong, ChaeHun Park, Jimin Hong 외 (2024). The Comparative Trap: Pairwise Comparisons Amplifies Biased Preferences of LLM Evaluators. arXiv. arXiv:2406.12319
43. Eddie Landesberg (2026). When LLM Judge Scores Look Good but Best-of-N Decisions Fail. arXiv. arXiv:2603.12520
44. Adian Liusie, Potsawee Manakul, M. Gales (2023). LLM Comparative Assessment: Zero-shot NLG Evaluation through Pairwise Comparisons using Large Language Models. Conference of the European Chapter of the Association for Computational Linguistics. arXiv:2307.07889
45. Vyas Raina, Adian Liusie, Mark Gales (2024). Is LLM-as-a-Judge Robust? Investigating Universal Adversarial Attacks on Zero-shot LLM Assessment. arXiv. arXiv:2402.14016
46. Shu Pu, Yaochen Wang, Dongping Chen 외 (2025). Judge Anything: MLLM as a Judge Across Any Modality. Knowledge Discovery and Data Mining. arXiv:2503.17489
47. Lukas Gienapp, Tim Hagen, Maik Fröbe 외 (2025). The Viability of Crowdsourcing for RAG Evaluation. Annual International ACM SIGIR Conference on Research and Development in Information Retrieval. arXiv:2504.15689

48. Lovedeep Gondara, Jekaterina Novikova, Sagarika Suresh 외 (2026). The Format is the Filter: Scoring Format Fixes What an LLM Judge Can Express. arXiv. arXiv:2610.17158
49. Atul Anand (2026). Ask Which, Not How Good: Sizing Benchmarks Scored by an LLM. arXiv. arXiv:2609.27787
50. Yu Li, Shen-Yu Zhang, Rui Wu 외 (2024). MATEval: A Multi-Agent Discussion Framework for Advancing Open-Ended Text Evaluation. International Conference on Database Systems for Advanced Applications. arXiv:2403.19305
51. Abir Harrasse, Chaithanya Bandi, Hari Bandi (2024). Debate, Deliberate, Decide (D3): A Cost-Aware Adversarial Framework for Reliable and Interpretable LLM Evaluation. EACL 2026. arXiv:2410.04663
52. Xinghua Zhang, Bowen Yu, Haiyang Yu 외 (2023). Wider and Deeper LLM Networks are Fairer LLM Evaluators. arXiv. arXiv:2308.01862
53. Zheng Wu, Yibo Luo, Pu Zhang 외 (2026). Beyond a Single Judge: The Evidence-Grounded, Social-Weighted Persona Panel for Generative UI Evaluation. arXiv. arXiv:2607.28439
54. Manar Hamed, Nora Kasiem, Mariem Abdou 외 (2025). Adversarial Shield: Using Large Language Models to Enhance Response Security Against Adversarial Attacks. International journal of intelligent engineering and systems. doi:10.22266/ijies2025.0930.50
55. Guneet Kohli (2026). Nine Judges, Two Effective Votes: Correlated Errors Undermine LLM Evaluation Panels. arXiv. arXiv:2605.29800
56. David Antonio Tomé (2026). Six Nameplates, Two Effective Votes: A Pre-Registered Local Replication of Correlated LLM Judge Errors, with a Deterministic Instrument for Measuring Panel Independence. arXiv (Cornell University). doi:10.5281/zenodo.21737025
57. Elias Hossain, Niloofar Yousefi, Ser-Nam Lim (2026). Agreement Overstates Evidence: Error Dependence in LLM Judge Consensus. arXiv. arXiv:2609.22512
58. Zongyou Yang, Yinghan Hou, Xiaokun Yang (2026). When the Judge Changes, So Does the Measurement: Auditing LLM-as-Judge Reliability. arXiv. arXiv:2607.08535
59. Robert Richardson (2026). What Predicts Correctness in Text-to-SQL? A Selective-Prediction Study. arXiv. arXiv:2607.06799
60. Chenyu Zhou (2026). More Convincing, Not More Correct: Self-Play Reward Hacking of Reference-Free LLM Judges. arXiv. arXiv:2607.05904
61. Sourabrata Mukherjee, Hamna Hamna, Kalika Bali 외 (2026). The Geometry of LLM-as-Judge: Why Inter-LLM Consensus Is Not Human Alignment. arXiv. arXiv:2606.03043
62. Minsoo Song, Chanwoo Kim, Sugyeong Eo 외 (2026). Beyond Consensus: Downward Bias and Role Asymmetry in Multi-Agent LLM Judges for Subjective Evaluation. arXiv. arXiv:2608.30373
63. Anish Laddha, Nitesh Pradhan, Gaurav Srivastava (2026). SLMJury: Can Small Language Models Judge as Well as Large Ones?. arXiv. arXiv:2606.07810
64. Chiyu Ma, Enpei Zhang, Yilun Zhao 외 (2025). Judging with Many Minds: Do More Perspectives Mean Less Prejudice? On Bias Amplification and Resistance in Multi-Agent Based LLM-as-Judge. Underline Science Inc.. doi:10.18653/v1/2025.findings-emnlp.941
65. Mohammad Reza Modarres, Armin Tourajmehr, Yadollah Yaghoobzadeh 외 (2026). CLIN: an Objective Framework for Evaluating Creativity in Short Persian Literary Text. arXiv. arXiv:2608.30754
66. Zachary Kenton, Noah Y. Siegel, János Kramár 외 (2024). On scalable oversight with weak LLMs judging strong LLMs. arXiv. arXiv:2407.04622
67. Lujun Li, Lama Sleem, Yangjie Xu 외 (2026). The Necessity of Setting Temperature in LLM-as-a-Judge. arXiv. arXiv:2603.28304
68. Yangda Peng, Yunjia Qi, Haotian Xia 외 (2026). Can LLM-as-a-Judge Reliably Verify Rubrics in Agentic Scenarios?. arXiv. arXiv:2606.29920
69. Hongyu Chen, Seraphina Goldfarb-Tarrant (2025). Safer or Luckier? LLMs as Safety Evaluators Are Not Robust to Artifacts. arXiv. arXiv:2503.09347
70. Samee Arif, Sualeha Farid, Abdul Hameed Azeemi 외 (2024). The Fellowship of the LLMs: Multi-Model Workflows for Synthetic Preference Optimization Dataset Generation. arXiv. arXiv:2408.08688

71. Kaihua Ding (2026). When LLMs Agree, Are They Right? Auditing Self-Consistency and Cross-Model Agreement as Confidence Signals. arXiv. arXiv:2607.08065
72. Peter Organisciak, Maggie Ryan, Mina Ghobadi (2026). Can LLMs Simulate Expert Panels? Evaluating CAT-Inspired Persona Prompting for Automated Creativity Scoring. ACM/IEEE Joint Conference on Digital Libraries. doi:10.1145/3805696.3846028
73. Suryaansh Jain, Umair Z. Ahmed, Shubham Sahai 외 (2025). Beyond Consensus: Mitigating the Agreeableness Bias in LLM Judge Evaluations. arXiv. arXiv:2510.11822
74. Claudiu Creanga, Liviu P. Dinu (2026). LLM-as-a-Judge for Low-Resource Languages: Adapting Ragas and Comparative Ranking for Romanian. arXiv. arXiv:2610.00406
75. Renato Aparecido Gomes (2026). Agreement Is Not Truth: How LLM Juries Converge Confidently on Legally False Answers. Zenodo (CERN European Organization for Nuclear Research). doi:10.5281/zenodo.21154330
76. Sebastian Fox, Luke Markham, Ryan Lail 외 (2026). LLM Judges Verify Presence, Not Absence: Omission Blindness in AI Clinical Notes and What Recovers It. arXiv. arXiv:2608.31016
77. Steve Han, Gilberto Titericz Junior, Tom Balough 외 (2025). Judge's Verdict: A Comprehensive Analysis of LLM Judge Capability Through Human Agreement. arXiv. arXiv:2510.09738
78. Giuseppe Crupi, Rosalia Tufano, Alejandro Velasco 외 (2025). On the Effectiveness of LLM-as-a-judge for Code Generation and Summarization. arXiv. arXiv:2507.16587
79. Tianjun Wei, Wei Wen, Ruizhi Qiao 외 (2025). RocketEval: Efficient Automated LLM Evaluation via Grading Checklist. arXiv. arXiv:2503.05142
80. S. Bedi, Hejie Cui, Miguel Fuentes 외 (2025). MedHELM: Holistic Evaluation of Large Language Models for Medical Tasks. arXiv.org. arXiv:2505.23802
81. Jiaan Wang, Yun-Long Liang, Fan-Dong Meng 외 (2023). Is ChatGPT a Good NLG Evaluator? A Preliminary Study. NEWSUM. arXiv:2303.04048
82. Sijun Tan, Siyuan Zhuang, Kyle Montgomery 외 (2024). JudgeBench: A Benchmark for Evaluating LLM-based Judges. arXiv. arXiv:2410.12784
83. Zhaorun Chen, Yi-Chao Du, Zichen Wen 외 (2024). MJ-Bench: Is Your Multimodal Reward Model Really a Good Judge for Text-to-Image Generation?. arXiv.org. arXiv:2407.04842
84. Lei Li, Yuancheng Wei, Zhihui Xie 외 (2024). VL-RewardBench: A Challenging Benchmark for Vision-Language Generative Reward Models. Computer Vision and Pattern Recognition. arXiv:2411.17451
85. Yann Dubois, Bal'azs Galambosi, Percy Liang 외 (2024). Length-Controlled AlpacaEval: A Simple Way to Debias Automatic Evaluators. arXiv.org. arXiv:2404.04475
86. Benjamin Feuer, Micah Goldblum, Teresa Datta 외 (2024). Style Outweighs Substance: Failure Modes of LLM Judges in Alignment Benchmarking. arXiv. arXiv:2409.15268
87. Rickard Stureborg, Dimitris Alikaniotis, Yoshi Suhara (2024). Large Language Models are Inconsistent and Biased Evaluators. arXiv. arXiv:2405.01724
88. Yiqi Liu, N. Moosavi, Cheng-Hua Lin (2023). LLMs as Narcissistic Evaluators: When Ego Inflates Evaluation Scores. Annual Meeting of the Association for Computational Linguistics. arXiv:2311.09766
89. Arjun Panickssery, Samuel R. Bowman, Shi Feng (2024). LLM Evaluators Recognize and Favor Their Own Generations. arXiv. arXiv:2404.13076
90. Arash Marioriyad, Mohammad Hossein Rohban, Mahdieh Soleymani Baghshah (2025). The Silent Judge: Unacknowledged Shortcut Bias in LLM-as-a-Judge. 39th Conference on Neural Information Processing System, 2025, Workshop: Reliable ML from Unreliable Data. arXiv:2509.26072
91. Sungwon Kim, Daniel Khashabi (2025). Challenging the Evaluator: LLM Sycophancy Under User Rebuttal. Conference on Empirical Methods in Natural Language Processing. arXiv:2509.16533
92. Rishav Hada, Varun Gumma, Adrian de Wynter 외 (2023). Are Large Language Model-based Evaluators the Solution to Scaling Up Multilingual Evaluation?. arXiv. arXiv:2309.07462
93. Chenhui Shen, Liying Cheng, Xuan-Phi Nguyen 외 (2023). Large Language Models are Not Yet Human-Level Evaluators for Abstractive Summarization. Findings of EMNLP 2023. arXiv:2305.13091

94. Gladys Tyen, H. Mansoor, Peter Chen 외 (2023). LLMs cannot find reasoning errors, but can correct them!. Annual Meeting of the Association for Computational Linguistics. arXiv:2311.08516
95. Laura Dietz, Bryan Li, Eugene Yang 외 (2026). Insider Knowledge: How Much Can RAG Systems Gain from Evaluation Secrets?. arXiv. arXiv:2601.13227
96. Vansh Wahi (2026). LLM-as-a-Judge Is Not an Oracle: Why Self-Improving Agents Need Deterministic Guardrails. arXiv. arXiv:2609.02246
97. Lin Shi, Chiyu Ma, Wenhua Liang 외 (2024). Judging the Judges: A Systematic Study of Position Bias in LLM-as-a-Judge. arXiv. arXiv:2406.07791
98. Qingquan Li, Shaoyu Dou, Kailai Shao 외 (2025). Evaluating Scoring Bias in LLM-as-a-Judge. arXiv. arXiv:2506.22316
99. Yerin Hwang, Dongryeol Lee, Taegwan Kang 외 (2025). Can You Trick the Grader? Adversarial Persuasion of LLM Judges. arXiv. arXiv:2508.07805
100. Hyein Seo, Taewook Hwang, Jeesu Jung 외 (2025). Large Language Models as Evaluators in Education: Verification of Feedback Consistency and Accuracy. Applied Sciences. doi:10.3390/app15020671
101. Yella Diekmann, Chase Fensore, Rodrigo M. Carrillo-Larco 외 (2025). LLMs as Medical Safety Judges: Evaluating Alignment with Human Annotation in Patient-Facing QA. BioNLP@ACL. doi:10.18653/v1/2025.bionlp-1.19
102. Dawei Li, Renliang Sun, Yue Huang 외 (2025). Preference Leakage: A Contamination Problem in LLM-as-a-judge. arXiv. arXiv:2502.01534
103. Yushi Hu, Reyhane Askari-Hemmat, Melissa Hall 외 (2025). Multimodal RewardBench 2: Evaluating Omni Reward Models for Interleaved Text and Image. arXiv. arXiv:2512.16899
104. Zheheng Luo, Qianqian Xie, Sophia Ananiadou (2024). Factual consistency evaluation of summarization in the Era of large language models. arXiv. arXiv:2402.13758
105. Shenbin Qian, Archchana Sindhujan, Minnie Kabra 외 (2024). What do Large Language Models Need for Machine Translation Evaluation?. arXiv. arXiv:2410.03278
106. Rohith Reddy Bellibatlu, Edward Raff, Wenbin Zhang (2026). JudgeSense: A Benchmark for Prompt Sensitivity in LLM-as-a-Judge Systems. arXiv. arXiv:2604.23478
107. Jiayi Ye, Yanbo Wang, Yue Huang 외 (2024). Justice or Prejudice? Quantifying Biases in LLM-as-a-Judge. arXiv. arXiv:2410.02736
108. Delip Rao, Chris Callison-Burch (2026). Decision Models vs. LLMs as Rubric Judges: Cheaper, Faster, and Wrong in the Same Places. arXiv. arXiv:2609.29769
109. Qian Wang, Zhanzhi Lou, Zhenheng Tang 외 (2025). Assessing Judging Bias in Large Reasoning Models: An Empirical Study. arXiv. arXiv:2504.09946
110. Gemma Zhang, Prachi Badarayani, Asmi Kumar 외 (2026). Can We Trust LLM Judges: A Study of Capability-Dependent Biases and Multi-Judge Ensemble for Bias Calibration. arXiv. arXiv:2609.12002
111. Jhen-Ke Lin (2026). Grading Needs a Rubric, Not Intelligence. arXiv:2608.17938
112. Laurène Vaugrante, Thilo Hagendorff (2026). How Much Do LLM-as-a-Judge Design Choices Matter? A Systematic Comparison of Prompt Designs, Rating Scales, and Models. arXiv. arXiv:2610.05094
113. Qian Wang, Zhen-Heng Tang, Z. Lou 외 (2025). Towards Evaluting Fake Reasoning Bias in Language Models. arXiv:2507.13758
114. Evangelia Spiliopoulou, Riccardo Fogliato, Hanna Burnsky 외 (2025). Play Favorites: A Statistical Method to Measure Self-Bias in LLM-as-a-Judge. arXiv. arXiv:2508.06709
115. José Pombal, Ricardo Rei, André F. T. Martins (2026). Self-Preference Bias in Rubric-Based Evaluation of Large Language Models. arXiv. arXiv:2604.06996
116. David Ababio Awuni, Luke E. K. Achenie, Benjamin Tei Partey 외 (2026). Who Judges Matters: Measuring Family-Conditioned Preference in LLM-as-Judge Panels. arXiv. arXiv:2609.17857
117. Shashwat Goel, Joschka Struber, Ilze Amanda Auzina 외 (2025). Great Models Think Alike and this Undermines AI Oversight. arXiv. arXiv:2502.04313
118. Shuitsu Koyama, Yuiga Wada, Daichi Yashima 외 (2026). MLLM-as-a-Judge Exhibits Model Preference Bias. arXiv.org. arXiv:2604.11589

119. Yi Zhao, Siqi Wang, Zhe Hu 외 (2026). A Visually Impaired Assistance Benchmark for VLM-as-a-Judge Evaluation. arXiv.org. arXiv:2605.31351
120. Yen-Shan Chen, Jing Jin, Peng-Ting Kuo 외 (2024). LLMs are Biased Evaluators But Not Biased for Retrieval Augmented Generation. arXiv. arXiv:2410.20833
121. Xanh Ho, Jiahao Huang, Florian Boudin 외 (2025). Reassessing Extractive QA Datasets at Scale: LLM-as-a-Judge and In-Depth Analyses. arXiv. arXiv:2504.11972
122. Amy Rouillard, S. Mundia, Linda Camara 외 (2026). Can LLMs Accurately Score Medical Diagnoses and Clinical Reasoning?. Conference on Artificial Intelligence in Medicine in Europe. arXiv:2604.14892
123. Abdullah Al Rabeyah, Fabrício Góes, Marco Volpe 외 (2024). Do LLMs Agree on the Creativity Evaluation of Alternative Uses?. arXiv. arXiv:2411.15560
124. Sriram Selvam, Anneswa Ghosh (2026). Eval-Pair Matrix: Answer-Paired Meta-Evaluation of LLM Judges for Grounded RAG. arXiv. arXiv:2607.10626
125. Dani Roytburg, Matthew Bozoukov, Matthew Nguyen 외 (2026). Are LLM Evaluators Really Narcissists? Sanity Checking Self-Preference Evaluations. arXiv. arXiv:2601.22548
126. Songeun Chae, Min Kim, Donghoon Jung 외 (2026). Self- and Other-Labels Induce Bidirectional Bias in LLM Judges. arXiv. arXiv:2608.18091
127. Muskan Saraf, Sajjad Rezvani Boroujeni, Justin Beaudry 외 (2025). Quantifying Label-Induced Bias in Large Language Model Self- and Cross-Evaluations. arXiv. arXiv:2508.21164
128. Liang Wang, Junpeng Wang, Chin-chia Michael Yeh 외 (2026). Understanding LLM Evaluator Behavior: A Structured Multi-Evaluator Framework for Merchant Risk Assessment. arXiv. arXiv:2602.05110
129. Wei-Lin Chen, Zhepei Wei, Xinyu Zhu 외 (2025). Do LLM Evaluators Prefer Themselves for a Reason?. arXiv. arXiv:2504.03846
130. Association for Computational Linguistics 2025, Gaur, Vedant, Goyal, Tanya 외 (2025). The Progress Illusion: Revisiting meta-evaluation standards of LLM evaluators. Underline Science Inc.. doi:10.48448/we46-vf16
131. Umesh Bodhwani, Thanh Tran, Kai Wei (2026). GAUGE: When Not to Trust LLM-as-a-Judge in User-Simulated Evaluation of Task-Oriented Agents. arXiv. arXiv:2609.12191
132. Ahrii Kim (2025). RUBRIC-MQM : Span-Level LLM-as-judge in Machine Translation For High-End Models. Annual Meeting of the Association for Computational Linguistics (ACL). doi:10.18653/v1/2025.acl-industry.12
133. Tianjun Pan, Xuan Lin, Wenyan Yang 외 (2026). RubricEval: A Rubric-Level Meta-Evaluation Benchmark for LLM Judges in Instruction Following. arXiv. arXiv:2603.25133
134. Henry Bergman (2026). Reliability and construct validity of a multi-model LLM-as-judge evaluator battery for clinician-facing clinical question answering: a controlled adversarial benchmark study (Preprint). doi:10.2196/preprints.112207
135. Haotian Deng, Chris Farber, Jiyoon Lee 외 (2025). Rubric-Conditioned LLM Grading: Alignment, Uncertainty, and Robustness. arXiv. arXiv:2601.08843
136. Michael Krumdick, Charles Lovering, Varshini Reddy 외 (2025). No Free Labels: Limitations of LLM-as-a-Judge Without Human Grounding. arXiv. arXiv:2503.05061
137. Andreas Stephan, Dawei Zhu, Matthias Aßenmacher 외 (2024). From Calculation to Adjudication: Examining LLM judges on Mathematical Reasoning Tasks. arXiv. arXiv:2409.04168
138. Abhigya Verma, Amit Kumar Saha, Seganrasan Subramanian 외 (2026). AgentJudgeBench: A Multi-Difficulty Benchmark for Evaluating LLM Judges on Agentic Tool-Calling. arXiv. arXiv:2608.26623
139. Bruno Brocai, Maria Becker (2026). Pair Difficulty Matters: Rethinking Pairwise LLM-as-a-Judge Evaluation and Consistency. arXiv. arXiv:2609.37577
140. Ruichen Zheng, Yihe Wang, Fabrice Y Harel-Canada 외 (2026). Does Reasoning Improve Psychological Depth in Large Language Models? It Depends on Who's Judging. arXiv. arXiv:2609.13773
141. Xiyan Fu, Wei Liu (2025). How Reliable is Multilingual LLM-as-a-Judge?. arXiv. arXiv:2505.12201
142. Saravanan Srinivasan (2026). Verify Before You Act: Human-audited Evaluation. Zenodo (CERN European Organization for Nuclear Research). doi:10.5281/zenodo.22891935

143. Seonghyeon Ye, Doyoung Kim, Sungdong Kim 외 (2023). FLASK: Fine-grained Language Model Evaluation based on Alignment Skill Sets. International Conference on Learning Representations. arXiv:2307.10928

144. Giulio Starace, Oliver Jaffe, Dane Sherburn 외 (2025). PaperBench: Evaluating AI's Ability to Replicate AI Research. arXiv. arXiv:2504.01848

145. Han Zhou, Xingchen Wan, Yinhong Liu 외 (2024). Fairer Preferences Elicit Improved Human-Aligned Large Language Model Judgments. arXiv. arXiv:2406.11370

146. David Salinas, Omar Swelam, Frank Hutter (2025). Tuning LLM Judge Design Decisions for 1/1000 of the Cost. arXiv. arXiv:2501.17178

147. Tianhao Wu, Weizhe Yuan, Olga Golovneva 외 (2024). Meta-Rewarding Language Models: Self-Improving Alignment with LLM-as-a-Meta-Judge. Conference on Empirical Methods in Natural Language Processing. arXiv:2407.19594

148. Karthik Valmeekam, Matthew Marquez, Subbarao Kambhampati (2023). Can Large Language Models Really Improve by Self-critiquing Their Own Plans?. arXiv.org. arXiv:2310.08118

149. Peng Lai, Jianjie Zheng, Sijie Cheng 외 (2025). Beyond the Surface: Enhancing LLM-as-a-Judge Alignment with Human via Internal Representations. arXiv. arXiv:2508.03550

150. Shuqian Sheng, Yi Xu, Tianhang Zhang 외 (2024). RepEval: Effective Text Evaluation with LLM Representation. arXiv. arXiv:2404.19563

151. Zhenwen Liang, Ruosen Li, Yujun Zhou 외 (2025). CLUE: Non-parametric Verification from Experience via Hidden-State Clustering. arXiv. arXiv:2510.01591

152. Shreya Shankar, J. D. Zamfirescu-Pereira, Björn Hartmann 외 (2024). Who Validates the Validators? Aligning LLM-Assisted Evaluation of LLM Outputs with Human Preferences. arXiv. arXiv:2404.12272

153. Jie Ren, Yao Zhao, Tu Vu 외 (2023). Self-Evaluation Improves Selective Generation in Large Language Models. ICBINB. arXiv:2312.09300

154. Toufique Ahmed, Premkumar Devanbu, Christoph Treude 외 (2024). Can LLMs Replace Manual Annotation of Software Engineering Artifacts?. arXiv. arXiv:2408.05534

155. Yubo Li, Yidi Miao, Ramayya Krishnan 외 (2026). JEV-as-a-Judge: Accept When Confident, Escalate When Unsure. arXiv. arXiv:2609.26550

156. Andrea Piergentili, Beatrice Savoldi, Matteo Negri 외 (2025). An LLM-as-a-judge Approach for Scalable Gender-Neutral Translation Evaluation. arXiv. arXiv:2504.11934

157. Cheng-Han Chiang, Hung-yi Lee (2023). A Closer Look into Using Large Language Models for Automatic Evaluation. doi:10.18653/v1/2023.findings-emnlp.599

158. Wenbo Zhang, Lijinghua Zhang, Liner Xiang 외 (2026). Reasoning Is Not Free: Robust Adaptive Cost-Efficient Routing for LLM-as-a-Judge. arXiv. arXiv:2605.10805

159. Eugenio Herrera-Berg, Tomás Vergara Browne, Pablo León-Villagrá 외 (2023). Large Language Models are biased to overestimate profoundness. https://aclanthology.org/2023.emnlp-main.599. arXiv:2310.14422

160. William Orwig, Roger E. Beaty (2026). How LLMs See Creativity: Zero-Shot Scoring of Visual Creativity with Interpretable Reasoning. arXiv. arXiv:2606.29672

161. Abdul Waheed, Zhen Wu, Dareen Alharthi 외 (2025). VideoJudge: Bootstrapping Enables Scalable Supervision of MLLM-as-a-Judge for Video Understanding. arXiv. arXiv:2509.21451

162. Ante Kapetanovic, Kemal Altwlkany, Andro Mercep 외 (2026). Anchoring Bias in LLM-as-a-Judge Systems: Prior Scores Compromise Evaluation Independence. arXiv. arXiv:2608.25869

163. Haolin Jin, Hua-Min Chen (2026). Are LLMs reliable code reviewers? systematic overcorrection in requirement conformance judgement. International Conference on Automated Software Engineering. arXiv:2603.00539

164. Yusuke Yamauchi, Taro Yano, Masafumi Oyamada (2025). An Empirical Study of LLM-as-a-Judge: How Design Choices Impact Evaluation Reliability. arXiv. arXiv:2506.13639

165. Victor Wang, Michael J. Q. Zhang, Eunsol Choi (2025). Improving LLM-as-a-Judge Inference with the Judgment Distribution. arXiv. arXiv:2503.03064

166. KuanChao Chu, Yi-Pei Chen, Hideki Nakayama (2024). A Better LLM Evaluator for Text Generation: The Impact of Prompt Output Sequencing and Optimization. arXiv. arXiv:2406.09972

167. Zachary Ankner, Mansheej Paul, Brandon Cui 외 (2024). Critique-out-Loud Reward Models. arXiv.org. arXiv:2408.11791

168. Yutong Wang, Pengliang Ji, Chaoqun Yang 외 (2025). MCTS-Judge: Test-Time Scaling in LLM-as-a-Judge for Code Correctness Evaluation. arXiv. arXiv:2502.12468

169. Yue Yu, Zhengxing Chen, Aston Zhang 외 (2024). Self-Generated Critiques Boost Reward Modeling for Language Models. NAACL 2025. arXiv:2411.16646

170. Hui Huang, Yancheng He, Hongli Zhou 외 (2025). Think-J: Learning to Think for Generative LLM-as-a-Judge. arXiv. arXiv:2505.14268

171. Will Yeadon, Tom Hardy, Paul Mackay 외 (2026). LLM-as-a-judge validity is strongly task-dependent across physics assessment formats. arXiv. arXiv:2603.14732

172. Xu Huang, Zhirui Zhang, Xiang Geng 외 (2024). Lost in the Source Language: How Large Language Models Evaluate the Quality of Machine Translation. Annual Meeting of the Association for Computational Linguistics. arXiv:2401.06568

173. Chalamalasetti Kranti, Sowmya Vajjala (2026). LLM Judges Can Be Too Generous When There Is No Reference Answer. arXiv. arXiv:2607.12885

174. Junjie Chen, Yuxi Dong, Haitao Li 외 (2026). Benchmarking LLM-as-a-Judge for Long-Form Output Evaluation. arXiv. arXiv:2606.01629

175. Antonio Laverghetta, Tuhin Chakrabarty, Tom Hope 외 (2025). How do Humans and Language Models Reason About Creativity? A Comparative Analysis. arXiv. arXiv:2502.03253

176. Jiayi Chang, Mingqi Gao, Xinyu Hu 외 (2025). Exploring the Multilingual NLG Evaluation Abilities of LLM-Based Evaluators. arXiv. arXiv:2503.04360

177. W. P. Li, Xintao Wang, Siyu Yuan 외 (2025). Curse of Knowledge: Your Guidance and Provided Knowledge are biasing LLM Judges in Complex Evaluation. Underline Science Inc.. doi:10.18653/v1/2025.findings-emnlp.805

178. Mukul Chhabra, Shail Patel, Luigi Medrano (2026). CARGO: Context-Aware Retrieval-Gated Evaluation of Agentic AI in Production. arXiv. arXiv:2609.30471

179. Pete Sherratt (2026). Contextual Conclusion Capture: Conflicting Conclusions Degrade LLM Judge Discrimination Across Reasoning Domains. Zenodo (CERN European Organization for Nuclear Research). doi:10.5281/zenodo.21878046

180. Xinxi Lyu, Yizhong Wang, Hannaneh Hajishirzi 외 (2024). HREF: Human Response-Guided Evaluation of Instruction Following in Language Models. arXiv. arXiv:2412.15524

181. Jung In Park, Mahyar Abbasian, Iman Azimi 외 (2024). Building Trust in Mental Health Chatbots: Safety Metrics and LLM-Based Evaluation Tools. arXiv. arXiv:2408.04650

182. S. K. Fianko, Augustine Addo, K. Agyemang 외 (2026). A comparative pilot study of the accuracy consistency and marking scheme responsiveness of AI chatbots and human evaluators in professional accounting assessment. Discover Education. doi:10.1007/s44217-026-01837-8

183. Qiyuan Zhang, Yufei Wang, Tiezheng YU 외 (2024). RevisEval: Improving LLM-as-a-Judge via Response-Adapted References. arXiv. arXiv:2410.05193

184. Nikhil Chandak, Shashwat Goel, Ameya Prabhu 외 (2025). Answer Matching Outperforms Multiple Choice for Language Model Evaluation. arXiv. arXiv:2507.02856

185. Aashish Yadavally, Hoan Nguyen, Laurent Callot 외 (2025). Large Language Model Critics for Execution-Free Evaluation of Code Changes. arXiv.org. arXiv:2501.16655

186. Aniruddha Tamhane, Raghavendra Addanki, Ayushi Aggarwal 외 (2026). Skill-based Agentic Evaluation for Real-time Data Science Tasks. arXiv. arXiv:2609.16487

187. Arther Tian, Alex Ding, Frank Chen 외 (2026). PoQ-Judge: A Multi-Architecture Evaluation Framework for Cost-Aware Proof-of-Quality in Decentralized LLM Inference. arXiv. arXiv:2606.11196

188. Yidong Wang, Zhuohao Yu, Wen-Jin Yao 외 (2023). PandaLM: An Automatic Evaluation Benchmark for LLM Instruction Tuning Optimization. International Conference on Learning Representations. arXiv:2306.05087

189. Lianghui Zhu, Xinggang Wang, Xinlong Wang (2023). JudgeLM: Fine-tuned Large Language Models are Scalable Judges. arXiv. arXiv:2310.17631

190. Tu Vu, Kalpesh Krishna, Salaheddin Alzubi 외 (2024). Foundational Autoraters: Taming Large Language Models for Better Automatic Evaluation. arXiv. arXiv:2407.10817

191. Nuo Chen, Zhiyuan Hu, Qingyun Zou 외 (2025). JudgeLRM: Large Reasoning Models as a Judge. arXiv. arXiv:2504.00050

192. Chenxi Whitehouse, Tianlu Wang, Ping Yu 외 (2025). J1: Incentivizing Thinking in LLM-as-a-Judge via Reinforcement Learning. arXiv. arXiv:2505.10320

193. Dakota Mahan, Duy Van Phung, Rafael Rafailov 외 (2024). Generative Reward Models. arXiv. arXiv:2410.12832

194. Hui Huang, Xingyuan Bu, Hongli Zhou 외 (2024). An Empirical Study of LLM-as-a-Judge for LLM Evaluation: Fine-tuned Judge Model is not a General Substitute for GPT-4. arXiv. arXiv:2403.02839

195. Janvijay Singh, Austin Xu, Yilun Zhou 외 (2025). On the Shelf Life of Fine-Tuned LLM-Judges: Future-Proofing, Backward-Compatibility, and Question Generalization. arXiv. arXiv:2509.23542

196. Rodrigo de Oliveira, Federico Pittino, James Gwinnutt 외 (2026). Beyond Correctness: Validity-Oriented Evaluation of Biomedical LLM Judges. arXiv. arXiv:2608.29127

197. Xuzhao Li, Xuchen Li, Shiyu Hu 외 (2025). VerifyBench: A Systematic Benchmark for Evaluating Reasoning Verifiers Across Domains. arXiv. arXiv:2507.09884

198. Irune Zubiaga, Aitor Soroa, Rodrigo Agerri (2026). Towards Reliable Multilingual LLMs-as-a-Judge: An Empirical Study. arXiv. arXiv:2605.28710

199. Tianyang Xu, Jing Gao (2026). Auditing Failure Attribution: Label Predictability and Judge Behavior. arXiv. arXiv:2610.17747

200. Zaruhi Navasardyan, Tatul Danielyan, Hrant Davtyan (2026). FailBench: How Reliable are VLMs at Judging Robot Task Success?. arXiv:2609.03611

201. Yuxia Wang, Haonan Li, Xudong Han 외 (2024). Do-Not-Answer: Evaluating Safeguards in LLMs. Findings. doi:10.18653/v1/2024.findings-eacl.61

202. Tongxin Yuan, Zhiwei He, Lingzhong Dong 외 (2024). R-Judge: Benchmarking Safety Risk Awareness for LLM Agents. arXiv. arXiv:2401.10019

203. Rui Ai, Yuqing Liu, Sitao Qiu 외 (2026). LLMAdBench: A Human Preference Benchmark for Advertising in LLM Responses. arXiv. arXiv:2609.32533

204. sambhav shrestha (2026). Can LLMs Judge Argument Quality? Evaluating Large Language Models on Argument Convincingness Ranking. Zenodo (CERN European Organization for Nuclear Research). doi:10.5281/zenodo.20673056

205. Zongjie Li, Chaozheng Wang, Pingchuan Ma 외 (2023). Split and Merge: Aligning Position Biases in LLM-based Evaluators. arXiv. arXiv:2310.01432

206. Swarnadeep Saha, Omer Levy, Asli Celikyilmaz 외 (2023). Branch-Solve-Merge Improves Large Language Model Evaluation and Generation. North American Chapter of the Association for Computational Linguistics. arXiv:2310.15123

207. Gerrit J. J. van den Burg, Gen Suzuki, Wei Liu 외 (2025). Aligning Black-box Language Models with Human Judgments. North American Chapter of the Association for Computational Linguistics. arXiv:2502.04997

208. Dani Roytburg, Matthew Bozoukov, Matthew Nguyen 외 (2025). Breaking the Mirror: Activation-Based Mitigation of Self-Preference in LLM Evaluators. arXiv. arXiv:2509.03647

209. Siyu Chen, Matthew Hayes, Amber Long 외 (2025). Bias-Aware LLM-as-a-Judge with Position-Invariant Pairwise Evaluation and Confidence Calibration. Journal of Information Systems and Business Technology

210. Sourabrata Mukherjee, Sunayana Sitaram (2026). Opening LLM Judges: Recovering Preference Signals Beyond the Final Verdict. arXiv. arXiv:2609.32407

211. Parisa Rabbani, Priyam Sahoo, Ruben Mathew 외 (2026). DialDefer: A Framework for Detecting and Mitigating LLM Dialogic Deference. ACL 2026 - Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). arXiv:2601.10896

212. Xiaosen Zheng, Tianyu Pang, Chao Du 외 (2024). Cheating Automatic LLM Benchmarks: Null Models Achieve High Win Rates. International Conference on Learning Representations. arXiv:2410.07137

213. Roland Daynauth, Christopher Clarke, Krisztian Flautner 외 (2025). SLMEval: Entropy-Based Calibration for Human-Aligned Evaluation of Large Language Models. arXiv. arXiv:2505.16003

214. Fabian Lukassen, Christoph Weisser, Alexander Silbersdorff (2026). Cheap, Consistent, Calibrated, but Biased? Typed Decision Models as Judges. arXiv. arXiv:2610.18122

215. Jiaqing Zhang, Sandeep Elluri, Bhanu Cherukuvada 외 (2026). Auditing Multimodal LLM Raters: Central Tendency Bias in Clinical Ordinal Scoring. arXiv. arXiv:2605.16386

216. Jian Xu, Delu Zeng, John Paisley 외 (2026). When Can You Debias an LLM Judge? Identifiability Limits, a Test, and Designs for Top-k Ranking. arXiv. arXiv:2607.02104

217. Delip Rao, Chris Callison-Burch (2026). Autorubric: A Unifying Framework for Rubric-Based LLM Evaluation on Non-Verifiable Tasks. arXiv. arXiv:2603.00077

218. Liang Zhao, Yong Wang, Jiangzhe Chen (2026). Debiasing as a Measurement Intervention: Calibrated Ties and Resolution Loss in LLM-as-a-Judge Evaluation. arXiv. arXiv:2609.12439

219. Sadman Kabir Soumik (2026). Judging the Judges: A Systematic Evaluation of Bias Mitigation Strategies in LLM-as-a-Judge Pipelines. Transactions on Machine Learning Research (2026). arXiv:2604.23178

220. Ayako Sato, Hwichan Kim, Zhousi Chen 외 (2026). Exploring the Effects of Alignment on Numerical Bias in Large Language Models. arXiv. arXiv:2601.16444

221. Nguyen Dung Son, Dang Quang Minh, Nguyen Huu Loi 외 (2026). How Far Can Sub-3B Open Language Models Go in Zero-Shot Essay Scoring on an 8 GB Consumer GPU?. arXiv. arXiv:2609.20250

222. Cheng-Han Chiang, Hung-yi Lee (2023). Can Large Language Models Be an Alternative to Human Evaluations?. arXiv. arXiv:2305.01937

223. Jian Zhao, Runze Liu, Kaiyan Zhang 외 (2025). GenPRM: Scaling Test-Time Compute of Process Reward Models via Generative Reasoning. AAAI Conference on Artificial Intelligence. arXiv:2504.00891

224. Ruiyang Zhou, Lu Chen, Kai Yu (2024). Is LLM a Reliable Reviewer? A Comprehensive Evaluation of LLM on Automatic Paper Reviewing Tasks. International Conference on Language Resources and Evaluation. doi:10.63317/48d359hjdvog

225. Theresa Isabelle Wilhelm, Jonas Roos, Robert Kaczmarczyk (2023). Large Language Models for Therapy Recommendations Across 3 Clinical Specialties: Comparative Study. Journal of Medical Internet Research. doi:10.2196/49324

226. Cheol Ryu, Seolhwa Lee, Subeen Pang 외 (2023). Retrieval-based Evaluation for LLMs: A Case Study in Korean Legal QA. Natural Legal Language Processing Workshop (NLLP). doi:10.18653/v1/2023.nllp-1.13

227. Sheng-Jie Ma, Qi-Zhi Chu, Jiaxin Mao 외 (2024). Leveraging Large Language Models for Relevance Judgments in Legal Case Retrieval. arXiv.org. arXiv:2403.18405

228. Peter Organisciak, Selçuk Acar, Denis Dumas 외 (2023). Beyond semantic distance: Automated scoring of divergent thinking greatly improves with large language models. Thinking Skills and Creativity. doi:10.1016/j.tsc.2023.101356

229. Kaushal Kumar Maurya, KV Aditya Srivatsa, Kseniia Petukhova 외 (2024). Unifying AI Tutor Evaluation: An Evaluation Taxonomy for Pedagogical Ability Assessment of LLM-Powered AI Tutors. North American Chapter of the Association for Computational Linguistics. arXiv:2412.09416

230. Zhilin Wang, Jaehun Jung, Ximing Lu 외 (2025). ProfBench: Multi-Domain Rubrics requiring Professional Knowledge to Answer and Judge. arXiv. arXiv:2510.18941

231. Tianyi Xiong, Xiyao Wang, Dong Guo 외 (2024). LLLaVA-Critic: Learning to Evaluate Multimodal Models. Computer Vision and Pattern Recognition. arXiv:2410.02712

232. Harrison Lee, Samrat Phatale, H. Mansoor 외 (2023). RLAIF vs. RLHF: Scaling Reinforcement Learning from Human Feedback with AI Feedback. International Conference on Machine Learning. arXiv:2309.00267

233. Lijun Li, Bowen Dong, Ruohui Wang 외 (2024). SALAD-Bench: A Hierarchical and Comprehensive Safety Benchmark for Large Language Models. arXiv. arXiv:2402.05044

234. Kate H. Bentley, Luca Belli, Adam M. Chekroud 외 (2026). AI Chatbot Suicide Risk Detection and Response: Human Validation Study of the Open-Source VERA-MH Safety Evaluation. JMIR AI. 2026;5. arXiv:2602.05088

235. Beidi Luan, Rui Sun, Sinuo Wang 외 (2026). FinResearchBench II: A Deep Research Benchmark with Consensus-Derived Gold Rubrics for Distinguishing Financial Report Quality. arXiv. arXiv:2607.12252

236. Emma Croxford, Yanjun Gao, Elliot First 외 (2025). Evaluating clinical AI summaries with large language models as judges. npj Digital Medicine. doi:10.1038/s41746-025-02005-2

237. David Wu, Fateme Nateghi Haredasht, David Wu 외 (2025). Automated Evaluation of Large Language Model Response Concordance with Human Specialist Responses on Physician-to-Physician eConsult Cases. medRxiv. doi:10.1101/2025.08.14.25332839

238. Bowen Long, Fangya Tan, Jinghang Zhang (2026). Evaluating U.S. Federal Zoonotic Records Against National One Health Goals: A Multi-LLM Assessment Across COVID-19, Monkeypox, and H5N1. Zoonotic Diseases. doi:10.3390/zoonoticdis6040040

239. Tu Anh Dinh, Carlos Mullov, Leonard Bärmann 외 (2024). SciEx: Benchmarking Large Language Models on Scientific Exams with Human Expert Grading and Automatic Grading. arXiv. arXiv:2406.10421

240. Annalisa Szymanski, Noah Ziems, Heather A. Eicher-Miller 외 (2024). Limitations of the LLM-as-a-Judge Approach for Evaluating LLM Outputs in Expert Knowledge Tasks. arXiv. arXiv:2410.20266

241. Hamed Mahdavi, Alireza Hashemi, Majid Daliri 외 (2025). Brains vs. Bytes: Evaluating LLM Proficiency in Olympiad Mathematics. arXiv.org. arXiv:2504.01995

242. Yilun Zhao, Weiyuan Chen, Zhijian Xu 외 (2025). AbGen: Evaluating Large Language Models in Ablation Study Design and Evaluation for Scientific Research. arXiv. arXiv:2507.13300

243. Chunyang Li, Yilun Zheng, Xinting Huang 외 (2025). WebDevJudge: Evaluating (M)LLMs as Critiques for Web Development Quality. arXiv. arXiv:2510.18560

244. Md Tahmid Rahman Laskar, Israt Jahan, Elham Dolatabadi 외 (2025). Improving Automatic Evaluation of Large Language Models (LLMs) in Biomedical Relation Extraction via LLMs-as-the-Judge. arXiv. arXiv:2506.00777

245. Ran Zhang, Wei Zhao, S. Eger (2024). How Good Are LLMs for Literary Translation, Really? Literary Translation Evaluation with Humans and LLMs. North American Chapter of the Association for Computational Linguistics. arXiv:2410.18697

246. Ajmal M., Abin Roy, Afthab Salam Kanniyan 외 (2026). CLExEval: A Human-in-the-Loop Framework for Qualitative Evaluation of LLM Clinical Reasoning. arXiv. arXiv:2606.31608

247. Mingcheng Zhu, Jinning Liang, Tingting Zhu (2026). Rethinking Correctness for Uncertainty Estimation in Clinical Prediction with Vision-Language Models. arXiv. arXiv:2609.15180

248. Alexandra DeLucia, Heyuan Huang, Sonal Joshi 외 (2026). Same Verdict, Different Reasons: LLM-as-a-Judge and Clinician Disagreement on Medical Chatbot Completeness. arXiv. arXiv:2604.16383

249. Marcello Di Pumpo, Leonardo Villani, Maria Rosaria Gualano 외 (2026). LLM-as-a-judge for infection prevention and control and antimicrobial resistance impact: comparing three main LLMs vs. human experts' assessment. Frontiers in Public Health. doi:10.3389/fpubh.2026.1874389

250. Cyril Drouot, Alain Percivalle (2026). Assessment of Clinical Empathy by an LLM-as-a-Judge: Bias Patterns in ATENA and a Replicable Audit Protocol for Medical Simulation. Education Sciences. doi:10.3390/educsci16091505

251. Natalia Echeverry (2026). QA Bot: LLM-Based Quality Assurance for Online Courses. 2026 2nd International Conference on Human-AI Interaction and Experience Design (HAXD). doi:10.1109/haxd70072.2026.11620617

252. Yunguo Yu (2026). Confidence Is Not Probability: Verification-Based Confidence Prediction for LLM-Generated Clinical Summaries. Preprints.org. doi:10.20944/preprints202607.1999.v1

253. Veerendra Kumar Sunkavalli (2026). LLM Judges as Raters: A Pre-Registered Audit of Severity, Halo, Reliability, and Version Instability in LLM Essay Scoring on Public Corpora. arXiv. arXiv:2608.29517

254. Nathan Brake, Thomas Schaaf (2024). Comparing Two Model Designs for Clinical Note Generation; Is an LLM a Useful Evaluator of Consistency?. NAACL-HLT. arXiv:2404.06503

255. Seungyoon Kim, Seungone Kim (2024). Can Language Models Evaluate Human Written Text? Case Study on Korean Student Writing for Education. arXiv. arXiv:2407.17022

256. Zidu Xu, Johnathan Zeng, Shuang Zhou 외 (2026). Validating LLM judges for automated oversight of patient communication. medRxiv. doi:10.64898/2026.09.16.26363176

257. Mevlüt Okan Aydin, Belkıs Nihan Coşkun, İbrahim Hamal (2026). Assessing multiple-choice question quality in internal medicine: a comparative analysis of three large language models against expert consensus. Frontiers in Medicine. doi:10.3389/fmed.2026.1866674

258. Holly Huang, Debra W. Yen, Michelle Y. Li 외 (2026). Hepatology e-consult responses generated by artificial intelligence demonstrate accuracy but require human oversight. Hepatology Communications. doi:10.1097/hc9.0000000000000983

259. Janak Dave, S Amalan, Harshana Devaraj 외 (2026). Locally Deployable LLMs for Automated Endoscopy Reporting: Benchmarking Generalist vs. Specialist Models. IEEE International Symposium on Medical Measurements and Applications. doi:10.1109/memea69746.2026.11537334

260. Ting Fang Tan, Kabilan Elangovan, Liyuan Jin 외 (2024). Fine-tuning Large Language Model (LLM) Artificial Intelligence Chatbots in Ophthalmology and LLM-based evaluation using GPT-4. arXiv. arXiv:2402.10083
261. Leandro Carísio Fernandes, Marcus Vinícius Borela de Castro, Leandro dos Santos Ribeiro 외 (2026). NormasTCU --- A Brazilian Portuguese IR Dataset and an Evaluation of LLM-as-a-Judge for Relevance Assessment. arXiv. arXiv:2608.27746
262. Tomoaki Yamaguchi, Yutong Zhou, Masahiro Ryo 외 (2025). Agentic Explainable Artificial Intelligence (Agentic XAI) Approach To Explore Better Explanation: A Case Study in Decision Support for Rice Cultivation in Japan. arXiv. arXiv:2512.21066
263. Shalawati Shalawati, A. Nasution, Winda Monika 외 (2026). Beyond BLEU: GPT-5, Human Judgment, and Classroom Validation for Multidimensional Machine Translation Evaluation. Digit.. doi:10.3390/digital6010008
264. Harry Lyu, Neil Thompson (2026). Right Order, Wrong Scale: Auditing LLM Judges for Occupational AI Measurement. arXiv. arXiv:2610.02492
265. Yuhao Chen, Bo Wen, Farhana H. Zulkernine (2025). A Multiagent Summarization and Auto-Evaluation Framework for Medical Text: Development and Evaluation Study. JMIR AI. doi:10.2196/75932
266. Yosuke Yamagishi, Atsushi Takamatsu, Yasunori Hamaguchi 외 (2026). Blinded Radiologist and LLM-Based Evaluation of LLM-Generated Japanese Translations of Chest CT Reports: Comparative Study. arXiv. arXiv:2604.02207
267. Melissa Harbrücker, Franka Menge, A Taebi 외 (2026). Evaluating reasoning models for therapy recommendations in gastrointestinal stromal tumors: expert and LLM-based evaluations of OpenAI o1 and DeepSeek-R1. Journal of Cancer Research and Clinical Oncology. doi:10.1007/s00432-026-06489-7
268. Ting Fang Tan, Kabilan Elangovan, Andreas Pollreisz 외 (2026). Clinical Validation of Medical-based Large Language Model Chatbots on Ophthalmic Patient Queries with LLM-based Evaluation. arXiv. arXiv:2602.05381
269. Pawitsapak Akarajaradwong, Wuttikrai Lertprasertphakorn, Chompakorn Chaksangchaichot 외 (2026). A Two-Phase Stability Study of LLM Judges and Bar Council Examiners on Thai Bar-Exam Free-Form Essays. arXiv. arXiv:2605.25652
270. Billy Gray, Gloria Fragoso-Diaz (2026). Adoption of Large Language Model for Improving Grading Timing in an Engineering Economics Course. ASEE Annual Conference & Exposition. doi:10.18260/1-2--59260
271. Shanshan Xu, Johan Lindholm, Amogh Raina 외 (2026). LP-Eval: Rubric and Dataset for Measuring the Quality of Legal Proposition Generation. arXiv.org. arXiv:2605.19815
272. Mattia Proietti, Lucia Passaro, Alessandro Lenci (2025). Leveraging LLMs to Build a Semi-synthetic Dataset for Legal Information Retrieval: A Case Study on the Italian Civil Code and GPT4-O. Zenodo (CERN European Organization for Nuclear Research). doi:10.5281/zenodo.18611444
273. Thomas A. Buckley, Zahir Kanjee, Peter G. Brodeur 외 (2026). Scaling Clinical Judgment to Evaluate Medical AI. arXiv. arXiv:2609.12822
274. Shuang Zhou, Wenya Xie, Jiaxi Li 외 (2025). Automating Expert-Level Medical Reasoning Evaluation of Large Language Models. arXiv. arXiv:2507.07988
275. Yu-Ming Yang, Xiao Sun, Yuanwei Zou 외 (2026). MentalHospital: A Virtual Environment for Evaluating Psychiatric Clinical Encounters. arXiv.org. arXiv:2607.08257
276. Philip Chung, Akshay Swaminathan, Alex J. Goodell 외 (2025). VeriFact: Verifying Facts in LLM-Generated Clinical Text with Electronic Health Records. arXiv. arXiv:2501.16672
277. Asad Aali, Vasiliki Bikia, Maya Varma 외 (2025). MedVAL: Toward Expert-Level Medical Text Validation with Language Models. arXiv. arXiv:2507.03152
278. Ruotong Zhao, Zhiyu Chen, Xurui Liu 외 (2026). LitReview Arena: Evaluating Literature Review Agents with Battle-Style Peer Review Platform. arXiv. arXiv:2608.21374
279. Yiteng Mao, Kenan Xu, Yijia Lyu 외 (2026). RealMath-Eval: Why SOTA Judges Struggle with Real Human Reasoning. arXiv. arXiv:2606.10254
280. Santiago Gonzalez, Alireza Amiri Bavandpour, Peter Ye 외 (2026). QEDBENCH: Quantifying the Alignment Gap in Automated Evaluation of University-Level Mathematical Proofs. arXiv. arXiv:2602.20629
281. Frank Elberzhager, Matthias Gerbershagen, Joshua Ginkel (2026). Using LLMs to Evaluate Architecture Documents: Results from a Digital Marketplace Environment. arXiv. arXiv:2601.19693
282. Edoardo Loru, Jacopo Nudo, N. Di Marco 외 (2025). The simulation of judgment in LLMs. Proceedings of the National Academy of Sciences of the United States of America. arXiv:2502.04426

283. Federica Bologna, Jean-Philippe Corbeil, Matthew Wilkens 외 (2026). Towards Better Aligned LLM Judges for Radiology Report Evaluation across Modalities and Anatomies. arXiv. arXiv:2604.03376

284. Guneet Singh Kohli, Yuxiang Zhou, Michael Sejr Schlichtkrull 외 (2026). Reference-Free Evaluation of Reasoning in Open-Ended Question Answering. arXiv. arXiv:2607.19678

285. Michael Keeman, Anastasia Keeman (2026). aipsy-judge: A Specialized, Psychologist-Corrected Local Judge for the Psychological Safety of Conversational AI. arXiv. arXiv:2608.24899

286. Yahan Li, Jifan Yao, John Bosco S. Bunyi 외 (2025). CounselBench: A Large-Scale Expert Evaluation and Adversarial Benchmarking of Large Language Models in Mental Health Question Answering. arXiv. arXiv:2506.08584

287. Annette Kott, Manuel Lehner, Rainer Groß 외 (2026). A systematic approach to quality scoring of AI-generated legal texts. International Conference on AI-generated Content. doi:10.1117/12.3109283

288. Soumitra Sinhahajari, Navonil Majumder, Soujanya Poria (2026). On the Limits of LLM-as-Judge for Scientific Novelty Assessment. arXiv. arXiv:2606.12071

289. Diogo Machado (2026). Generative AI bias against scientific novelty: a cautionary tale from a small-sample evaluation of research proposals. Scientometrics. doi:10.1007/s11192-026-05792-x

290. Kyo Gerrits, Rik van Noord, Ana Guerberof Arenas (2026). Creativity Bias: How Machine Evaluation Struggles with Creativity in Literary Translations. arXiv. arXiv:2605.13596

291. Bolei Ma, Yina Yao, Anna-Carolina Haensch (2025). Capabilities and Evaluation Biases of Large Language Models in Classical Chinese Poetry Generation: A Case Study on Tang Poetry. arXiv. arXiv:2510.15313

292. Hyunji Nam, Lucia Langlois, James Malamut 외 (2025). IDEAlign: Comparing Ideas of Large Language Models to Domain Expert. arXiv. arXiv:2509.02855

293. Yann Thorens, Martin Angerer, Pejman Ebrahimi 외 (2026). LLM application in digital asset assessments: mixed methods research. Knowledge and Information Systems. doi:10.1007/s10115-026-02910-2

294. William Philipp, Finn Fassbender, Daniel Fister 외 (2026). Evaluating Large Language Model Raters for German Open-Response Clinical Questions: A Physician-Annotated Benchmark Study of Agreement, Evaluator Bias, and Abstention. arXiv. arXiv:2607.01103

295. Anthony Abou Mrad, Jayanth S. Pratap, Aviona Conti 외 (2026). Stress-testing consentAI: a pipeline for evaluating a conversational educational adjunct to surgical informed consent. npj Digital Surgery. doi:10.1038/s44484-026-00025-3

296. Peter Jansen, Samiah Hassan, Pragnya Narasimha (2025). CodeDistiller: Automatically Generating Code Libraries for Scientific Coding Agents. arXiv. arXiv:2512.01089

297. Toshiaki Koike-Akino, Vladislav Blaykhman, Ye Wang 외 (2026). Vibe Patenting: Evaluating LLM Judges for Professional Patent-Drafting Agents. arXiv. arXiv:2609.13422

298. Gwydion Williams, Samuel Rutunda, Floris Nzabakira 외 (2026). Human evaluators vs. LLM-as-a-Judge: toward scalable evaluation of GenAI in global health. npj Digital Medicine. doi:10.1038/s41746-026-02992-w

299. Sajjad Abdoli, Ghassan Al-Sumaidaee, Ahmad ElShiekh 외 (2026). Benchmarking Frontier LLMs on Arabic Cultural and Sociolinguistic Knowledge: A Cross-Evaluation Framework with Human SME Ground Truth. arXiv. arXiv:2607.00139

300. Jiho Jin, Junho Myung, Juhyun Oh 외 (2026). JuICE: A Benchmark for Evaluating LLM-Judge in Identifying Cultural Errors. arXiv. arXiv:2605.26955

301. Shoko Yamagishi, Shunsuke Kando, Yusuke Miyao (2026). Feasibility Study of Large Language Models for Courtroom Interpreting and Check Interpreting. Journal of Natural Language Processing. doi:10.5715/jnlp.33.1615

302. Jiawen Shi, Zenghui Yuan, Yinuo Liu 외 (2024). Optimization-based Prompt Injection Attack to LLM-as-a-Judge. arXiv. arXiv:2403.17710

303. Narek Maloyan, Bislan Ashinov, Dmitry Namiot (2025). Investigating the Vulnerability of LLM-as-a-Judge Architectures to Prompt-Injection Attacks. arXiv. arXiv:2505.13348

304. Tung-Ling Li, Yuhao Wu, Hongliang Liu (2025). AdvJudge-Zero: Binary Decision Flips in LLM-as-a-Judge via Adversarial Control Tokens. arXiv. arXiv:2512.17375

305. Yulai Zhao, Haolin Liu, Dian Yu 외 (2025). One Token to Fool LLM-as-a-Judge. arXiv. arXiv:2507.08794

306. Yongxi Zhou, Wenbo Ye, Yuanzhe Liu 외 (2026). Style Over Substance: Content-Invariant Wrappers Flip LLM Safety-Judge Verdicts. arXiv. arXiv:2609.08236

307. Yang Gao (2026). How Reliable Is Your Jailbreak Judge? Calibration and Adversarial Robustness of Automated ASR Scoring. arXiv. arXiv:2606.25487

308. Lisa Alazraki, Tan Yi-Chern, Jon Ander Campos 외 (2025). Reverse Engineering Human Preferences with Reinforcement Learning. arXiv. arXiv:2505.15795

309. Narek Maloyan, Dmitry Namiot (2025). Adversarial Attacks on LLM-as-a-Judge Systems: Insights from Prompt Injections. arXiv. arXiv:2504.18333

310. Yaoyao Qian, Yifan Zeng, Yuchao Jiang 외 (2025). The Ranking Blind Spot: Decision Hijacking in LLM-based Text Ranking. arXiv. arXiv:2509.18575

311. Nguyen Khoi Vo, Duy Duong Tuong, Oleg Zendel 외 (2026). The Effect of Multi-Lingual and Keyword Adversarial Injection on LLM Relevance Judgment. arXiv. arXiv:2607.10080

312. Preet Baxi, Jiannan Xu, Jane Yi Jiang 외 (2026). Prompt Injection in Automated Résumé Screening with Large Language Models: Single and Multi-Injection Settings. Findings of the Association for Computational Linguistics: ACL 2026. arXiv:2606.27287

313. Lijia Liu, Takumi Kondo, Kyohei Atarashi 외 (2025). Counterfactual Evaluation for Blind Attack Detection in LLM-based Evaluation Systems. arXiv. arXiv:2507.23453

314. Cheng-Han Chiang, Wei-Chih Chen, Chun-Yi Kuan 외 (2024). Large Language Model as an Assignment Evaluator: Insights, Feedback, and Challenges in a 1000+ Student Course. arXiv. arXiv:2407.05216

315. Xianglin Yang, Bryan Hooi, Gelei Deng 외 (2026). Turning Bias into Bugs: Bandit-Guided Style Manipulation Attacks on LLM Judges. arXiv. arXiv:2605.26156

316. Francisco Eiras, Eliott Zemour, Eric Lin 외 (2025). Know Thy Judge: On the Robustness Meta-Evaluation of LLM Safety Judges. arXiv. arXiv:2503.04474

317. Dipankar Sarkar (2026). A Four-Axis Trustworthiness Benchmark for LLM-as-Judge in Principle-Based Regulation. arXiv. arXiv:2608.14329

318. Victor Akinwande, J. Zico Kolter, Aran Nayebi (2026). Sharding Prevents LLM Oversight Failures and Adversarial Exploitation. arXiv. arXiv:2608.06422

319. Zhipeng Wei, Yuqi Liu, N. Benjamin Erichson (2024). Emoji Attack: Enhancing Jailbreak Attacks Against Judge LLM Detection. arXiv. arXiv:2411.01077

320. Yerin Hwang, Dongryeol Lee, Kyungmin Min 외 (2025). Fooling the LVLM Judges: Visual Biases in LVLM-Based Evaluation. Conference on Empirical Methods in Natural Language Processing. arXiv:2505.15249

321. Zihan Wang, Guansong Pang, Zelin Liu 외 (2026). On the Adversarial Robustness of Multimodal LLM Judges. arXiv. arXiv:2606.15608

322. Guiming Hardy Chen, Shunian Chen, Ziche Liu 외 (2024). Humans or LLMs as the Judge? A Study on Judgement Biases. arXiv. arXiv:2402.10669

323. Srimonti Dutta, Akshata Kishore Moharir (2026). Stability vs. Manipulability: Evaluating Robustness Under Post-Decision Interaction in LLM Judges. arXiv. arXiv:2606.05384

324. Justin Zhao, Himaghna Bhattacharjee, Hannah Korevaar 외 (2026). Jagged Judges: Epistemic Stability Under Perturbation, Pressure, and Persistence. arXiv. arXiv:2608.12645

325. Devanshu Sahoo, Vasudev Majhi, Arjun Neekhra 외 (2025). How to Trick Your AI TA: A Systematic Study of Academic Jailbreaking in LLM Code Evaluation. arXiv. arXiv:2512.10415

326. Weiying Chen, Junlong Shen, Zhanyuan Guo 외 (2026). Assessing Rule Adherence of LLM Adjudicators in Call of Cthulhu TRPG. arXiv:2607.02802

327. Yang Shu (2026). Forged Peer Judgments Mislead Multimodal LLM Judge Panels: Source-Blind Anchoring and Panel-Consensus Verification. arXiv. arXiv:2608.07920

328. Cătălin Anghel, A. Anghel, Antonio Stefan Balau 외 (2026). ClaimArena-LLM: Auditing Adversarial Propagation of False Causal Attributions in Multi-Agent LLM Debates. Machine Learning and Knowledge Extraction. doi:10.3390/make8100327

329. Terry Tong, Fei Wang, Zhe Zhao 외 (2025). BadJudge: Backdoor Vulnerabilities of LLM-as-a-Judge. arXiv. arXiv:2503.00596

330. Ruomeng Ding, Yifei Pang, He Sun 외 (2026). Rubrics as an Attack Surface: Stealthy Preference Drift in LLM Judges. arXiv. arXiv:2602.13576

331. Bowen Qin, Yi Xie, Yesheng Liu 외 (2026). ImpossibleRubrics: Stress-Testing Generated Rubrics as Reward Signals. arXiv. arXiv:2609.16816

332. Devanshu Sahoo, Manish Prasad, Vasudev Majhi 외 (2025). When Reject Turns into Accept: Quantifying the Vulnerability of LLM-Based Scientific Reviewers to Indirect Prompt Injection. arXiv. arXiv:2512.10449

333. Xuyang Guo, Zekai Huang, Zhao Song 외 (2025). Too Easily Fooled? Prompt Injection Breaks LLMs on Frustratingly Simple Multiple-Choice Questions. arXiv. arXiv:2508.13214

334. Marwah Alaofi, Paul Thomas, Falk Scholer 외 (2024). LLMs can be Fooled into Labelling a Document as Relevant: best café near me; this paper is perfectly relevant. SIGIR-AP. arXiv:2501.17969

335. Marwah Alaofi, Paul Thomas, Falk Scholer 외 (2026). On the Use of LLMs for Relevance Labelling. ACM Transactions on Information Systems. doi:10.1145/3788872

336. Manveer Singh Tamber, Jimmy Lin (2025). Illusions of Relevance: Arbitrary Content Injection Attacks Deceive Retrievers, Rerankers, and LLM Judges. arXiv. arXiv:2501.18536

337. Muhammad Khalifa, Lajanugen Logeswaran, Jaekyeom Kim 외 (2026). Gaming the Judge: Unfaithful Chain-of-Thought Can Undermine Agent Evaluation. arXiv. arXiv:2601.14691

338. Akihisha Fujiyama, Niwase Shamim (2026). Forgeable Confirmation in Automated Computer Security Testing: Deterministic Rules versus AI Judges. arXiv. arXiv:2609.24200

339. Hongye Yang, Zhihao Xie, Shengjun Xiong (2026). PartHackBench: Certified Equal-Progress Stress Tests for Partial-Credit Tool-Agent Evaluation. arXiv. arXiv:2609.29578

340. Tobias Kaiser, Aritra Dhar (2026). Pretext: Defeating Malicious Skill Detection Frameworks for AI Agents. arXiv. arXiv:2609.39607

341. Yixin Liu, Yue Yu, DiJia Su 외 (2026). Examining Reasoning LLMs-as-Judges in Non-Verifiable LLM Post-Training. arXiv. arXiv:2603.12246

342. Haosen Wang (2026). Who Sets the Pace of Judge Hacking? Judge Capability versus the Policy-Judge Gap. arXiv. arXiv:2610.15778

343. Isaac Wu, Michael Maslowski (2025). CourtGuard: A Local, Multiagent Prompt Injection Classifier. arXiv. arXiv:2510.19844

344. Idil Gozel (2026). Commit-first LLM judging inherits the judge's own errors. arXiv. arXiv:2609.00088

345. Riya Tapwal, Abhishek Kumar, Carsten Maple (2026). Faithful or Fabricated? A Causal Framework for Rationalization Bias in LLM Judges. arXiv. arXiv:2605.23970

346. David Gros, Adam Gleave (2026). Evaluating using Mock Tool Calls to Quarantine Untrusted Prompt Inputs. arXiv. arXiv:2605.30521

347. Songze Li, Chuokun Xu, Jiaying Wang 외 (2025). LLMs Cannot Reliably Judge (Yet?): A Comprehensive Assessment on the Robustness of LLM-as-a-Judge. arXiv. arXiv:2506.09443

348. Anning Hu, Yangyu Li, Yuqi Huang 외 (2026). StableJudge: A Lightweight Adversarial Defense Framework for LLM-as-a-Judge. arXiv. arXiv:2610.16814

349. Shujie Yang, Xiping Li, Yu-Zheng Li 외 (2026). SEED: A Staged Evidence-Empowered Decoupling Framework for Fraud-Resistant Assessment of Student Text Reports. 2026 8th International Conference on Computer Science and Technologies in Education (CSTE). doi:10.1109/cste69562.2026.11649758

350. Anish Acharya, Kris W Pan, Brian Verkhovsky (2026). RoPoLL: Robust Panel of LLM Judges. arXiv. arXiv:2606.30931

351. Manas Khatore, Sumana Sridharan, Kevork Sulahian 외 (2025). Gaming the Answer Matcher: Examining the Impact of Text Manipulation on Automated Judgment. arXiv. arXiv:2601.08849

352. Adrian Asher (2026). Many Minds, One Verdict: The Limits of LLM Consensus as a Security Gate — Reproducibility Artifact. Zenodo (CERN European Organization for Nuclear Research). doi:10.5281/zenodo.21235384

353. Jujia Zhao, Zhaoxin Huan, Zihan Wang 외 (2026). ReportLogic: Evaluating Logical Quality in Deep Research Reports. arXiv. arXiv:2602.18446

354. Leo Schwinn, Moritz Ladenburger, Tim Beyer 외 (2026). A Coin Flip for Safety: LLM Judges Fail to Reliably Measure Adversarial Robustness. arXiv. arXiv:2603.06594

355. Liam Davis, Romain Emil-Popescu, Suman Jana (2026). Did the LLM Answer the Question? A Semantic Reconstruction Game for Jailbreak Evaluation. arXiv. arXiv:2610.19306